

Análise de Longo Prazo (1985 - 2018) das Mudanças Florestais
na Mata Atlântica Utilizando Técnicas de Detecção de Mudança
Baseadas em Trajetórias

Eduardo Ribeiro Lacerda

Conteúdo

Lista de Figuras	3
Introdução	6
Questionamentos motivadores	8
Objetivos Gerais	8
Objetivos Específicos	8
1 Perspectivas sobre a Utilização de Algoritmos para o Processamento de Séries Temporais no Estudo de Distúrbios Florestais	1
1.1 Introdução	1
1.2 Breve Histórico	3
1.3 Técnicas e Algoritmos para a Análise Temporal de Áreas Florestadas	4
1.4 Detecção de Mudanças Baseada em Limiares	6
1.5 Detecção de Mudanças Baseada no Ajuste de Curvas	6
1.6 Detecção de Mudanças Baseada no Ajuste de Trajetórias	6
1.7 Detecção de Mudanças Baseado na Segmentação de Trajetórias	7
1.8 Exemplos de Técnicas e suas Características	7
1.9 Validação de Séries Temporais	10
1.10 Novas Perspectivas	10
1.11 Conclusão	11
2 Uso do algoritmo Landtrendr em larga escala no contexto tropical: Um estudo de caso na Mata Atlântica entre os anos de 1985 e 2018	1
2.1 Introdução	1
2.2 Materiais e Métodos	2
2.2.1 Área de estudo	2
2.2.2 Dados de entrada	3
2.2.3 Método de análise	6
2.2.4 Escolha da banda ou índice a ser analisado	9
2.2.5 Processamento dos cenários de ganho	13
2.2.6 Processamento dos cenários de perda	15
2.2.7 Escolha dos limiares para a filtragem dos eventos de mudança	17
2.3 Resultados e Discussões	18
2.3.1 Validação	19
2.3.2 Plataforma para visualização dos resultados	21
2.3.3 Resultados para os eventos de perda na Mata Atlântica	22
2.3.4 Os eventos de ganho na Mata Atlântica	23
2.4 Conclusão	24
3 Análise de longo prazo (1985 – 2018) das mudanças florestais na Mata Atlântica utilizando o algoritmo Landtrendr	1
3.1 Introdução	1
3.2 Materiais e Métodos	2
3.2.1 Dados de entrada	2
3.2.2 Processamento dos dados	2
3.3 Resultados e Discussões	3
3.3.1 Resultados para os eventos de perda na Mata Atlântica	3

3.3.2	Os eventos de ganho na Mata Atlântica	14
3.4	Conclusão	22
4	Conclusões	1
5	Bibliografia	1
A	Apêndice - Gráficos com total de área perdida ano a ano por estado	1
B	Apêndice - Gráficos com total de área ganha ano a ano por estado	7

Lista de Figuras

1	Área de Estudo - Mata Atlântica	8
2	Área de Estudo - Mata Atlântica brasileira	3
3	Média da quantidade de imagens disponíveis por ano considerando toda as cenas necessárias para o mapeamento da Mata Atlântica	4
4	Quantidade total de imagens disponíveis por ano considerando toda as cenas necessárias para o mapeamento da Mata Atlântica	5
5	No centro das duas imagens podemos ver os centroides em verde, assim como os polígonos de voronoi na mesma cor. Já em ciano e amarelo, podemos observar os polígonos envolventes para as cenas Landsat 222/73 e 222/74. As imagens de fundo são compostas pela composição das seis bandas geradas pelo Landtrendr para as duas cenas. É possível ver a presença de sobreposição entre os dois resultados a partir dos retângulos envolventes do satélite e também de sobreposição nos polígonos de voronoi.	7
6	Pathrows das imagens Landsat e seus respectivos centróides que foram utilizados para delimitar as cenas a serem processadas pelo algoritmo	8
7	Diagrama de Voronoi criado a partir dos centróides.	8
8	Segmentação temporal do pixel pelo algoritmo Landtrendr. Fonte: Documentação oficial	9
9	Fluxograma do processo de execução do algoritmo Landtrendr	13
10	Fluxograma do processo de pós processamento dos dados de ganho	15
11	Fluxograma do processo de pós processamento dos dados de perda	17
12	Visualização dos valores de NDVI para cada ano. A cor dos pontos segue a mesma coloração obtida pelo pixel na imagem, o que ajuda na interpretação visual dos eventos. Na imagem, podemos ver um evento de perda.	19
13	TimeSync Image Viewer. Evento de perda na bacia hidrográfica do rio São João. Cada imagem representa o mesmo pixel/local para cada ano do estudo.	20
14	Página principal da aplicação web para visualização dos resultados de mudança na Mata Atlântica	22
15	Todos os eventos de perda na Mata Atlântica entre 1985 e 2018.	23
16	Eventos de ganho entre 1985 e 2018.	24
17	Todos os eventos de perda na Mata Atlântica entre 1985 e 2018.	4
18	Mapa com os eventos de perda entre 1985 e 2018 tanto com duração igual a 1 quanto somente maiores que 1.	5
19	Todos os eventos de perda na Mata Atlântica entre 1985 e 2018 por estado. Os valores representam o número de pixels que tiveram alguma detecção de perda.	5
20	Mapa com os eventos de perda entre 1985 e 2018 classificado de acordo com a proporção de área de cada estado.	6
21	Mapa com a proporção dos eventos de perda entre 1985 e 2018 classificado de acordo com a área total de floresta em 1985.	7
22	Todos os eventos de perda rápida (duração igual a 1) na Mata Atlântica entre 1985 e 2018 por estado. Os valores representam o número de pixels que tiveram alguma detecção de perda.	9
23	Todos os eventos de perda longa (duração maior que 1) na Mata Atlântica entre 1985 e 2018 por estado.	10

24	Todos os eventos de perda na Mata Atlântica entre 1985 e 2018 por município. Os valores representam o número de pixels que tiveram alguma detecção de perda.	10
25	Mapa com os eventos de perda entre 1985 e 2018 classificado de acordo com a proporção de área de cada estado.	11
26	Mapa com os eventos de perda entre 1985 e 2018 classificado de acordo com a proporção de área de cada estado.	12
27	Mapa com a elevação relativa dos eventos de perda por estado.	13
28	Mapa com os graus de declividade mais comuns de acordo com as áreas de evento de perda para cada município do bioma.	14
29	Mapa com os eventos de ganho entre 1985 e 2018.	15
30	Mapa com os eventos de ganho entre 1985 e 2018 por estado. Os valores representam o número de pixels que tiveram alguma detecção de ganho.	16
31	Mapa com os eventos de ganho entre 1985 e 2018 classificado de acordo com a proporção de área de cada estado.	16
32	Mapa com a proporção dos eventos de ganho entre 1985 e 2018 classificado de acordo com a área total de floresta em 1985.	17
33	Mapa com os eventos de ganho entre 1985 e 2018 por município. Os valores representam o número de pixels que tiveram alguma detecção de ganho.	18
34	Mapa com os períodos dos maiores eventos de ganho dividido por década por estado.	20
35	Mapa com os períodos dos maiores eventos de ganho dividido por década por município.	20
36	Mapa com a elevação relativa dos eventos de ganho por estado.	21
37	Mapa com os graus de declividade mais comuns de acordo com as áreas de evento de ganho para cada município do bioma.	22
38	Perda de área por ano em Alagoas	1
39	Perda de área por ano na Bahia	1
40	Perda de área por ano no Espírito Santo	2
41	Perda de área por ano em Goiás	2
42	Perda de área por ano no Mato Grosso do Sul	2
43	Perda de área por ano em Minas Gerais	3
44	Perda de área por ano na Paraíba	3
45	Perda de área por ano no Paraná	3
46	Perda de área por ano em Pernambuco	4
47	Perda de área por ano no Rio de Janeiro	4
48	Perda de área por ano no Rio Grande do Norte	4
49	Perda de área por ano no Rio Grande do Sul	5
50	Perda de área por ano em Santa Catarina	5
51	Perda de área por ano em São Paulo	5
52	Perda de área por ano em Sergipe	6
53	Ganho de área por ano em Alagoas	7
54	Ganho de área por ano na Bahia	7
55	Ganho de área por ano no Espírito Santo	8
56	Ganho de área por ano em Goiás	8
57	Ganho de área por ano no Mato Grosso do Sul	8
58	Ganho de área por ano em Minas Gerais	9
59	Ganho de área por ano na Paraíba	9

60	Ganho de área por ano no Paraná	9
61	Ganho de área por ano em Pernambuco	10
62	Ganho de área por ano no Rio de Janeiro	10
63	Ganho de área por ano no Rio Grande do Norte	10
64	Ganho de área por ano no Rio Grande do Sul	11
65	Ganho de área por ano em Santa Catarina	11
66	Ganho de área por ano em São Paulo	11
67	Ganho de área por ano em Sergipe	12

Introdução

A busca por um melhor entendimento dos processos e dinâmicas ocorridas na paisagem passa necessariamente por uma melhor compreensão do tempo [38]. Os avanços na utilização de séries temporais ao longo das últimas décadas vem contribuindo para o avanço da detecção de supressões florestais, sejam as relacionadas a processos antrópicos, como a processos naturais. Estes esforços são importantes principalmente quando utilizados como subsídio ao desenvolvimento e a aplicação de políticas públicas conservacionistas. As aplicações podem ser vistas tanto em análises pontuais como em programas de monitoramento, assim como aplicadas em diversas escalas, mostrando sua flexibilidade para o subsídio de projetos locais [98], regionais [100, 94, 10], nacionais [30] e até mesmo globais [41, 23, 80]. A produção desses insumos contribuem diretamente, por exemplo, para o desenvolvimento de cooperações internacionais viáveis que foquem em políticas compensatórias visando a redução dos efeitos da mudança climática.

No entanto, detectar mudanças na paisagem comparando mapas de uso e cobertura a partir de classificações prévias, tende a propagar erros e terem custo de produção elevado, como o caso de projetos governamentais como o realizado pelo IBGE [54] ou projetos independentes como o Mapbiomas [95]. O aumento na disponibilidade de imagens prontas para processamento [79] em plataformas como o Google Earth Engine facilitaram a aplicação de abordagens que buscam diminuir custos e facilitar o desenvolvimento de produtos no qual o foco pode estar compreendido no entendimento dos processos, sejam eles de curta ou de longa duração.

Ao longo dos últimos 10 anos algumas soluções passaram a ser desenvolvidas com o intuito de suprir esta demanda. Algoritmos de detecção de mudança em séries temporais como o Landtrendr foram desenvolvidos e aplicados inicialmente em ambientes de florestas temperadas [61]. Desde as primeiras versões do algoritmo até hoje, muitas aplicações foram desenvolvidas em diversas áreas como: distúrbios florestais [68, 33], mudanças em áreas urbanas [73, 76], distúrbios causados por incêndios [105, 8], mineração [115, 75], distúrbios em áreas de proteção [65], detecção de mudanças ou abandonos de áreas de produção agrícola [118, 120, 63, 24], entre outros.

Alguns trabalhos em âmbito nacional também foram realizados e buscaram aplicar o algoritmo em áreas tropicais com o objetivo de entender seu comportamento em ambientes de maior diversidade ecológica. No entanto, todos os trabalhos focaram em contextos locais ou espacialmente limitados já que só puderam utilizar a primeira versão do algoritmo, ainda desenvolvido em linguagem proprietária IDL e com processamento exclusivo em ambiente offline, o que limitou significativamente a aplicação do mesmo para áreas extensas. O algoritmo foi aplicado primeiramente em áreas de várzea na floresta amazônica [29] e depois no contexto de Mata Atlântica em escala municipal [119] e estadual [110]. A partir da implementação do algoritmo na plataforma Google Earth Engine [62], a utilização do mesmo pode ser democratizada e possivelmente ampliada para extensões de terra maiores ao mesmo tempo que diminui o custo de produção do mapeamento, já que todo o processamento pesado passou a ser feito de forma gratuita e centralizada em um servidor online.

A partir de sua nova implementação surgiram possibilidades de aplicação do algoritmo visando a detecção de mudanças baseadas em trajetórias não só para paisagens locais como para grandes extensões. No entanto, para que sua aplicação seja de fato difundida como ferramenta de suporte à trabalhos de grande escala e que tenham significância para a elaboração de políticas nacionais e regionais, seria necessário entender seu desempenho

quando aplicado a um grande grupo de ecossistemas e diferentes fitofisionomias.

Após análise de diferentes possibilidades de aplicação e áreas de estudo, verificou-se que o bioma Mata Atlântica poderia ser uma excelente e importante área de estudo para buscar o melhor entendimento da técnica proposta. Assim como sua extensão, o bioma possui outros números impressionantes. É na Mata Atlântica onde cerca de 100 milhões de pessoas vivem e também onde 70% do produto interno bruto brasileiro é gerado, o que em parte explica o fato de hoje apenas cerca de 12% de sua cobertura natural ter persistido e apenas 30% dessas serem protegida em unidades de conservação. Apesar da baixa porcentagem de cobertura natural, é o bioma que abriga mais de 15.700 espécies de plantas e mais de 2.200 espécies de vertebrados registrados pela ciência (260-300 mamíferos; 930-990 aves; 200-300 répteis; 370-480 anfíbios; 300-350 peixes). As estimativas variam, mas, de qualquer forma, impressiona que a Mata Atlântica, representando apenas 0.8% da superfície terrestre do planeta, abrigue cerca de 5% das espécies de vertebrados e 5% da flora mundial [90]. Mesmo tratando-se do bioma brasileiro mais estudado, ainda há muito por descobrir. Entre 1990 e 2006, foram registradas mais de 1.190 novas espécies de plantas na Mata Atlântica, no coração da área urbana da cidade do Rio de Janeiro e novas espécies são encontradas com alguma frequência. Parte expressiva da fauna e da flora da Mata Atlântica é endêmica, ou seja, não ocorre em nenhum outro lugar do planeta. Estima-se que entre 43% e 45% do total de espécies de plantas e vertebrados sejam restritas a esse bioma [90].

A Mata Atlântica ainda apresenta a maior diferença altitudinal e latitudinal dentro todos os biomas brasileiros, o que justifica toda sua complexidade biológica, fitofisionômica e geomorfológica. Sendo assim, quando falamos de floresta no contexto da Mata Atlântica, não estamos falando de apenas uma floresta, mas de muitas. O bioma possui majoritariamente vegetação estacional semidecidual (403 mil km²), seguido por grandes áreas de vegetação ombrófila densa (183 mil km²) e ombrófila mista (160 mil km²). Além disso, possui também outros tipos de fitofisionomias como áreas estacionais deciduais, áreas de vegetação de estepe, savana, áreas de mangue, entre outros.

Sendo assim, a análise se deu em áreas com vegetação de floresta. Foram excluídas áreas de floresta plantada, florestas em ambientes urbanos e também vegetação de mangue ou qualquer outra fitofisionomia não relacionada a tipos de vegetação de grande porte. O trabalho focou especialmente na análise e na validação de áreas de floresta ombrófila e estacional por serem as fitofisionomias mais predominantes no bioma.

O foco foi gerar tanto cenários de perda de vegetação quanto de ganho ao longo do período de 34 anos (1985 - 2018) com o intuito de entender melhor o comportamento do algoritmo na detecção de mudanças em um bioma tão complexo quanto a Mata Atlântica.

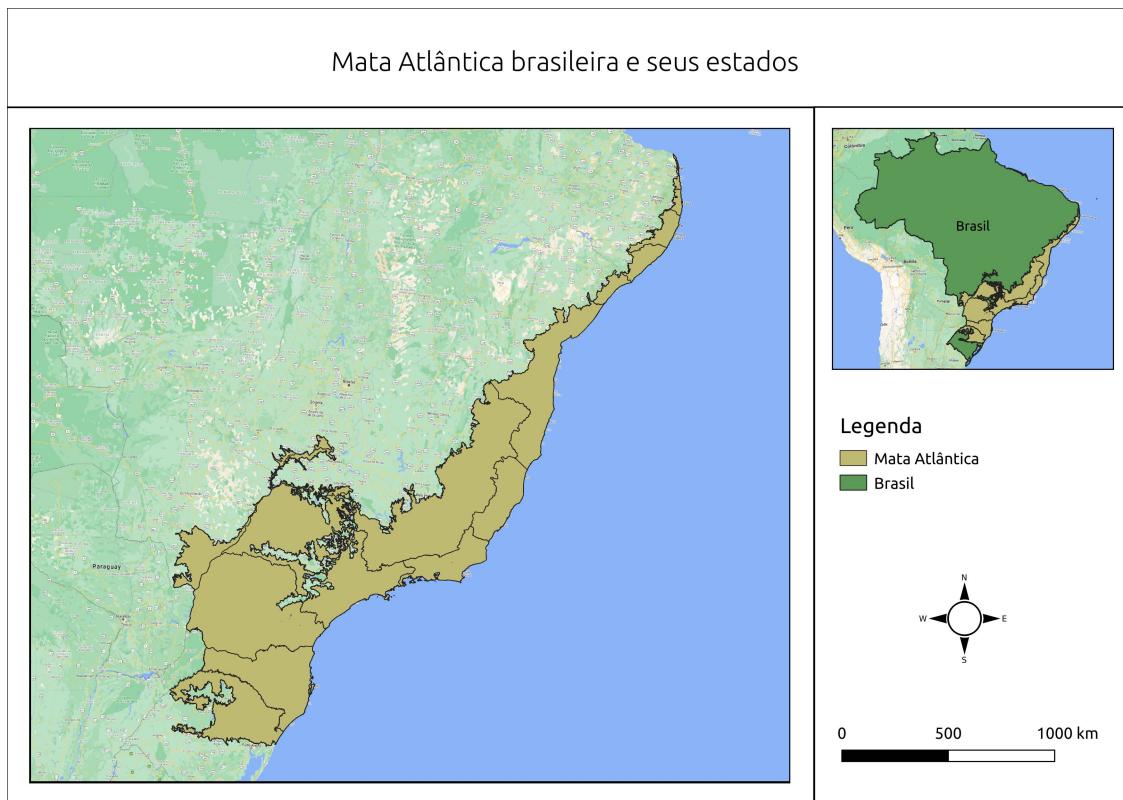


Figura 1: Área de Estudo - Mata Atlântica

Questionamentos motivadores

Os questionamentos motivadores da pesquisa foram:

- Como um algoritmo como o Landtrendr, inicialmente desenvolvido e utilizado para detecção de mudanças em ambientes de floresta temperada poderia ser utilizado para identificar mudanças ocorridas em uma paisagem complexa como a presente na Mata Atlântica?
- Uma metodologia baseada na utilização do algoritmo conseguiria boa performance geral considerando as diferentes fitofisionomias presentes na Mata Atlântica?
- Como se distribuem as perdas e os ganhos de floresta no bioma ao longo das últimas três décadas?

Objetivos Gerais

A tese tem como objetivo geral a análise da evolução do uso das áreas ocupadas por floresta no bioma da Mata Atlântica utilizando o algoritmo Landtrendr com o intuito de desenvolver e apresentar soluções metodológicas para o mapeamento de áreas tropicais de alta complexidade como a do bioma em questão.

Objetivos Específicos

1. Estruturação de uma metodologia para análise de mudanças em áreas de floresta tropical

- Definição do período, seleção das imagens e criação da composição da série temporal Landsat a ser utilizada;
 - Estruturação de um fluxo de trabalho ótimo para o processamento dos dados através do desenvolvimento de software com objetivo de garantir a replicabilidade dos processos;
2. Detecção das mudanças através do mapeamento e classificação das trajetórias
- Definição dos parâmetros e do índice espectral para a execução do processo de segmentação temporal utilizando o algoritmo Landtrendr;
 - Desenvolvimento do código na plataforma Google Earth Engine para a execução do algoritmo em todas as cenas que englobam o bioma da Mata Atlântica brasileira;
 - Mapeamento das trajetórias florestais compatíveis com a escala 1:100.000 através da criação de mapas de detecção de magnitude, ano de início da mudança, duração e taxa de mudança;
 - Avaliação da acurácia dos produtos gerados. Avaliar o desempenho do algoritmo em ambientes de florestas tropicais com alto nível de complexidade ecológica.
3. Análise da distribuição das mudanças no bioma da Mata Atlântica no período de 1985 até 2018
- Análise qualitativa através da criação de mapas de calor;
 - Conversão dos dados matriciais gerados em dados vetoriais com intuito de identificar áreas com maior nível de ocorrência de perdas e ganhos de acordo com divisões políticas e geoecológicas;

Capítulo 1

Perspectivas sobre a Utilização de Algoritmos para o
Processamento de Séries Temporais no Estudo de Distúrbios
Florestais

1 Perspectivas sobre a Utilização de Algoritmos para o Processamento de Séries Temporais no Estudo de Distúrbios Florestais

1.1 Introdução

A necessidade da incorporação do tempo como variável chave em estudos geográficos se deu inicialmente a partir da década de 1960/1970 no campo teórico [38] como uma promessa para a melhor compreensão da dimensão espacial dos processos. Na prática, esta incorporação acabou se dando de forma bastante limitada devido a dificuldade de acesso a séries históricas confiáveis, assim como pela dificuldade de manipulação das mesmas, quase sempre através de um ambiente computacional também limitado. Por décadas, houve uma predominância na ausência de políticas voltadas para o estabelecimento de ações sistemáticas voltadas para o acúmulo de dados em órgãos públicos e empresas do governo, assim como para a criação de programas de monitoramento. Até então, poucas eram as bases disponíveis para além do censo do IBGE, como o PRODES, exceção desenvolvida pelo INPE ainda na década de 1980.

A partir da década de 1990 com o desenvolvimento da internet, da capacidade e barateamento do hardware e do amadurecimento no desenvolvimento de softwares pela comunidade científica, a utilização de métodos computacionais na análise de dados científicos se tornou cada vez mais presente e com uma maior possibilidade de acesso não só a grandes bases de dados como também a ambientes computacionais de alto desempenho. Inicialmente o acesso ainda possuía algumas limitações como a alta concorrência pelo uso de poder computacional disponível e de tráfego de dados através de projetos e editais, mas logo se tornou descentralizado quando muitos projetos puderam ser realizados em *workstations*. Ainda sim, havia uma dependência física da disponibilidade de acesso a estas estruturadas através de centros universitários normalmente localizados em grandes centros urbanos e quase sempre nos países desenvolvidos.

Já nos anos 2000 e 2010 com o estabelecimento da internet como meio oficial de comunicação do corpo científico global através da digitalização dos periódicos, assim como a padronização dela como meio de acesso a bases de dados abertas, parte significativa da comunidade científica passa então a interagir de forma mais integrada ao criar padrões de armazenamento de dados. O aumento da percepção popular sobre o uso de dados acumulados através do uso diário das redes sociais significou também uma percepção quase senso comum sobre a importância do armazenamento de dados ao longo do tempo e também da abertura e transparência sobre dados com características temporais intrínsecas.

Muitas bases de dados importantes tradicionalmente fechadas e com valores de acesso proibitivos para o grande público passaram a disponibilizar todo o acervo de forma gratuita como o caso das imagens do satélite Landsat. A democratização do acesso aos dados é sem dúvida de extrema importância para o desenvolvimento científico global e fica ainda mais evidente quando programas como o do satélite Landsat comprovam o aumento exponencial na produção de trabalhos científicos que passaram a utilizar as imagens desde a liberação [125, 113, 114]. No entanto, o acesso ao poder computacional para processar essa quantidade enorme de dados agora disponível ainda se restringia quase sempre a instituições que já possuíam recurso disponível. Foi somente a partir da segunda metade da década de 2010 que opções baseadas no conceito de computação em nuvem/computação elástica passaram a surgir como uma solução para a falta de capacidade computacional enfrentada por pesquisadores em atuação em instituições de orçamento reduzido. Isso

representou uma mudança significativa para pesquisadores de países onde o acesso as estruturas científicas quase sempre se deu de forma mais limitada.

As consequências dessas novas possibilidades vem gerando não só um aumento ainda maior na quantidade total da produção acadêmica global como também na elaboração de estudos com uma visão descentralizada dos grandes centros de pesquisas já consagrados. Não somente estudos sobre o próprio território, como estudos em escala global que anteriormente eram quase sempre liderados somente pelos mesmos grupos de pesquisa e agora podem ser desenvolvidos por cabeças pensantes no sul global [3].

Devido aos avanços citados, a utilização de séries temporais para a análise espaço-temporal da paisagem tem surgido com maior força nos últimos anos como consequência dessa evolução histórica. A aplicação dessas técnicas é da mais diversa possível, vindo inicialmente quase que exclusivamente dos estudos econométricos e de poucas outras áreas científicas para a sua massificação em muitas outras áreas. Uma delas, e que será abordada neste trabalho é a utilização de técnicas de análise de séries temporais em imagens digitais orbitais com o intuito de analisar perdas e ganhos de vegetação em áreas naturais florestadas. Esse tipo de aplicação vem ganhando força não só pelo entendimento das mudanças da paisagem e suas dinâmicas, como também pela necessidade de entender estes processos no tempo para melhor detectar eventos e monitorar a degradação e a recuperação da paisagem, sejam eles naturais ou antrópicos.

Tanto a análise quanto o monitoramento do uso do solo nunca tiveram tanta importância como hoje devido ao maior entendimento e comprometimento internacional em relação as variáveis influenciadoras do processo da mudanças climáticas através de tratados e acordos de estímulo à conservação e restauração de áreas naturais [2], entendendo ainda o protagonismo da análise espacial e do monitoramento por satélites como ferramenta essencial neste processo [112].

Políticas de REDD+, assim como vários esforços de cooperação internacional como os propostos pelo Bonn Challenge e os Aichi Targets defididos pela CDB (*Convention on Biological Diversity*), tem como ferramenta principal a incorporação de técnicas de sensoriamento remoto para o monitoramento do cumprimento dos objetivos, sendo então diretamente vinculados ao entendimento do comportamento da paisagem no tempo [9, 22]. Estudos mais recentes vem demonstrando que os processos de degradação em florestas tropicais tem impacto similar ou até mesmo maior em relação as emissões de carbono que o desmatamento das mesmas [42, 50, 36]. É importante notar aqui que a utilização do termo distúrbio é diferente do de degradação. Enquanto distúrbio está associado a um único evento que pode ser tanto natural como antrópico, degradação se associa a um processo temporalmente maior de perda de biomassa e a um tipo de influência necessariamente antrópica se considerarmos a definição do IPCC (*Intergovernmental Panel on Climate Change*) ou não necessariamente antrópica caso se considere a definição da FAO (*Food and Agriculture Organization of the United Nations*) [47].

Além disso, outros estudos demonstram que as florestas tropicais tem sofrido mais pressões do que as temperadas. Um terço das florestas tropicais já foram perdidas para o desmatamento, e da área restante, 46% da área está fragmentada, 30% degradada e apenas 24% ainda permanece em estado mais preservado [47]. Sabendo disso, fica ainda mais clara a necessidade de entender quais as melhores técnicas que podem ser utilizadas para o monitoramento destes processos [47].

O momento político em relação a perspectiva da preservação do meio ambiente em que estamos inseridos necessita ainda mais que as pesquisas de compreensão e mapeamento de distúrbios sejam realizadas de forma cada vez mais transparente e acessível a todos

para que processos de degradação sejam detectados a tempo. Apesar da importância inquestionável dos projetos de monitoramento, a análise dos processos no tempo através do mapeamento dessas áreas poderá contribuir ainda mais para um entendimento mais profundo sobre os porquês. Isso representa uma melhora qualitativa das análises sobre a paisagem. Pensando nisso, é importante entendermos quais tecnologias estão disponíveis e quais as possibilidades de mapeamento são possíveis, tendo como objetivo principal entender não só suas potencialidades como suas limitações.

Sendo assim, este trabalho tem como objetivo a apresentação e análise das características dos principais algoritmos de detecção de distúrbios, principalmente os especializados na detecção de mudanças em áreas florestadas, seja na perda como no ganho de biomassa.

1.2 Breve Histórico

Estudos spaçotemporais com o objetivo de detecção de mudanças não são novos na área do sensoriamento remoto. A tradicional análise bi-temporal de dados previamente classificados ainda é presente em muitos estudos atuais. No entanto, esse tipo de estudo tende a conter um número maior de erros, já que quanto maior o número de imagens analisadas, maior a quantidade de mapas com erros de classificação associados que serão levados em consideração. De qualquer forma, estes tipos de estudos tendem a ser o que possuem menor requisito de poder computacional, já que necessitam apenas de operações simples entre álgebra de bandas.

Com o tempo, o maior poder computacional disponível não só para o processamento como para o armazenamento de dados possibilitou que outras técnicas mais elaboradas pudessem ser implementadas, onde ao invés de apenas algumas imagens serem consideradas, todas as imagens da série temporal são levadas em consideração. Isso possibilitou também que muitas técnicas de análise de séries temporais tipicamente aplicadas principalmente na área de econometria pudessem ser utilizadas em estudos geoespaciais.

O processamento de imagens de satélite que historicamente sempre foi feito através do processamento de pixels individuais, passou a partir da década de 2000 a ser feita em muitos casos através do delimitação de objetos com a popularização das imagens de alta-resolução espacial e consequentemente das técnicas de GEOBIA (*Geographic Object-Based Image Analysis*). As análises pixel à pixel que pareciam estar cada vez mais em desuso, acabaram ressuscitando nos últimos anos devido a capacidade de processamento de séries temporais densas. A densidade da série é um ponto chave para esse retorno, já que para que a análise temporal seja bem sucedida e para que os algoritmos aplicados possam entender ainda melhor os processos ocorridos no tempo, é necessário que os dados utilizados tenham resolução temporal condizente com o que se quer detectar. No caso da utilização de imagens de satélite isso se torna um limitador importante, já que a disponibilidade de satélites imageadores historicamente nunca foi alta e tem custo extremamente elevado quando comparado a outros tipos de sensores. Outro problema é que os satélites possuem um tempo de revisita que em muitos casos não possibilitam que uma série mais densa possa ser estruturada. Além disso, problemas como a presença de nuvens, assim como ruídos na própria imagem e a heterogeneidade da distribuição solar no planeta e sua interação com o relevo dificultam ainda mais esse processo ao criar sombras. No entanto, com o tempo, outros satélites foram sendo desenvolvidos e propositalmente pensados com o objetivo de incorporar as séries de imagens já existentes derivadas de projetos antigos com os recém lançados. Um exemplo disso foi o lançamento da série Sentinel 2 (A e B) pela

Agência Espacial Europeia com resoluções espetrais e espaciais similares às encontradas na série Landsat, o que possibilita uma fusão entre imagens de satélites diferentes com o objetivo de aumentar a densidade de imagens. Com isso, tanto a disponibilidade de dados como a resolução temporal dos satélites ganharam nova relevância. A disponibilização de imagens de forma gratuita, assim como a preocupação com a manutenção de séries históricas e o desenvolvimento de constelações que diminuam a resolução temporal acabaram possibilitando esse retorno do pixel como chave analítica central no sensoriamento remoto.

1.3 Técnicas e Algoritmos para a Análise Temporal de Áreas Florestadas

Analizar áreas florestadas sob uma perspectiva temporal possibilita a identificação de processos e padrões que uma simples caracterização espectral mais tradicional não é possível de identificar devido a limitações ligadas a resolução espacial, radiométrica e espectral. Sendo assim, ao incluir a dimensão temporal, é possível entender dinâmicas como a supressão da floresta em um dado momento, assim como também os distúrbios naturais e degradações de origem antrópica ao longo do tempo. A degradação associada ao desmatamento e posterior uso agrícola da terra, seguido do abandono e consequente retorno da vegetação através de processos de regeneração natural, ou então um processo de degradação mais lento, como a extração seletiva de madeira, são exemplos de mudanças no uso e cobertura da terra que só podem ser compreendidos através de técnicas como as que serão mostradas neste trabalho.

Técnicas de detecção de mudança possuem uma longa história na área de sensoriamento remoto. Desde as primeiras aplicações utilizando sensores TM do satélite Landsat 5 na década de 1980 e 1990, muitos estudos foram feitos. Inicialmente os estudos visavam majoritariamente a aplicação de técnicas mais tradicionais como o mapeamento das áreas de interesse utilizando técnicas de classificação de imagens tanto de forma supervisionada como não supervisionada e posterior cálculo da diferença entre duas ou mais imagens. Neste caso, somente métricas como ganho e perda de área e sua consequente espacialização poderiam ser extraídas e visualizadas. No entanto, com o aumento do poder computacional e consequente amadurecimento das técnicas, softwares e bibliotecas disponíveis, o processamento de dados multi-temporais passaram a ser entendidos em sua totalidade. Ou seja, com a aplicação de técnicas menos reducionistas. O que isso significa na prática é que a análise de mudanças de áreas de floresta passou a ser feita através da manipulação tanto da criação de composições anuais, assim como intra-anuais e também da análise de toda a série temporal sem maiores cortes.

Para o processamento de séries temporais utilizando imagens de satélite é necessário se preocupar também com o pré processamento das mesmas para que a aplicação do algoritmo, seja ele qual for, não influencie o resultado final com ruídos derivados de falta de calibração geométrica entre as imagens de diferentes datas, assim como a variação radiométrica, além da presença de possíveis sombras. Para isso, é necessário utilizar técnicas de pré-processamento como a ortorretificação e a correção radiométrica (atmosférica) das imagens. Dependendo do satélite utilizado é possível utilizar métodos implementados pela própria agência distribuidora, o que é bastante recomendado. No caso da correção geométrica das imagens, muitas já são disponibilizadas após serem tratadas automaticamente por método de correção subpixel [40]. Já para a correção radiométrica existem dois tipos: a calibração absoluta e a relativa. A absoluta faz a calibração transformando os

valores digitais em valores físicos de superfície e aplicando algoritmos como o 6S [86], já a calibração relativa utiliza uma imagem de referência como base e aproxima os valores do resto da série de acordo com a imagem base. Trabalhos comparando os dois métodos já foram desenvolvidos utilizando imagens Landsat e apresentam resultados similares [18]. Produtos da série Landsat ainda possuem métodos internos de correção além de máscaras para a filtragem de nuvens, sombras e outras características das imagens [121, 122, 51], o que facilita bastante a etapa de pré-processamento.

Alguns algoritmos foram sendo desenvolvidos ao longo dos últimos anos com o objetivo de lidar melhor com essas séries. Um dos mais tradicionais é o BFEST [102, 103, 104] que possui uma versão visando dados espaciais denominada bfastSpatial [26]. As duas ferramentas possuem o mesmo algoritmo de detecção, mas a versão espacial se diferencia por conta de uma série de funções voltadas para facilitar o pré-processamento dos dados com o intuito de construir inicialmente a série temporal. A construção das séries temporais em ambiente offline sem ajuda de ferramentas mais modernas é, de fato, bastante trabalhosa e contém muitas etapas necessárias para que a análise final possa ser feita sem maiores problemas e sem a geração de ruídos por conta de dados de entrada problemáticos. É importante notar também que as duas ferramentas, diferentemente de outros algoritmos que serão analisados neste trabalho, não são voltados exclusivamente para a detecção de distúrbios em ambientes florestais, mas sim em basicamente qualquer outro tipo de uso. No entanto, o uso das duas ferramentas em ambientes florestais é provavelmente o mais comum entre os trabalhos existentes.

O BFEST tem como ideia geral analisar a série temporal de imagens analisando os valores pixel à pixel e detectar quebras (*breakpoints*) de pixels que tenham valor discrepante do valor médio esperado. É possível detectar mais de uma quebra em uma mesma série de pixels, o que é interessante principalmente para análise de usos agrícolas, assim como quando comparados a áreas florestais. O algoritmo ainda pode ser utilizado em objetos, como apresentado por Siti Latifah [67], onde a integração com técnicas de GEOBIA apresentou ótimos resultados. Este resultado demonstra ainda um novo potencial a ser explorado, onde a integração de dois paradigmas (pixel/objeto) através do processamento de séries temporais pode trazer novas formas de análise e até mesmo a implementação de novos algoritmos.

Já outros trabalhos utilizando o BFEST demonstraram a capacidade do mesmo na detecção de quebras para a caracterização de distúrbios cíclicos em florestas com o objetivo de explicar mudanças estruturais que acabam influenciando diretamente na qualidade da floresta presente e não só na sua simples presença ou não presença [55, 27].

Mais recentemente, o BFEST passou por um processo de reimplementação, deixando a linguagem R de lado como em sua versão original e sendo totalmente reprogramado utilizando a linguagem Python. Essa mudança se deu pela fato da nova versão possuir uma integração direta com a biblioteca de processamento paralelo OpenCL, o que garantiu uma diminuição no tempo total de processamento em duas ordens de grandeza [34]. Por utilizar um padrão aberto de paralelismo, a nova implementação possui a capacidade de poder se beneficiar do paralelismo independente do tipo e do fabricante do hardware, podendo ser paralelizado tanto na CPU (Intel/AMD) quanto na GPU (Nvidia, AMD, Intel).

Além do BFEST, outras implementações computacionais foram desenvolvidas com o objetivo de analisar séries temporais para detecção de padrões em tipos variados de uso do solo. Este é o caso do Timesat [58]. O Timesat, apesar de ter a aplicação mais voltada para a caracterização de tipos de culturas agrícolas através da interpretação da

série, também possui uso na caracterização de tipos e também de distúrbios em florestas [111]. O Timesat ainda possui diversas ferramentas internas para o tratamento de ruídos, tratamento de dados faltantes e composição de séries sazonais utilizando algoritmos como o Savitzky-Golay [88].

Ao aprofundarmos mais, para além das técnicas mais tradicionais, podemos entender que esses algoritmos apresentados, assim como muitos outros existentes se diferenciam entre si. Além disso, alguns acabam sendo desenvolvidos como algoritmos especialistas na aplicação de detecção de distúrbios em florestas, ao contrário dos algoritmos já citados. Esses novos métodos de análise ainda podem ser categorizados em quatro sub-categorias: algoritmos baseados na detecção de mudanças baseados em limiares, os baseados em ajude de curvas, os baseados no ajude de trajetórias e os baseados na segmentação de trajetórias [4, 47].

1.4 Detecção de Mudanças Baseada em Limiares

Os métodos de detecção baseados em limiares funcionam buscando a diferenciação de áreas de floresta e não floresta, e posteriormente separando áreas de floresta "intacta" das que sofreram algum tipo de distúrbio ou processo de degradação. A ideia é utilizar uma série temporal previamente tratada formadas tanto puramente por índices de vegetação, como pela integração de diversas bandas espectrais e bandas sintéticas derivadas de estatísticas da própria série. Esses métodos possuem um grande potencial e aplicação, mas ao mesmo tempo tem como ponto negativo a necessidade da delimitação empírica de limiares, o que dificulta bastante a replicabilidade dos trabalhos.

1.5 Detecção de Mudanças Baseada no Ajuste de Curvas

A utilização de métodos baseados no ajuste de curvas em áreas florestadas tem como objetivo entender o comportamento espectral primeiramente aplicando uma linha de regressão, onde, dependendo da inclinação da mesma, é possível detectar a presença ou ausência de mudanças significativas. Além disso, o sinal da inclinação determina também o ganho ou perda de biomassa. O lado negativo desse método é a necessidade da suposição de uma certa normalidade entre os dados de entrada, o que em sensoriamento remoto é quase sempre muito difícil de se obter. Isso já tende a limitar a aplicação de métodos como esse a sensores com menor resolução temporal como os presentes no projeto MODIS (*Moderate-Resolution Imaging Spectroradiometer*), ou então de composições muito bem estruturadas de sensores como o Landsat. A utilização desse método pode ser exemplificada pelo trabalho desenvolvido no bioma amazônico utilizando imagens MODIS onde é demonstrado a relação entre o corte seletivo e a mudança da resposta fenológica da vegetação na região ao longo do tempo [64].

1.6 Detecção de Mudanças Baseada no Ajuste de Trajetórias

As técnicas de ajuste de trajetórias se diferenciam das anteriores por analisarem as mudanças a partir de trajetórias idealizadas. Através da aplicação de métodos comparativos (ajuste) entre a série estudada com a de referência, seja através do cálculo da distância euclidiana como pela utilização de métodos mais complexos como o DTW (*Dynamic Time Warping*) [101, 87, 6] ou sua versão para a classificação de uso do solo, o TWDTW (*Time-Weighted Dynamic Time Warping*) [70, 69], o ajuste de trajetórias

funciona como um método de análise supervisionado já que depende de amostras de "treino" para a obtenção de resultados satisfatórios.

Este tipo de algoritmo, devido a sua natureza de carácter supervisionado, tem sido utilizado principalmente em estudos aplicados na tipificação de culturas agrícolas, onde a diferenciação dos alvos só pode ser feita utilizando conhecimentos relativos ao comportamento espectral do alvo no tempo. Este tipo de algoritmo necessita de uma densidade de imagens maior que as outras técnicas, já que é necessário o maior grau possível de precisão na série para encaixar e detectar as características entre as duas séries. Para este tipo de aplicação são utilizadas normalmente imagens derivadas do sensor MODIS, devido a sua resolução temporal e as suas aplicações na caracterização do comportamento espectral de grandes áreas agrícolas, onde a resolução espacial das bandas do visível e NIR, mais usadas na elaboração de índices, apresentam resolução de 250m. É possível utilizar imagens Landsat com este método, mas é necessário acumular uma grande densidade de imagens através da fusão do histórico de vários sensores e/ou trabalhando com área de interseção entre path/row diferentes, o que limita sua aplicação [5]. Além dessas limitações, outros desafios vem sendo enfrentados em relação à dificuldade de detecção de distúrbios pontuais de corte seletivo e posterior regeneração natural do local, já que amostras muito bem definidas para este tipo de distúrbio precisam ser coletadas. No entanto, exemplos de aplicação em florestas tropicais são presentes [48, 59].

1.7 Detecção de Mudanças Baseado na Segmentação de Trajetórias

O método de segmentação de trajetórias pode ser exemplificado pelo algoritmo Landtrendr [60, 61], que funciona dividindo a série temporal em segmentos para posterior classificação. Este tipo de abordagem favorece estudos onde o objetivo não está somente na quantificação de eventos de grande impacto e mudança, mas também na qualificação desses eventos. Com este tipo de algoritmo é possível não só a detectar distúrbios imediatos (provável evento de desmatamento), como em detectar de distúrbios de longo prazo (possível processo de degradação/corte seletivo/praga), assim como processos de regeneração/recuperação de longa duração (regeneração natural) e de curto prazo (floresta plantada e projetos de reflorestamento). Os segmentos são divididos a partir da identificação de vértices ao longo da série. Os vértices representam os pontos da série onde ocorreram algum tipo de mudança na qual o algoritmo considerou relevante. A escolha da relevância para a criação de um vértice (quebra) é feita de acordo com regras pré-definidas pelo usuário. Outra vantagem desse método é a possibilidade de análise sem a necessidade de amostras de eventos exemplo como no caso dos algoritmos de ajustes de trajetórias. No entanto, o método de segmentação de trajetórias também possui suas desvantagens. Uma delas é que algoritmo tende a desconsiderar efeitos sazonais da vegetação, apesar da possibilidade de ajuste da série através da utilização de limiares de relevância para consequente suavização. Além disso, é um método que ainda possui poucos trabalhos que aplicam o métodos em florestas tropicais, sendo em sua maioria aplicados à áreas temperadas [78, 39].

1.8 Exemplos de Técnicas e suas Características

Além do BFAST e de outros algoritmos/softwares apresentados previamente, podemos listar brevemente alguns outros algoritmos de detecção automática de mudanças. É

importante notar que alguns desses na verdade não realizam exatamente o trabalho de detecção da mudança, mas sim mais um processo de predição dessas mudanças, já que trabalham a partir de técnicas de regressão. Algumas características e particularidades de cada algoritmo também serão apresentadas. Todos foram desenvolvidos nos últimos anos e representam grande parte dos métodos de detecção automática de distúrbios presentes na literatura recente. São eles:

- **CCDC** - *Continuous Change Detection and Classification* [123] - O CCDC apresenta funções de análise de séries temporais utilizando não composições anuais ou intra-anuais, mas sim toda a série de imagens de entrada sem a necessidade de intervalos constantes, o que o difere da maioria dos algoritmos exemplificados aqui. O CCDC funciona apenas com imagens sem a presença de nuvens e sombra e busca encontrar padrões de sazonalidade, tendências e quebras na série. Uma característica interessante do CCDC é que o algoritmo é capaz de gerar imagens "sintéticas" para qualquer data presente na série de entrada [124]. Estas imagens sintéticas geradas são utilizadas obrigatoriamente como dado de entrada por algoritmos como o MIICA e o ITRA e também podem ser utilizadas opcionalmente por algoritmos como o Landtrendr e o VCT, ao invés de utilizar as imagens originais com valores de reflectância da superfície. O CCDC é utilizado para a detecção de eventos de grande magnitude, sendo limitado para a detecção de processos de degradação, por exemplo. No entanto, pode ser utilizado na detecção de mudanças de vários tipos de uso do solo e não somente na detecção de distúrbios florestais.
- **COLD** - *Continuous Monitoring of Land Disturbance* [19] - O COLD é baseado no CCDC com o objetivo de melhorar a detecção de distúrbios florestais. Diferente do CCDC que detecta mudanças baseadas em eventos de grande diferença espectral, o COLD possui a capacidade de detecção de mudanças mais sutis, o que lhe garante suprir essa deficiência presente no CCDC.
- **LandTrendr** [60, 61] - O Landtrendr, desenvolvido pelo Environmental Monitoring, Analysis and Process Recognition Lab da Universidade de Oregon, também trabalha tanto com composições de imagens com valores de reflectância da superfície como com imagens sintéticas geradas pelo CCDC. O algoritmo necessita que as imagens não possuam interferência de nuvens e sombras e gera seus dados de saída através da aplicação da técnica de segmentação de trajetórias. O Landtrendr pode gerar saídas como métricas tanto para distúrbios de perda como de ganho, além de detectar se as mudanças ocorreram de forma lenta ou rápida, possibilitando também o cálculo da duração dos eventos segmentados previamente gerando não só dados contínuos como a magnitude, assim como dados discretos como a duração e o ano da detecção. É certamente um dos algoritmos com maior quantidade de informação gerada por rodada, o que facilita muito sua utilização. Outra vantagem do Landtrendr é que apesar de ter sido implementado inicialmente utilizando a linguagem de programação proprietária IDL em um ambiente bastante complicado de manuseio através do software ENVI, foi recentemente implementado diretamente na plataforma online Google Earth Engine [35], o que veio a facilitar e muito sua utilização pela comunidade [62]. A conversão do algoritmo para a plataforma online do Google possibilitou ainda que o tempo de processamento do mesmo fosse reduzido significativamente. No entanto, a plataforma parece restringir o processamento para uma área equivalente a de uma imagem Landsat por vez. Ou seja, para a aplicação do

algoritmo para áreas maiores é necessário dividir o processamento em segmentos menores.

- **VCT** - *Vegetation Change Tracker* [51, 99] - O VCT utiliza composições sem nuvem de imagens com valor de reflectância da superfície, ou de composições sintéticas geradas pelo algoritmo CCDC e extrai uma métrica de similaridade a áreas de floresta intacta. O algoritmo prediz os distúrbios detectando padrões que se afastam da métrica de similaridade.
- **EWMACD** - *Exponentially Weighted Moving Average Change Detection* [13] - Este algoritmo foi desenvolvido com o objetivo de detectar apenas distúrbios florestais ao analisar o resíduo entre o pixel observado e os valores derivados de uma predição gerado por um processo de regressão harmônica [12]. Além disso, tem como característica, assim como o CCDC, utilizar todas as imagens de entrada ao invés de composições. Também possui uma série de funções e parâmetros para a detecção de mudanças de pouca magnitude e de longo prazo, apresentando bons resultados na detecção de processos de degradação.
- **VerDET** - *Vegetation Regeneration and Disturbance Estimates through Time* [52] - O VerDET funciona através da entrada de composições anuais sem nuvem com valores de reflectância de superfície que são segmentadas se baseando em técnicas de regressão utilizando redes neurais artificiais. Para cada pixel o slope é calculado e são posteriormente interpretados como áreas de distúrbio, estabilidade e regeneração, além de apresentar as magnitudes para a interpretação e classificação entre eventos rápidos ou lentos. Assim como o EWMACD, o VerDET também foi desenvolvido para trabalhar apenas com detecção de distúrbios em florestas.
- **MIICA** - *Multi-index Integrated Change Analysis* [57] - Este algoritmo utiliza a composição de imagens sintéticas como entrada e tem como característica realizar sua análise baseado em limiares em intervalos bi-anuais. O MIICA analisa as mudanças espectrais de magnitude baseado nesses limiares utilizando quatro índices diferentes (NBR - *Normalized Burn Ratio*, NDVI - *Normalized Difference Vegetation Index*, *Change Vector* e o *Relative Change Vector Maximum*). Pode detectar mudanças relacionadas ao ganho e perda de biomassa e também a cenários de não mudança. É voltado para a detecção de grande magnitude e pode ser utilizado para a detecção de mudança em vários tipos de uso do solo.
- **ITRA** - *Image Trends from Regression Analysis* [108] É outro algoritmo que utiliza composições anuais sem nuvem geradas sinteticamente pelo CCDC. O ITRA ainda divide a série em três períodos e compara as mesmas com um modelo de regressão linear. É um algoritmo que tem como ênfase a detecção de distúrbios de longo período tanto em florestas como em áreas com vegetação arbustiva. Devido a sua característica de poder identificar mudanças de diferentes magnitudes, o ITRA pode ser utilizado detecção não só de distúrbios em florestas como também em outros tipos de vegetação.
- **Shapes-NBR** [71, 72] Como o nome já demonstra, este algoritmo funciona através da composição de uma série temporal de índices NBR, o que o difere de sua aplicação original, onde apenas um preditor de mudanças em áreas florestadas era utilizado e portanto chamado apenas de Shape [91]. O algoritmo funciona para cada pixel aplicando um método de regressão aditiva semi-paramétrico fornecendo uma trajetória

suavizada restrita para se comportar de uma maneira ecologicamente sensível. Assim como o Landtrendr, este também gera resultados de acordo com as formas encontradas como o ano da detecção, magnitude da mudança, valores prévios à mudança e posteriores, assim como taxas de crescimento ou recuperação.

1.9 Validação de Séries Temporais

O processo de validação de séries temporais se difere dos adotados em estudos de mapeamento de apenas uma ou poucas datas de estudo. Normalmente as amostras coletadas para validação são extraídas para apenas uma única data e comparada ao resultado obtido, no entanto, no caso do processamento de séries temporais, muitas datas ou até mesmo toda uma série de imagens deve ser utilizada como dado de entrada para os algoritmos preditores. Sendo assim, o método tradicional perde sua validade. É necessário analisar toda a série de imagens utilizada para entender os momentos de possível quebra e consequente detecção do distúrbio para podermos obter um resultado com maior precisão. Principalmente em situações onde houve distúrbios florestais que aconteceram em um determinado momento histórico e que posteriormente iniciaram um processo de regeneração natural ou então uma mudança para um terceiro uso do solo. Quanto maior a quantidade de tipos de mudança ocorridos durante o tempo analisado, maior a complexidade e consequente necessidade de utilização de métodos de validação apropriados.

Um dos métodos mais utilizados atualmente na validação de séries temporais, independentemente do algoritmo utilizado para a detecção das mudanças é o TimeSync [21]. O TimeSync possui versão offline na qual possui uma interface gráfica onde é possível visualizar não somente uma imagem de uma única data, mas toda a série temporal tanto através de gráficos como através de miniaturas de imagens referentes a área mais próxima do pixel analisado. Além disso, após a implementação do algoritmo Landtrendr na plataforma Google Earth Engine, é possível exportar os dados para validação diretamente da plataforma online. O TimeSync funciona recebendo uma lista de coordenadas na qual ele utiliza para exportar pequenas imagens com um *buffer* da coordenada analisada para cada ano da série. O software utiliza uma interface gráfica para apresentar uma imagem por ano para cada coordenada e assim possibilitar que o pesquisador faça a validação visual de cada local ao longo do tempo. Os pontos de interesse para a validação são escolhidos pelo próprio usuário, preferencialmente de forma aleatória e estratificada de acordo com as classes utilizadas no mapeamento da série. As formas para a criação dos pontos aleatórios estratificados são diversas e podem ser feitas em um SIG assim como utilizando linguagens de programação através de bibliotecas especializadas.

1.10 Novas Perspectivas

Com a possibilidade de uso de diversos algoritmos e tipos de análise disponíveis, a escolha por um único método de análise pode ser problemática. Trabalhos desenvolvidos com o objetivo de comparação entre os algoritmos também podem ser problemáticos já que muitos dos algoritmos não se propõe exatamente ao mesmo tipo de análise. No entanto, é possível encontrar trabalhos que apresentam uma integração dos mesmos com o objetivo de encontrar o melhor resultado possível. O trabalho proposto por Sean Healey [43] buscou integrar todos os oito algoritmos citados neste trabalho junto a outros dados de entrada como o próprio conjunto de imagens com valores de reflectância da superfície, relevo e um mapa temático com os tipos de vegetação presente nas cenas. Todos os dados de entrada

foram então processados e classificados utilizando o Random Forest [11]. Vários resultados foram gerados utilizando todos os dados de entrada assim como variações de combinação entre eles: resultados utilizando somente imagens Landsat, utilizando somente o resultado da combinação de todos os oito algoritmos preditivos, todos os algoritmos combinando as imagens Landsat, entre outros. O resultado que acabou representando a menor quantidade de erros foi justamente o que levou em consideração todos os dados de entrada possíveis.

Outro estudo ainda mais recente desenvolvido por [14] também buscou analisar distúrbios florestais integrando vários algoritmos apresentando ótimos resultados. Além disso, implementações feitas utilizando somente algoritmos com o Random Forest analisando séries temporais de imagens Landsat junto a camadas derivadas de estatísticas simples foram realizadas e também obtiveram resultados promissores [109]. Estudos como os citados demonstram que apesar do bom resultado obtido individualmente, os algoritmos de detecção estudados possuem um potencial ainda maior de resultados ainda melhores quando integrados ou entre si e/ou utilizando técnicas híbridas. Além disso, não é possível dizer de forma objetiva que uma técnica seja melhor que outra. Cada uma apresenta pontos positivos e negativos dependendo do tipo de análise a ser realizada. No entanto, dentro os algoritmos analisados, o Landtrendr tem se mostrado a opção com implementação mais acessível e madura na plataforma do Google, o que possibilita uma maior democratização da técnica. Também é a solução que apresenta o maior número de erros de comissão e menor quantidade de omissão. A maior quantidade de eventos de comissão junto com uma baixa taxa de omissão se mostra promissora devido ao fato de que quase sempre é mais fácil limpar o resultado final removendo erros de comissão do que adicionar omissões.

1.11 Conclusão

Ao analisar as opções de algoritmos disponíveis entendendo melhor suas características positivas e negativas, assim como outras possibilidades de implementação das análises de séries temporais de forma integrada, podemos compreender melhor o potencial da pesquisa na área. O desenvolvimento de soluções de monitoramento de distúrbios e de processos de degradação assim como de regeneração, restauração e conservação de áreas de interesse tem alavancado ainda mais a aplicabilidade dos acordos nacionais e internacionais que são mais do que nunca necessários para o desenvolvimento de políticas públicas que busquem resultados práticos.

As aplicações destas tecnologias em ambientes tropicais ainda se encontra defasado quando comparado aos realizados em ambientes temperados, no entanto, o potencial para seu uso vem ampliando ao longo dos anos com o amadurecimento e ampliação do acesso a essas ferramentas em plataformas de uso livre como o Google Earth Engine. Sendo assim, a revisão de conceitos e potencial de aplicação das tecnologias apresentadas neste trabalho espera ter contribuído para uma atualização da comunidade científica em relação ao tema abordado.

Capítulo 2

Uso do algoritmo Landtrendr em larga escala no contexto
tropical: Um estudo de caso na Mata Atlântica entre os anos de
1985 e 2018

2 Uso do algoritmo Landtrendr em larga escala no contexto tropical: Um estudo de caso na Mata Atlântica entre os anos de 1985 e 2018

2.1 Introdução

A disponibilização de forma gratuita de imagens Landsat ao longo dos anos possibilitou um aumento significativo no número de estudos em diversas áreas ao redor do mundo [125, 114]. Já o surgimento recente de ferramentas de processamento paralelo na nuvem como o Google Earth Engine [35] vem possibilitando agora uma ampliação tanto da área dos estudos quanto também na densidade de cenas, ou seja, na quantidade de imagens Landsat processadas para um único local, o que significa um maior desenvolvimento nas análises temporais.

A incorporação do tempo nas análises espaciais possibilita não só uma maior compreensão dos processos que ocorrem na paisagem como pode ser usado como subsídio para o gerenciamento de recursos e monitoramento de áreas de conservação ou projetos de restauração, estes cada vez mais importantes no contexto geopolítico atual devido principalmente aos efeitos crescentes das mudanças climáticas.

Com o intuito de possibilitar estas análises, algoritmos especializados passaram a ser desenvolvidos principalmente na última década. Podemos citar como exemplo o desenvolvimento de ferramentas como o CCDC [123], COLD [19], VCT [51, 99] , VerDET [52], EWMACD [13], MIICA [57], ITRA [108], Shapes-NBR [71, 72] e o Landtrendr [60, 61] que tem se mostrado uma das opções mais populares desde sua implementação na plataforma do Google [62].

No entanto, inicialmente, grande parte destes algoritmos foram desenvolvidos e testados quase sempre em áreas reduzidas e majoritariamente de clima temperado. Ao incorporar ferramentas de processamento de *big data* como o Google Earth Engine, algoritmos como o Landtrendr puderam ser de certa forma expandidos e acabaram viabilizando sua aplicação em áreas de grande extensão, assim como em áreas com diferentes configurações climáticas.

Apesar disso, ainda sim vivemos sob crescente demanda de técnicas que deem conta de forma cada vez mais precisa de projetos de análise e/ou de monitoramento de áreas florestadas devido ao crescente número de projetos de conservação e restauração vinculados muitas vezes à acordos internacionais que impactam diretamente no desenvolvimento econômico dos países. Para além da própria detecção da mudança, se torna cada vez mais necessário a qualificação da detecção, e que as ferramentas utilizadas para a detecção, além de precisas, sejam de fácil implementação, manutenção, validação e possuam preferencialmente baixo requisito computacional.

Uma das áreas sob constante interesse nacional e internacional é o bioma da Mata Atlântica. O interesse pelo bioma é antigo, já que foi a primeira região do Brasil a ser colonizada e também por ser considerado um *hotspot* de biodiversidade [84]. Devido a sua evolução histórica, é também o bioma mais fragmentado, o que exige, mais do que em outros biomas, um cuidado especial na hora de analisar seus remanescentes. Devido ao efeito da fragmentação, a resolução espacial da análise se torna ainda mais importante já que resoluções mais grosseiras podem levar a uma má interpretação de sua condição ecológica atual, subestimando a quantidade total de floresta. Além disso, devido a sua área extensa, a aplicação de algoritmos de detecção de mudança na região acabam sendo limitados a pequenas regiões, já que são ferramentas que necessitam de alto poder computacional. Este fator dificulta não só possíveis análises quanto principalmente a incorporação de técnicas

de detecção de distúrbios baseado em séries temporais em projetos de monitoramento.

Devido a sua importância no contexto nacional, inúmeras análises, acordos e projetos de monitoramento foram e ainda são realizados na região. No entanto, nenhum deles incorporou técnicas de detecção de mudança baseado na segmentação de trajetórias para todo o bioma. Isso significa que para além da detecção de eventos de mudança e sua quantificação em área e cruzamento com suas respectivas classes, ainda existe uma dificuldade na qualificação dessas mudanças. Novas técnicas de análise tem mostrando bons resultados na acurácia das áreas que sofreram algum tipo de interferência e também na adição de informações como a magnitude do evento, ano de detecção, taxa de mudança, entre outros. Informações que atualmente podem ser obtidas, mas somente através de análises posteriores. No entanto, ainda existe dúvida sobre a capacidade de análise de algoritmos como o Landtrendr para áreas tropicais, e principalmente de grande extensão. Seus pontos positivos e negativos não só em relação aos resultados apresentados mas a viabilidade de implementação da técnica para esta quantidade de dados.

Este estudo tem como objetivo buscar um melhor entendimento da capacidade do algoritmo Landtrendr na detecção das dinâmicas ocorridas ao longo de mais de três décadas para todo o bioma da Mata Atlântica considerando suas principais fitofisionomias. Foram analisadas áreas de vegetação estacional semi-decidual, vegetação ombrófila densa e também áreas de vegetação ombrófila mista. Áreas com predominância de vegetação de estepe, savânica, mangue, além de áreas altamente antropisadas foram excluídas da análise.

A escolha deste algoritmo se deu pelo mesmo ter obtido resultados mais interessantes quando comparado a outras técnicas [89] e devido a sua recente implementação na plataforma Google Earth Engine [62], o que facilitou sua aplicação a uma área tão grande como a deste bioma.

2.2 Materiais e Métodos

2.2.1 Área de estudo

O estudo abrange toda a área do bioma da Mata Atlântica dentro do território brasileiro (Figura 2), que possui atualmente uma área total de aproximadamente 1.1 Mkm² ou 110 Mha. O bioma está presente em 15 estados brasileiros e é onde se localiza grande parte da atividade econômica e população do país. Atualmente, vivem na Mata Atlântica cerca de 72% da população brasileira, o que em parte explica o fato de hoje apenas cerca de 28% [84] de sua cobertura natural ter persistido.. O bioma ainda possui 75,6% das espécies ameaçadas e endêmicas do Brasil, o que o torna um dos mais prioritários para conservação no país. Além disso, estima-se que entre 43% e 45% do total de espécies de plantas e vertebrados sejam restritas a esse bioma [90]. O número elevado de espécies no bioma o coloca como a quinta área mais ameaçada e rica em espécies endêmicas do Mundo. No total são 1.361 espécies, sendo 261 espécies de mamíferos, 620 de aves, 200 de répteis e 280 de anfíbios. Das 1.361, 567 só ocorrem neste bioma [53].

Na época da chegada dos portugueses no Brasil, a Mata Atlântica cobria cerca de 1,5 milhões de quilômetros quadrados (incluindo ecótonos), estendendo-se ao longo de 3 mil quilômetros da costa brasileira - do Rio Grande do Sul ao Rio Grande do Norte - e penetrando pelo interior, cruzando São Paulo, Minas Gerais e Mato Grosso do Sul até as fronteiras da Argentina e do Paraguai [90]. Cerca de 500 anos depois, esse extenso e representativo bioma abriga mais de 100 milhões de pessoas, cerca de 1/4 das quais ainda vivem na pobreza [90].

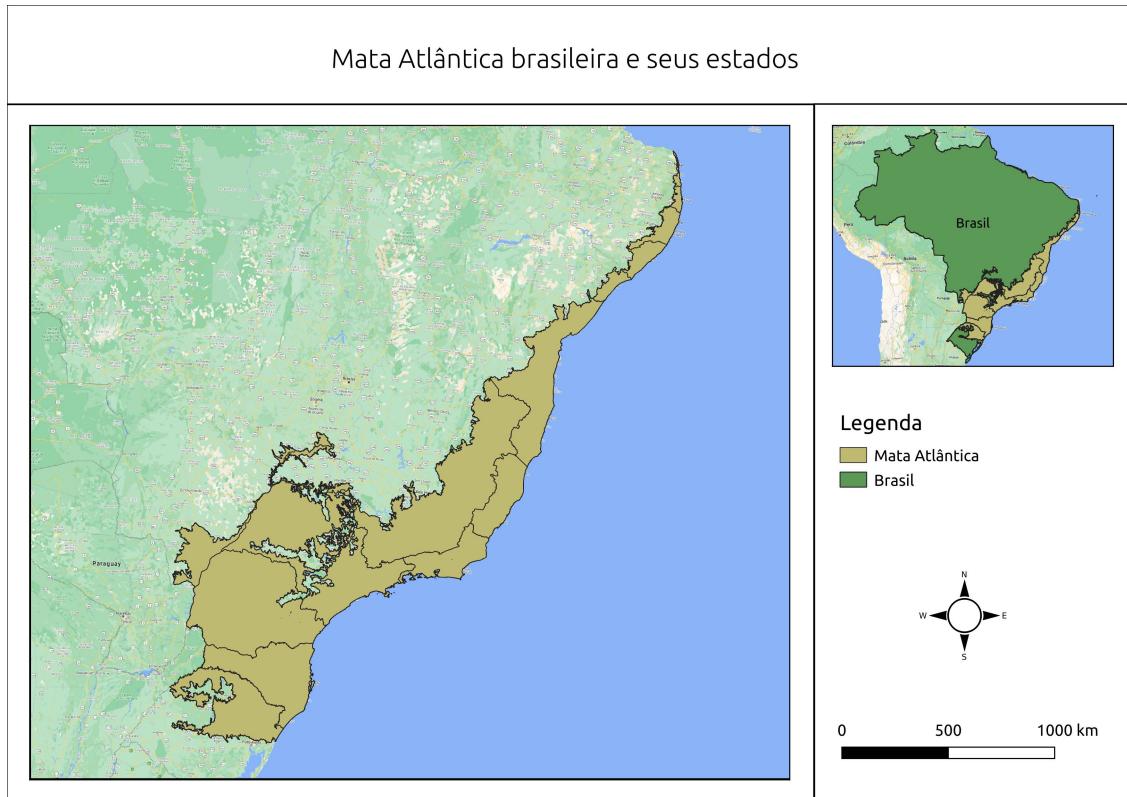


Figura 2: Área de Estudo - Mata Atlântica brasileira

Segundo o projeto Mapbiomas [95], a área total de florestas no bioma em 1985 era de mais de 30 Mha e em 2018 de 28 Mha. Já a área de florestas que não sofreram mudanças significativas (pseudo-invariantes) durante o período de 1985 até 2018 foi de aproximadamente 21.4 Mha. Deste total, somente 30% da vegetação nativa remanescente está protegida legalmente através de unidades de conservação.

2.2.2 Dados de entrada

Para o mapeamento do bioma consideramos um intervalo anual que compreendeu todos os anos de 1985 até 2018 utilizando imagens do satélite Landsat das séries 5, 7 e 8. A escolha desse período de análise se deu por conta do início da captura de dados em 1 de março de 1984 pelo satélite Landsat 5 e consequente disponibilidade de dados pela comunidade científica para o mesmo período, o que facilitou a verificação e validação dos resultados. Para cobrir todos os 110 Mha do bioma foi necessário a compilação e processamento de 88 cenas Landsat. Se considerarmos que para cada cena que engloba os 33 anos da análise temos uma média de 23 imagens por ano, temos um total de aproximadamente 67 mil imagens, o que representaria quase 2.5x toda a quantidade de imagens Landsat utilizada em estudos no continente sul americano nos últimos 50 anos [44]. Se considerarmos ainda que cada uma dessas imagens utilizadas possui pelo menos 7 bandas, chegamos a um cubo multidimensional de quase meio milhão de bandas. Um processamento que sem dúvidas só seria possível com o advento das tecnologias já citadas. No entanto, a distribuição da quantidade de imagens disponíveis para uso para a série Landsat ao longo dos 33 anos não é uniforme, como mostra a figura 3. Já a quantidade real de imagens utilizadas por ano pode ser visto na figura 4.

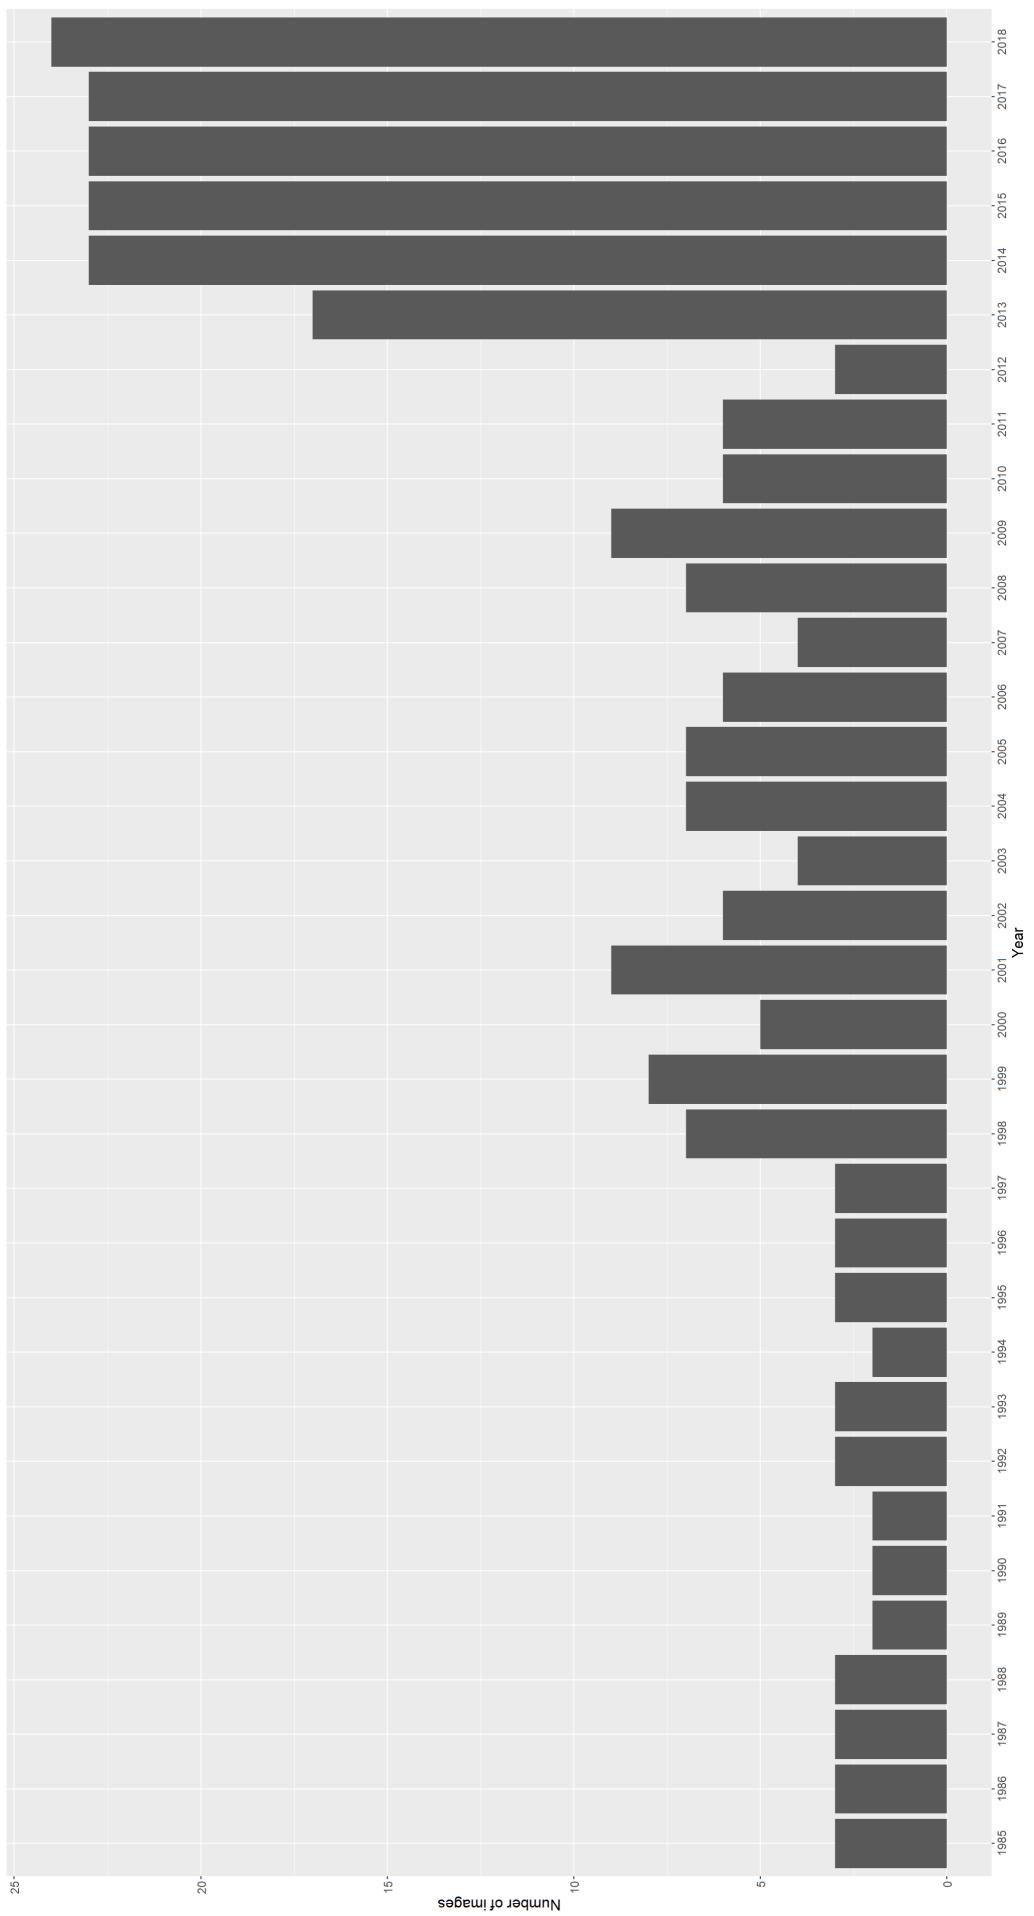


Figura 3: Média da quantidade de imagens disponíveis por ano considerando toda as cenas necessárias para o mapeamento da Mata Atlântica

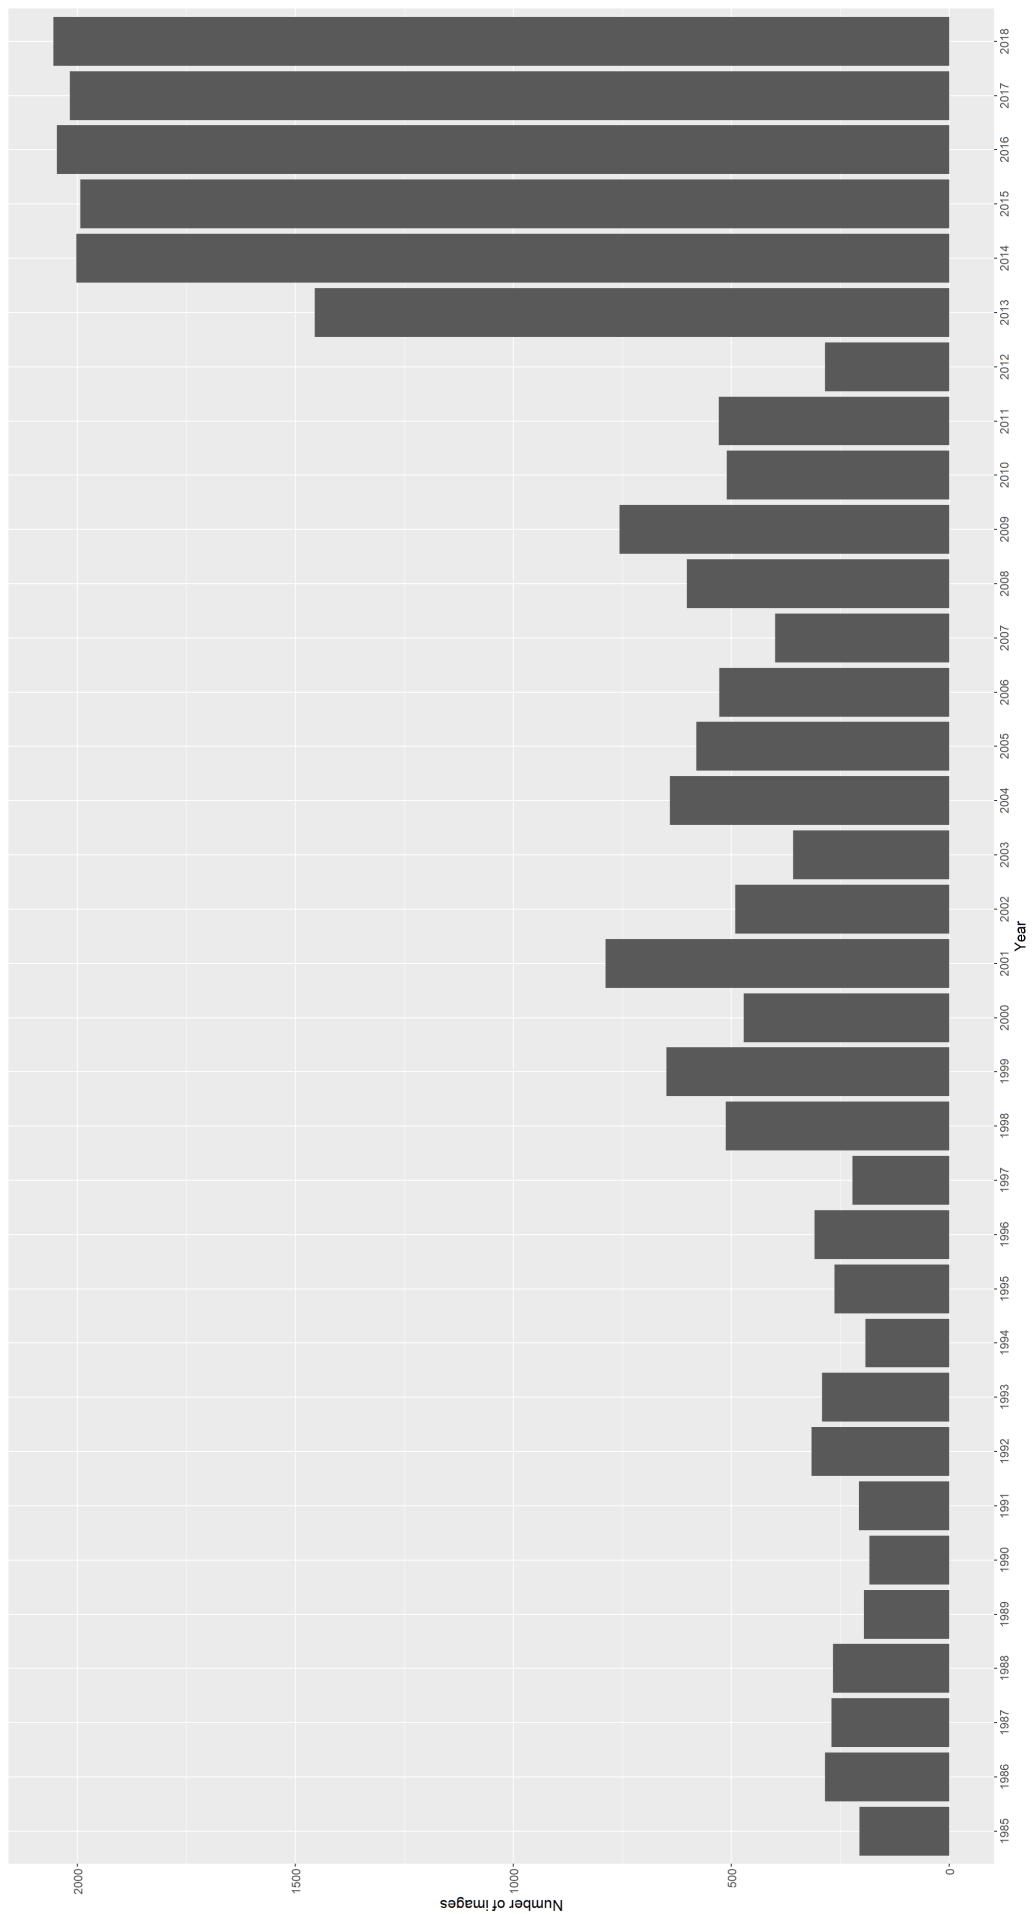


Figura 4: Quantidade total de imagens disponíveis por ano considerando toda as cenas necessárias para o mapeamento da Mata Atlântica

Todas as imagens utilizadas são da coleção *surface reflectance*, o que significa que já possuem correção geométrica, radiométrica e possuem valor físico referente a superfície terrestre. Além disso, as imagens passaram por processo de harmonização para evitar acúmulo de ruídos e também de remoção de nuvens e sombras. Todos os processamentos para a composição das séries temporais foram feitos utilizando funções internas do próprio Landtrendr, o que facilitou em muito toda a etapa de preparação dos dados.

2.2.3 Método de análise

A análise das trajetórias foi feita utilizando o algoritmo Landtrendr em sua versão para a plataforma Google Earth Engine (GEE) [62]. A principal vantagem da implementação do algoritmo no GEE em relação a sua versão original em ENVI/IDL está na possibilidade de sua aplicação em áreas extensas com um tempo de pré-processamento e análise em si muito menores, o que possibilita sua aplicação em contextos anteriormente inviáveis. O ganho de tempo não está somente no tempo de processamento do algoritmo em si, como também na eliminação de grande parte dos desafios técnicos relacionados ao processamento dos dados de entrada presentes em sua implementação clássica. No entanto, apesar do ganho significativo no tempo de processamento, o Landtrendr para o GEE também apresenta algumas limitações quando comparado a sua versão em original em IDL. Uma das maiores está na limitação na extensão da análise para apenas uma imagem Landsat por vez. A plataforma apresentou erros sistemáticos quando requisitada para processar análises para toda a Mata Atlântica de uma só vez, ou para áreas que abrangiam vários estados, por exemplo. Com isso, o processamento teve de ser feito em etapas.

As etapas tiveram de ser divididas por cenas Landsat, neste caso, 88 cenas (Figura 6). Como o resultado do algoritmo é dado de forma separada por cena, foi necessário juntar todas as camadas geradas. Devido a ruídos presentes nas bordas das imagens Landsat e a sobreposição natural entre imagens diferentes, nem todos os pixels presentes nas bordas apresentaram resultados similares. Juntar todos as 88 camadas de resultados em uma se tornou um desafio e só foi possível através da criação de polígonos de voronoi [77], o que possibilitou utilizarmos somente as áreas mais próximas do centro das camadas geradas pelo algoritmo (Figura 5).

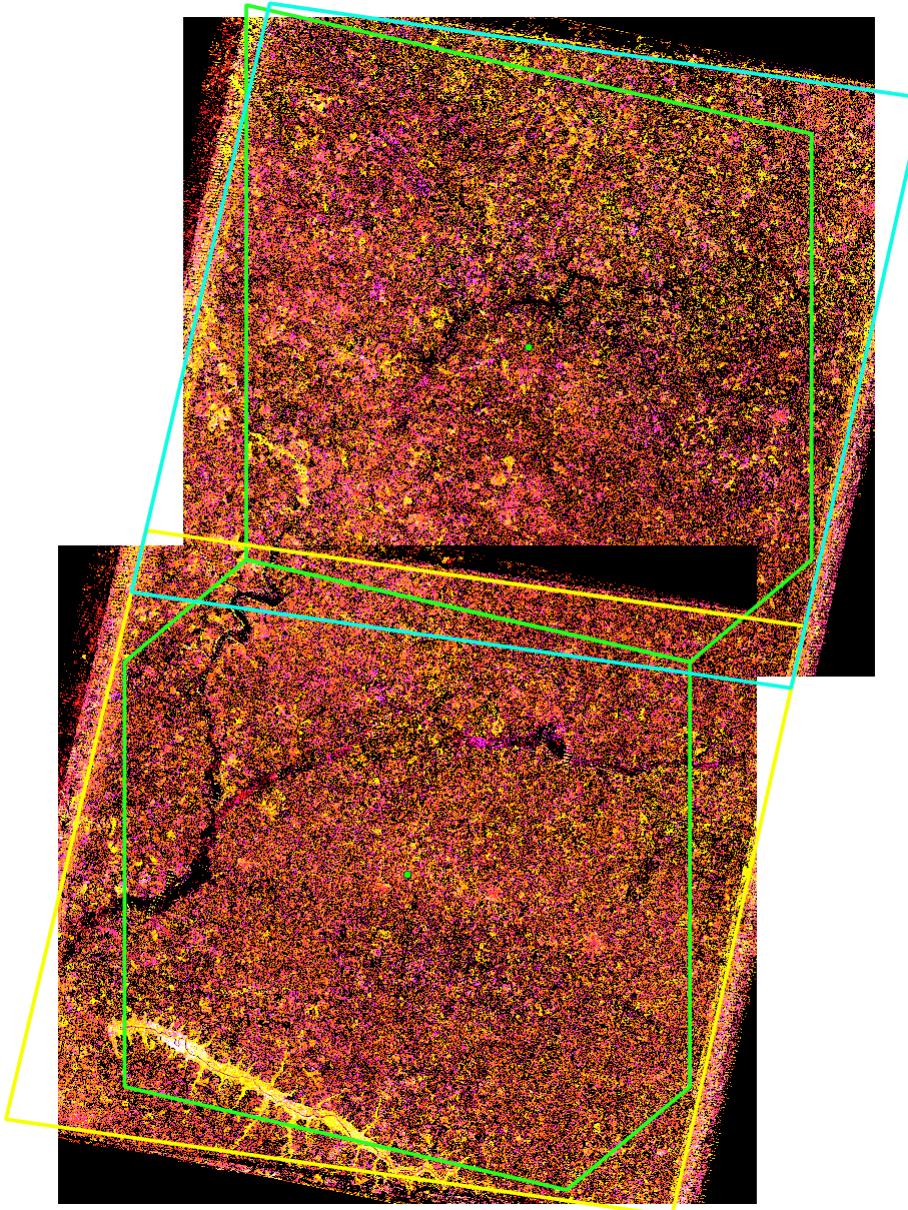


Figura 5: No centro das duas imagens podemos ver os centroides em verde, assim como os polígonos de voronoi na mesma cor. Já em ciano e amarelo, podemos observar os polígonos envolventes para as cenas Landsat 222/73 e 222/74. As imagens de fundo são compostas pela composição das seis bandas geradas pelo Landtrendr para as duas cenas. É possível ver a presença de sobreposição entre os dois resultados a partir dos retângulos envolventes do satélite e também de sobreposição nos polígonos de voronoi.

Os polígonos de voronoi foram gerados através da extração dos centroides dos polígonos delimitadores das cenas Landsat e posteriormente utilizados para a criação dos polígonos com as áreas centrais (Figura 7). Após a geração dos polígonos de voronoi, os mesmos foram utilizados para recortar os resultados de forma a limpar possíveis sobreposições. Após o recorte, todas as imagens foram agregadas para toda extensão do bioma e separadas banda a banda para análise posterior.

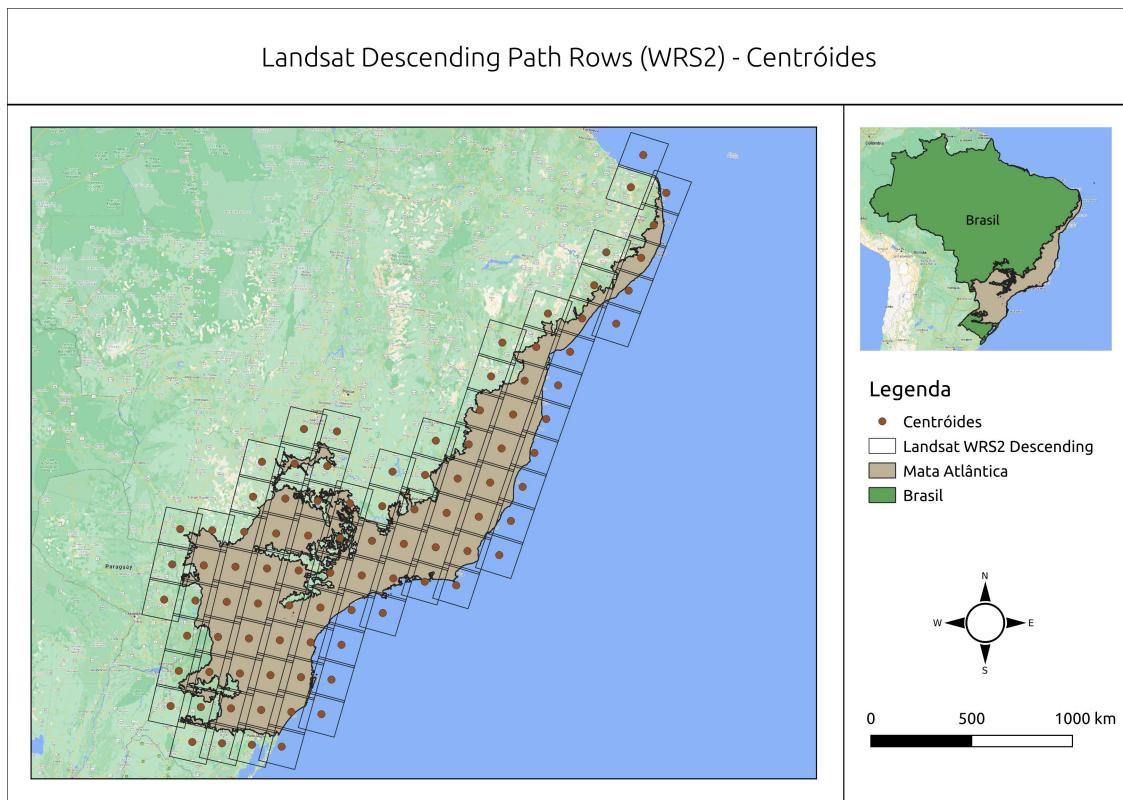


Figura 6: Pathrows das imagens Landasat e seus respectivos centróides que foram utilizados para delimitar as cenas a serem processadas pelo algoritmo

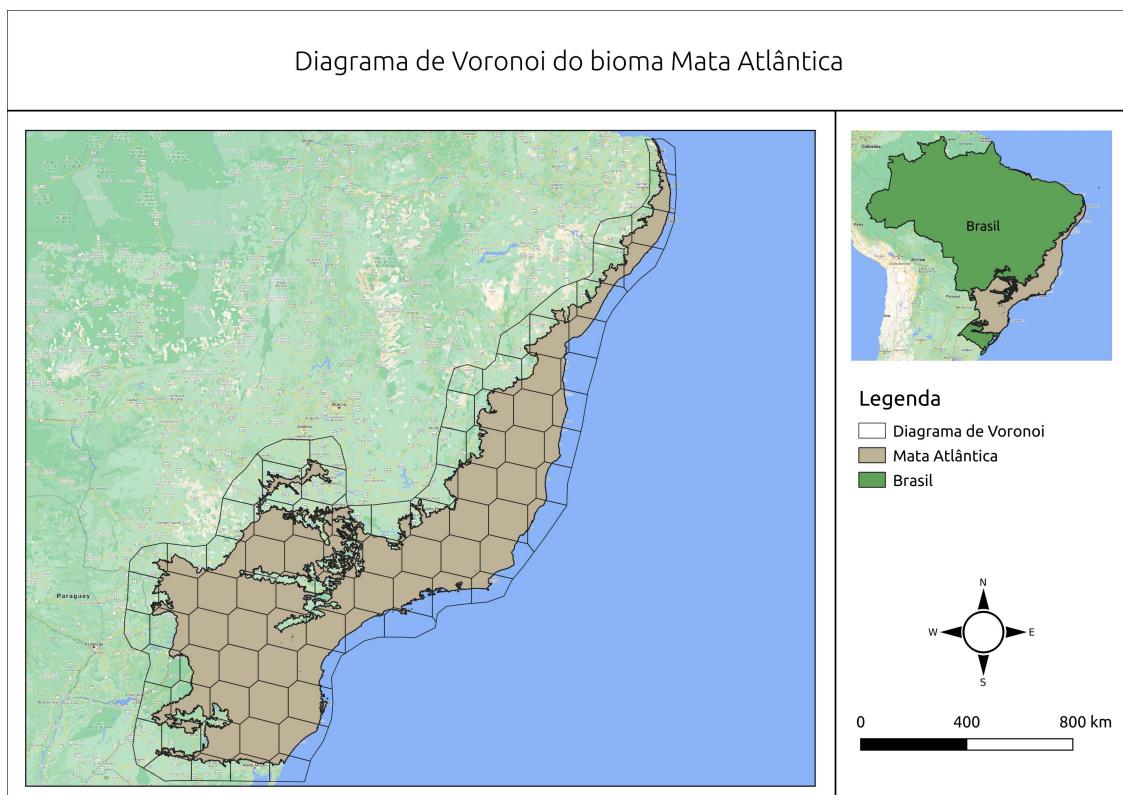


Figura 7: Diagrama de Voronoi criado a partir dos centróides.

O algoritmo Landtrendr trabalha analisando os valores pixel a pixel para toda a composição de imagens visando criar segmentos e assim identificar trajetórias (Figura 8). O algoritmo pode gerar métricas tanto para distúrbios de perda como de ganho, além de detectar mudanças que ocorreram de forma lenta ou rápida, possibilitando também o cálculo da duração de eventos segmentados previamente gerando dados contínuos, discretos, assim como a duração e o ano da detecção. Podemos analisar, portanto, a história do pixel em questão, neste caso, sob uma perspectiva meso-escalar das florestas de Mata Atlântica. Para realizar o processo de segmentação temporal o algoritmo pode utilizar tanto uma banda padrão do satélite como algum índice espectral. Alguns índices já bem estabelecidos já estão implementados na ferramenta como o NDVI (*Normalized Difference Vegetation Index*), o EVI (*Enhanced vegetation index*), o NDMI (*Normalized Difference Moisture Index*) e o NBR (*Normalized Burn Ratio*). É possível também utilizar uma das próprias bandas do satélite para realizar as análises, como a banda do vermelho ou o SWIR (*Short-wave infrared*).

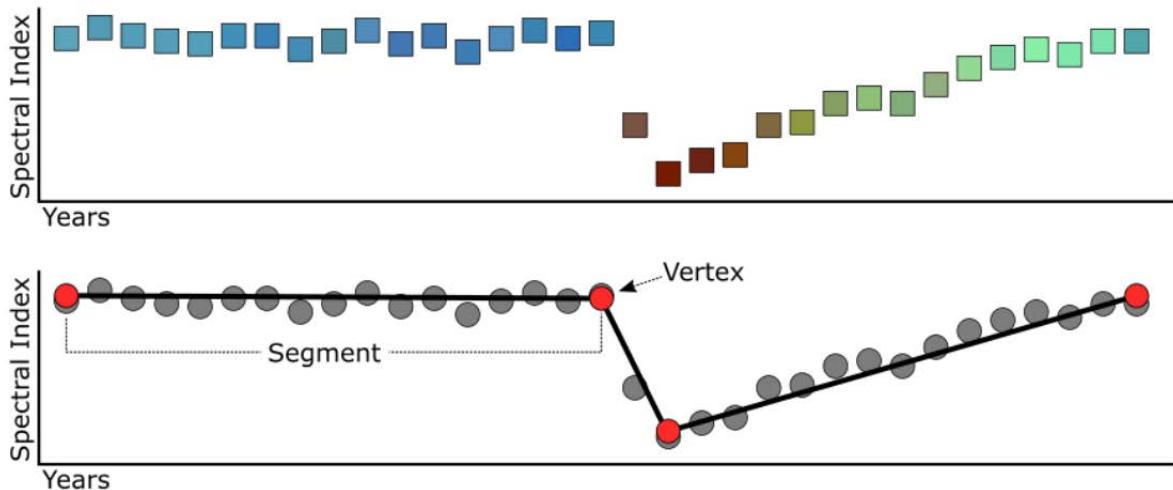


Figura 8: Segmentação temporal do pixel pelo algoritmo Landtrendr.
Fonte: Documentação oficial

2.2.4 Escolha da banda ou índice a ser analisado

A escolha do índice a ser utilizado é parte importante do processo já que essa escolha pode influenciar na precisão do processo de identificação das mudanças de acordo com o que se está tentando detectar. O índice NBR, tradicional no monitoramento de queimadas vem mostrando excelentes resultados na detecção de mudanças em áreas de florestas temperadas, com resultados superiores a índices mais tradicionais como o próprio NDVI ou o EVI.

Em áreas tropicais, o uso de índices com o NDVI ainda é predominante [106, 29], mas devido a variabilidade na qualidade dos resultados de acordo com a banda ou índice utilizado, o algoritmo fornece como uma das camadas resultantes de cada análise realizada uma banda extra chamada CSNR (*Change Signal to Noise Ratio*), que oferece uma métrica para entender qual banda pode ser ideal para cada tipo de região estudada. Antes chamada de DSNR (*Disturbance Signal to Noise Ratio*), o CSNR é calculado ao dividir o valor obtido pelo sinal da mudança pelo ruído calculado pelo RMSE [20]. Como o CSNR

só pode ser gerado após a execução do algoritmo, é recomendado que o algoritmo seja primeiro executado para uma mesma área teste diversas vezes utilizando bandas e índices diferentes para cada rodada. Bandas/índices que obtiverem maior valor médio geral na camada CSNR possuem menor quantidade de erro associada ao processo de detecção de mudanças.

Sendo assim, o teste com a banda CSNR foi realizado para as 13 bandas/índices (Azul, Verde, Vermelho, NIR, SWIR, Tasseled Cap Brightness/Greenness/Wetness, NBR, NBRz, NDVI, EVI e NDMI) presentes no algoritmo para cada uma das fitofisionomias estudadas no bioma neste estudo (Tabela 1).

Camada	Est. Semidecidual	Omb. Mista	Omb. Densa	Média
SWIR	2.53	3.47	3.00	3.00
Vermelho	2.49	3.25	2.93	2.89
TCW	2.40	3.26	2.95	2.87
Verde	2.42	3.16	2.76	2.78
TCB	2.58	3.05	2.66	2.77
EVI	2.56	2.82	2.87	2.75
NDMI	2.27	2.86	2.98	2.70
NDVI	2.40	2.85	2.86	2.70
NBR	2.27	2.90	2.81	2.66
NBRz	2.25	2.88	2.81	2.65
TCG	2.05	2.19	2.53	2.26
NIR	2.06	2.17	2.31	2.18
Azul	1.92	2.36	2.19	2.16

Tabela 1: Mediana dos valores da camada CSNR para cada banda/índice em cada fitofisionomia (Estacional Semidecidual, Ombrófila Mista e Ombrófila Densa). A última coluna representa a média geral da banda/índice considerando todas as medianas obtidas em todas as fitofisionomias.

Podemos observar que de forma geral os melhores resultados se concentraram nas regiões de floresta ombrófila com uma maior quantidade de ruído nas regiões estacionais, resultado de certa forma já esperado devido a maior interferência estrutural devido ao ciclo das estações. Mesmo analisando composições anuais, podemos perceber que existe interferência no valor mediano em regiões estacionais suficiente para influenciar na geração de ruídos. Apesar disso, o acréscimo de ruídos nas regiões estacionais não impactou o resultado final a ponto de influenciar a acurácia global de forma significativamente negativa.

Quanto aos índices disponíveis, nenhum apresentou resultado superior para todas as fitofisionomias. Para as áreas de vegetação ombrófila, a banda do SWIR apresentou o melhor resultado tanto nas áreas mistas quanto densas. Já nas áreas semideciduais, o melhor resultado se deu com os valores de bilho do Tasseled Cap, seguido do EVI. O tradicional NDVI obteve um resultado geral mediano, tecnicamente empatado com o NDMI. Já na média geral, foi o SWIR que obteve melhor resultado. O NBR, índice recorrente em trabalhos aplicados a áreas temperadas não se saiu tão bem em ambientes tropicais, mas se posicionando logo abaixo do NDVI.

Apesar desses resultados iniciais, um novo teste foi realizado. Desta vez, uma nova área de teste dentro de florestas ombrófilas densas foi adicionada com o intuito de entender se os resultados obtidos se manteriam similares entre fitofisionomias semelhantes. A

área escolhida foi dentro da Bacia Hidrográfica do Rio São João (BHRSJ). Através do novo teste, foi possível observar que houve grande variabilidade na escolha dos melhores índices/bandas mesmo em regiões similares. Desta vez, a banda do vermelho obteve o melhor resultado, seguido do NDVI, o que fez a média geral do índice normalizado subir (Tabela 2).

Camada	BHRSJ	Est. Semidecidual	Omb. Mista	Omb. Densa	Média
SWIR	3.09	2.53	3.47	3.00	3.02
Vermelho	3.35	2.49	3.25	2.93	3.00
TCW	3.00	2.40	3.26	2.95	2.90
Verde	3.15	2.42	3.16	2.76	2.87
NDVI	3.25	2.40	2.85	2.86	2.84
TCB	2.86	2.58	3.05	2.66	2.79
NDMI	3.00	2.27	2.86	2.98	2.78
EVI	2.85	2.56	2.82	2.87	2.77
NBRz	2.94	2.25	2.88	2.81	2.72
NBR	2.88	2.27	2.90	2.81	2.71
TCG	2.93	2.05	2.19	2.53	2.43
NIR	2.68	2.06	2.17	2.31	2.31
Azul	2.40	1.92	2.36	2.19	2.22

Tabela 2: Mediana dos valores da camada CSNR para cada banda/índice em cada fitofisionomia (Estacional Semidecidual, Ombrófila Mista e Ombrófila Densa). A última coluna representa a média geral da banda/índice considerando todas as medianas obtidas em todas as fitofisionomias.

Observando os resultados obtidos, entende-se que a escolha do índice ou banda a ser utilizada para a análise dependa muito mais do que se busca detectar do que necessariamente a camada com maior valor obtido pela banda CSNR. Além disso, para áreas de estudo extensas, é possível que não exista coerência entre os resultados para áreas em teoria similares. Essas diferenças acabam reforçando ainda mais a preocupação com o uso de bandas e índices já conhecidos e estudados anteriormente de acordo com cada contexto.

Entende-se também ser possível utilizar índices que obtiveram o melhor resultado para cada caso como o do SWIR no caso de florestas ombrófilas e do TCB para áreas de florestas estacionais semideciduais para estudos que envolvam áreas mais restritas. Outra possibilidade analisada através dos resultados obtidos é a utilização de uma combinação de bandas/índices diferentes para áreas extensas que envolvam uma ou mais fitofisionomias. No entanto, é necessário pensar no custo-benefício dessa escolha, já que a mesma envolveria uma série de testes e processos fragmentados, elevando significativamente o tempo total de execução e viabilidade do estudo.

Neste trabalho, o NDVI foi utilizado para a detecção de mudanças para toda a extensão do bioma. Esta escolha se deu com o objetivo de testar o desempenho final do resultados buscando entender se a escolha de um único índice, principalmente um tradicional com o NDVI, pode gerar resultados satisfatórios para áreas extensas de floresta tropical. A utilização de uma única camada tem ainda como objetivo facilitar o processo de interpretação geral e de contribuir com análises comparativas entre fitofisionomias. A escolha do índice significa apenas uma etapa do processo, sendo necessário pensar a escolha de outros parâmetros.

Tanto os resultados para o cenário de perda quanto de ganho foram gerados com o

objetivo de detectar supressões e processos de degradação, assim como de restauração e regeneração da floresta (Figura 9). Para este estudo, o Landtrendr foi aplicado utilizando todos seus parâmetros padrões. Os tipos de eventos (perda ou ganho) foram organizados de acordo com seu maior evento/segmento (*Greatest Loss / Greatest Gain*).

Posterior aos resultados obtidos pelo algoritmo, toda a etapa de pós-processamento dos dados gerados no GEE foi desenvolvida em ambiente *offline* utilizando ferramentas *open source* como o QGIS [81], GDAL [31], e a linguagem de programação R [82], utilizando os pacotes Raster [45], Terra [46], gdalUtils [37] e MLR [7].

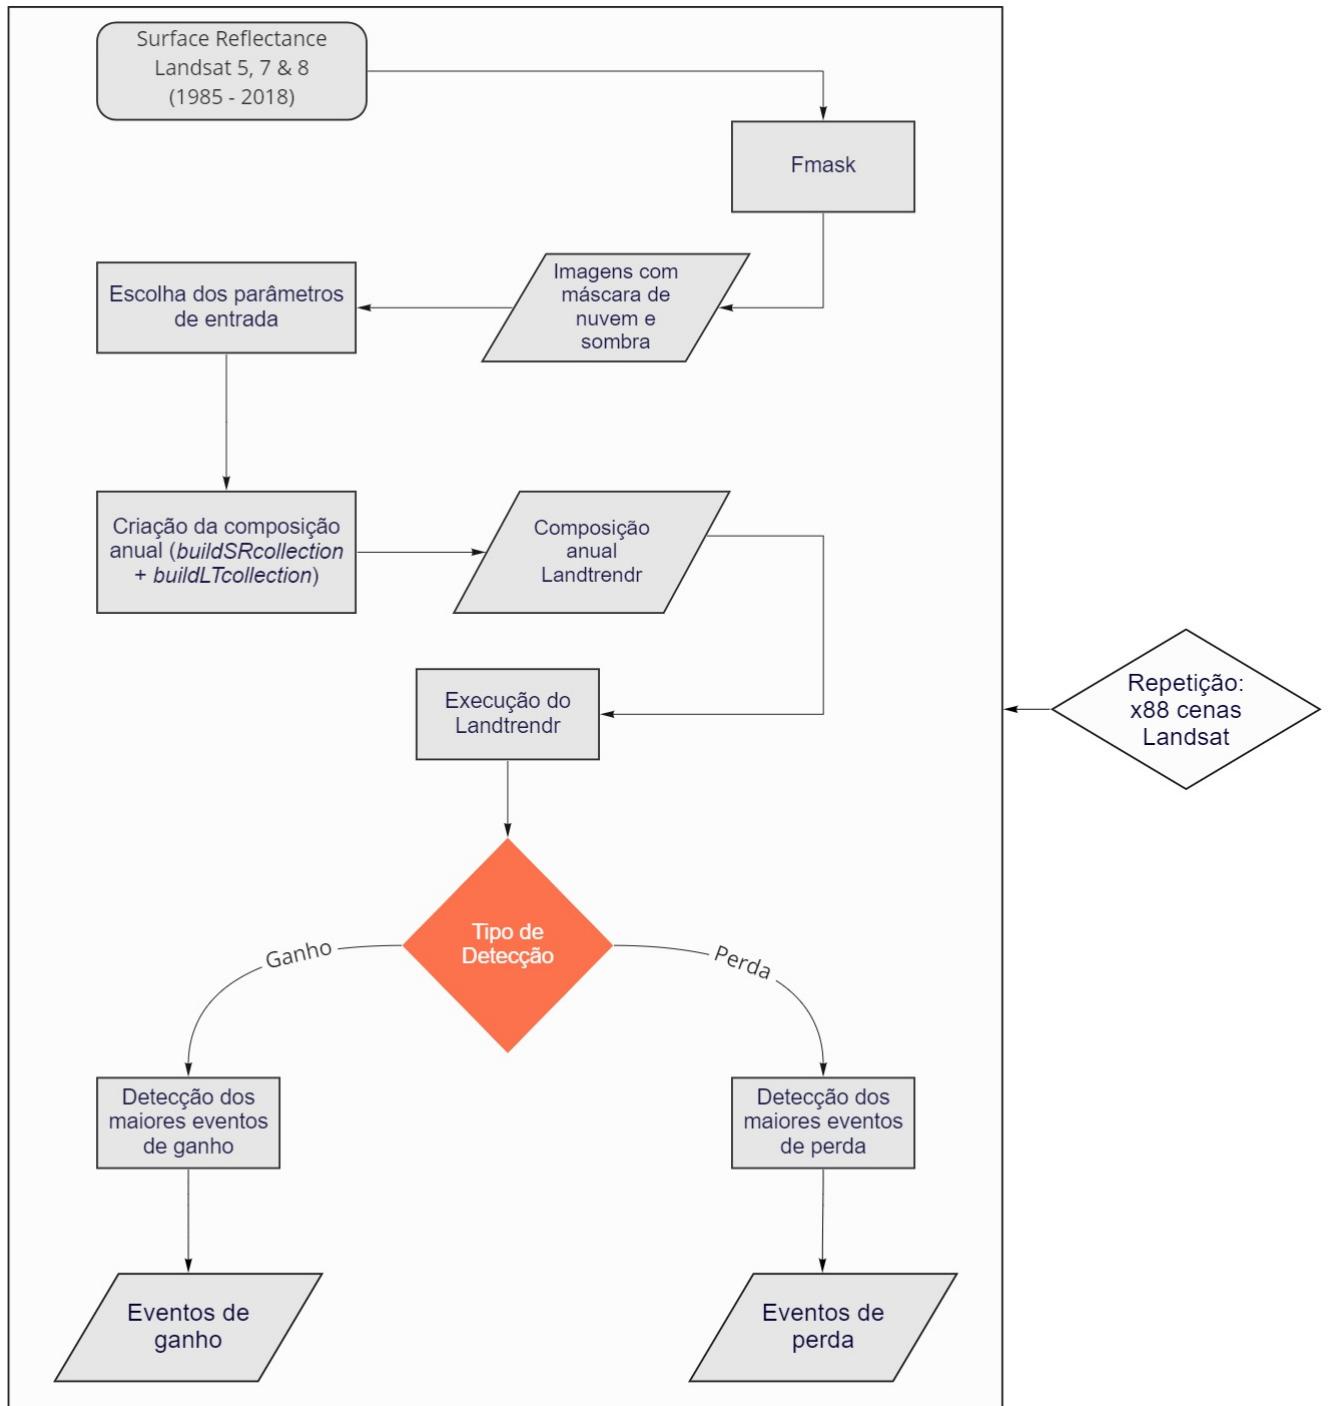


Figura 9: Fluxograma do processo de execução do algoritmo Landtrendr

2.2.5 Processamento dos cenários de ganho

Para o cenário de ganho, a maior parte dos valores para os parâmetros de execução do algoritmo foram mantidos com exceção do *preventOneYearRecovery* que foi modificado para **True** com intuito de evitar falsas detecções devido a ruídos na série e também o

bestModelProportion que foi modificado de 1.25 para 0.75 já que o primeiro valor normalmente produz resultados muito ruins e o último é mais consistente com muitos dos estudos de caso publicados [49, 93, 116, 25, 32, 74, 117, 115, 107, 83, 92] (Tabela 3). Cenários de magnitude (*magnitude*), valor prévio (*previous value*), ano de detecção (*year of detection*), duração (*duration*) e taxa (*rate*) foram gerados e posteriormente pós-processados para limpeza de ruídos e para retirada de valores indesejados.

Input	Type	Earth Engine default	Used
timeSeries	ImageCollection	user-specified	NDVI
maxSegments	Integer	6	6
spikeThreshold	Float	0.9	0.9
vertexCountOvershoot	Integer	3	3
preventOneYearRecovery	Boolean	False	True
recoveryThreshold	Float	0.25	0.25
pvalThreshold	Float	0.05	0.05
bestModelProportion	Float	1.25	0.75
minObservationsNeeded	Integer	6	6

Tabela 3: Valores utilizados para os parâmetros do Landtrendr para executar os cenários de ganho.

Primeiramente, foi gerado uma máscara com todas as áreas pseudo-invariantes entre os anos da análise (1985 - 2018) com o intuito de limpar detecções de mudança muito pequenas. Esta máscara representa todos os pixels que não tiveram nenhum tipo de mudança significativa durante todos os anos da análise, ou seja, áreas que em 1985 já eram consideradas floresta e que se mantiveram praticamente iguais até 2018 (Figura 10).

Inicialmente esta máscara foi desenvolvida utilizando composições anuais de imagens Landsat considerando todos os anos da análise e posteriormente classificadas com o algoritmo Random Forest implementado no pacote MLR [7]. No entanto, apesar de apresentar resultados promissores quando aplicada no mapeamento da área teste na Bacia Hidrográfica do Rio São João, acabou demonstrando problemas quando extrapolada para o resto do bioma e se mostrou uma técnica altamente custosa tanto no tempo de processamento como no tempo de preparação dos dados de entrada [66]. Apesar de não ter sido utilizada como uma máscara neste estudo, a técnica de identificação de áreas pseudo-invariantes utilizando técnicas de aprendizado de máquina pode ser de extrema valia quando aplicada em áreas menores.

Sendo assim, uma abordagem alternativa foi adotada para a criação da máscara para todo o bioma. Camadas de resultado do projeto Mapbiomas v4 foram utilizadas como uma *proxy*. Todas as imagens classificadas para o bioma foram reclassificadas ano a ano em formato binário (floresta [1] e não-floresta [0]) e posteriormente multiplicadas entre si. Um *raster* final binário foi então gerado, onde os pixels com valor 1 representavam áreas que permaneceram como floresta durante todos os anos do estudo e os de valor 0 todos os outros cenários, incluindo além de áreas que presenciaram algum tipo de mudança maior, todas as outras classes mapeadas pelo projeto. Somente pixels da classe floresta (classe número 3) da série 4 foram utilizados. Pixels de classes como floresta plantada foram excluídos assim como todas as outras. Esta máscara evitou que muitos eventos pudessem ser classificados como ganho, apesar de terem baixa magnitude, já que representavam apenas um processo natural nas florestas já existentes. É importante notar que não estamos nos referindo a áreas de regeneração natural, mas de áreas pseudo-

invariantes com variações mínimas durante o período do estudo.

Além disso, foram mascarados todos os eventos com duração menor ou igual a 4 anos, já que não gostaríamos de incorporar eventos ainda muito recentes ou curtos que poderiam ser identificados como falsos eventos de mudança. O valor mínimo de 5 anos para eventos de ganho ajudou a identificar apenas eventos mais longos que tiveram tempo de apresentar respostas espectrais significativas de recuperação. Com 5 anos a vegetação já passa a apresentar um estágio sucessional característico de floresta secundária inicial [16].

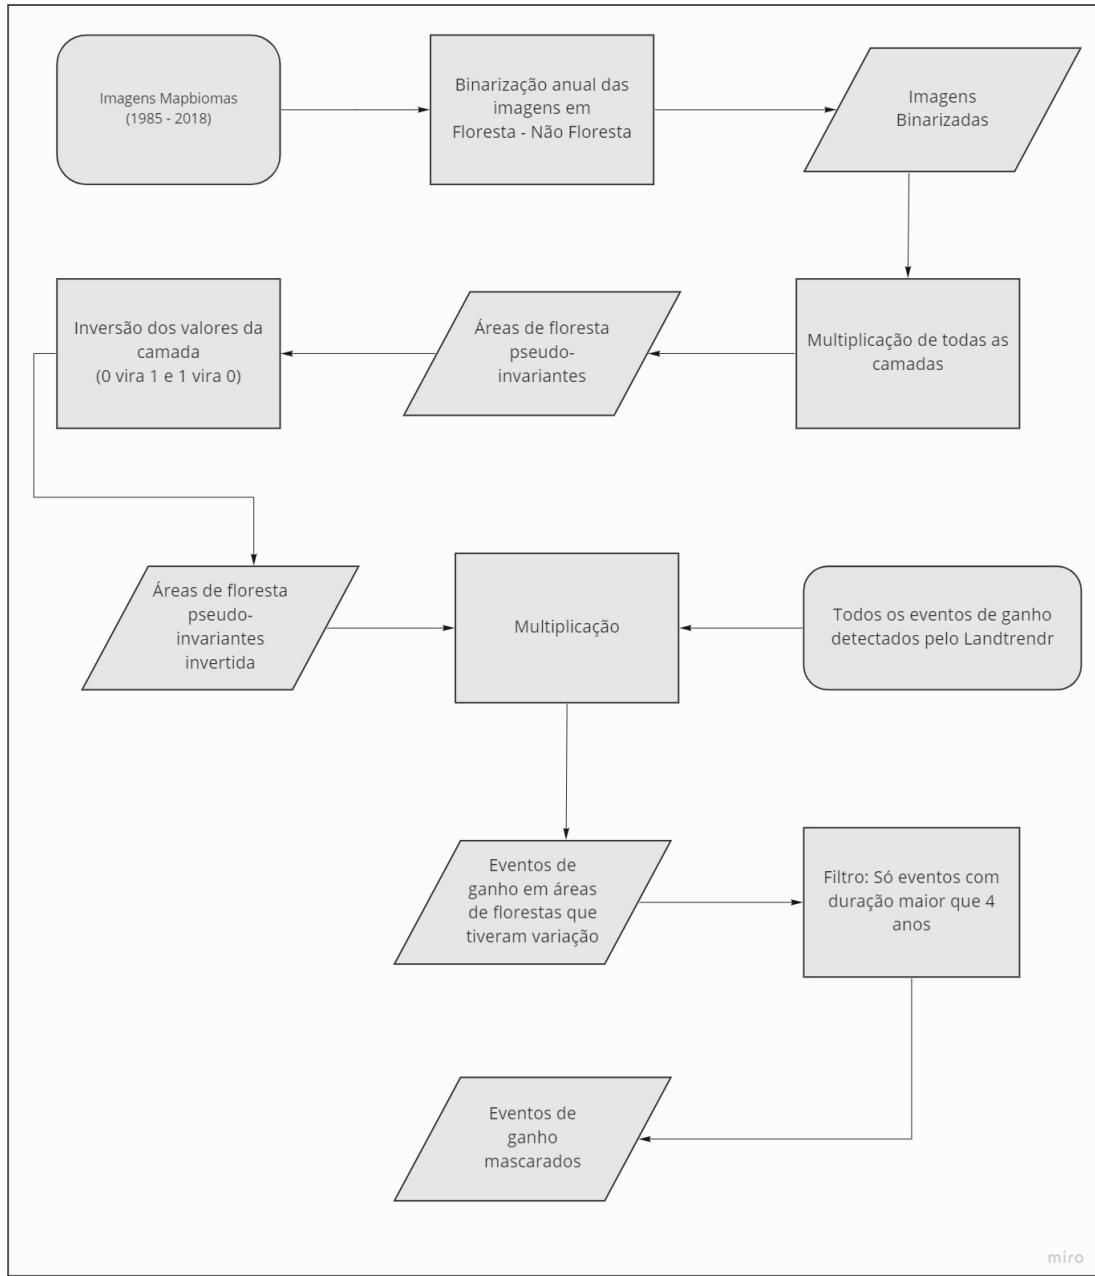


Figura 10: Fluxograma do processo de pós processamento dos dados de ganho

2.2.6 Processamento dos cenários de perda

Assim como o cenário de ganho, o processamento do cenário de perda utilizou a maior parte dos parâmetros padrões do algoritmo sem nenhum tipo de restrição com o objetivo

de realizar limpezas nos resultados obtidos apenas na etapa de pós-processamento. Os mesmos cenários de magnitude (*magnitude*), valor prévio (*previous value*), ano de detecção (*year of detection*), duração (*duration*) e taxa (*rate*) também foram gerados.

No caso das perdas, diferente do cenário de ganho, criou-se uma máscara para garantir que o Landtrendr fosse capaz de detectar mudanças de perda apenas em áreas que foram classificadas como floresta pelo projeto Mapbiomas no ano de 1985. Essa máscara ajudou na não seleção de áreas que nem mesmo tinham sido classificadas como florestas mas que sofreram algum tipo de perda com magnitude grande o suficiente para ser detectada pelo algoritmo. Além disso, uma outra máscara foi gerada para excluir áreas que apesar de terem sido mapeadas em 1985 como floresta e terem sofrido algum tipo de perda significativa, sofreram algum processo de restauração ou regeneração natural ao longo dos anos. Sendo assim, o resultado final para o dado de perdas visou somente a seleção de áreas que tiveram floresta, mas que perderam essa vegetação e não apresentaram nenhum processo de recuperação significativa posterior (Figura 11).

Diferentemente dos dados de ganho, os dados de perda tem como característica importante a grande variabilidade na duração dos eventos. Sendo assim, utilizou-se a camada de duração para gerar, além das camadas de perda gerais, camadas de perda com duração igual a um ano e camadas com duração superior à um ano. Esta diferenciação é importante para que possamos identificar eventos de perda rápida, sejam eles de natureza antrópica ou natural, normalmente associados à cortes rasos ou queimadas.

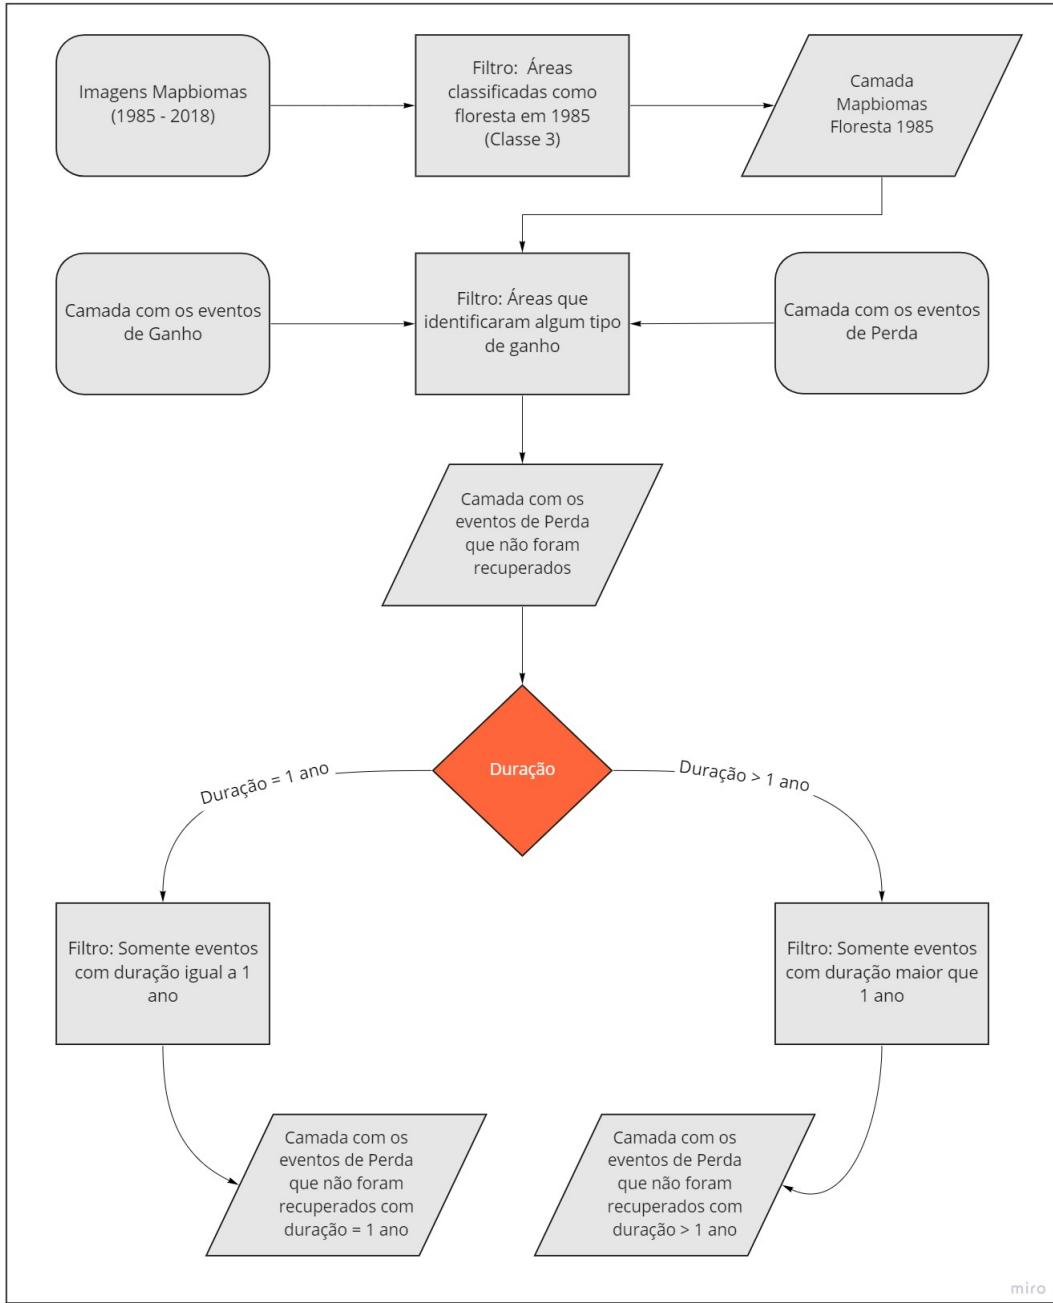


Figura 11: Fluxograma do processo de pós processamento dos dados de perda

2.2.7 Escolha dos limiares para a filtragem dos eventos de mudança

Para além da filtragem das áreas de interesse, é interessante que, em alguns casos, uma segunda etapa de filtragem seja realizada para garantir que mesmo nas áreas de interesse, os pixels detectados como eventos de mudança pelo algoritmo estejam realmente dentro do esperado e façam sentido dentro do contexto da análise.

Para isso, o Landtrendr possui a possibilidade de especificação de parâmetros de filtragem (*Change Mapping Parameters*). Através da especificação desses parâmetros é possível realizar, já na execução do algoritmo, a filtragem dos eventos de acordo com a magnitude, duração e valor prévio (*Pre-Dist Value*) do evento.

É possível, por exemplo, a filtragem de todos os maiores eventos de perda que possuem

duração maior que 4 anos, com magnitude maior que 400 e valor prévio maior que 600. No entanto, ao aplicar o algoritmo no contexto da Mata Atlântica, foi possível observar que a variabilidade de contextos espaciais pode implicar em muitos casos na filtragem de eventos indesejáveis, ou seja, falso-negativos. Apesar da facilidade apresentada pela implementação do algoritmo, fica evidente a necessidade da condução de testes para o maior entendimento da região a ser mapeada antes da aplicação de qualquer filtro deste tipo. A possibilidade de uso de filtros prévios acabam beneficiando apenas situações onde a área a ser mapeada foi previamente estudada ou em situações onde o resultado deve se restringir apenas a algumas características específicas.

Para este estudo, um filtro especificando um limiar para os eventos de perda era necessário. Muitos eventos com pouca magnitude foram detectados, representando áreas que houveram perdas, mas não significativas o suficiente ao longo da série para representar uma real mudança no uso e cobertura do solo.

Sendo assim, testes foram realizados tanto para áreas de florestas ombrófilas densas quanto estacionárias semideciduais, já que era possível que o valor do limiar pudesse ser diferente de acordo com a fitofisionomia estudada. Cem amostras foram coletadas para cada fitofisionomia de floresta como também para áreas de pasto dentro de cada contexto. O valor médio de NDVI encontrado para áreas de floresta estacionária foi de 0.80 e ombrófila de 0.86. Já para áreas de pasto, o valor médio foi de 0.61. Ou seja, uma diferença média de mais de 0.2 ou mais de 200 de magnitude entre áreas de floresta e de pasto. Além disso, a média geral da magnitude dos eventos de perda na Mata Atlântica foi de 225, o que corroborou para o resultado comparativo. Comparando-se as médias das amostras de floresta ombrófila com amostras de pasto, o p-valor obtido foi de 1.599e-11, já para a comparação com as amostras de florestas estacionárias o valor do teste-t foi de 2.495e-7. Ou seja, independente da fitofisionomia, ambas as situações apresentaram diferença estatisticamente significativa em suas médias.

No entanto, este valor de limiar encontrado não foi suficiente para ser utilizado como máscara para as análises de perda devido a um alto desvio padrão encontrado nos valores de magnitude (média de 123). Foi observado que muitas áreas que já apresentavam um certo grau de degradação já possuíam números próximos de áreas de pasto com valor de magnitude próximas de 150. Para não excluirmos estas áreas do resultado, optou-se então por realizar a filtragem utilizando máscaras baseadas em camadas previamente geradas pelo projeto Mapbiomas v4 como descrito anteriormente.

Para áreas de estudos que não possuam mapeamentos de uso e cobertura anuais, a filtragem pela magnitude pode sim ser uma boa prática e forma de limpeza dos resultados finais. Além disso, uma solução híbrida também é possível. Entretanto, para áreas extensas como a Mata Atlântica, a especificação de uma constante de filtragem pode ser arriscada devido a alta variabilidade de contextos ecológicos e de interferência antrópica na região.

2.3 Resultados e Discussões

Os resultados para os cenários de perda e ganho foram aglomerados (*merge*) em imagens únicas abrangendo todo o bioma para cada cenário. Com isso, foi possível compilar os resultados analisando o contexto geral da região e posteriormente transformando os arquivos matriciais em arquivos vetoriais. Essa transformação foi necessária para facilitar a visualização através de mapas de calor (*heatmaps*). Os resultados foram transformados para um sistema de referência de área igual ideal para análises de áreas de grandes ex-

tensões. Neste caso específico foi utilizado a projeção de Albers, mais especificamente a projeção *South America Albers Equal Area Conic* (ESRI: 102003).

2.3.1 Validação

Entender os erros gerados em um processo de detecção para uma área extensa como a Mata Atlântica é complicado e requer certo exercício de individualização de cenários já que estamos tratando de dinâmicas dissemelhantes. Entendendo isso, o processo de validação teve de ser executado de forma individual para cada fitofisionomia estudada. A ideia foi buscar entender o comportamento, as semelhanças e as discrepâncias entre as diferentes fitofisionomias.

O processo de validação de séries temporais possui algumas semelhanças com o processo tradicional, mas também algumas diferenças significativas que acabam impactando de forma direta o planejamento da execução. Assim como na validação de uma única data, é esperado que o especialista faça a interpretação visual das amostras. No entanto, na validação de séries temporais a interpretação necessita de uma série temporal de imagens, que a depender da resolução temporal, impossibilita o uso de imagens de mais alta resolução, como no caso desse estudo. Além disso, é interessante que se possua alguma forma de visualização de toda a série de forma prática, algo não implementado de forma padrão na grande maioria dos SIG disponíveis. O que se tem muitas vezes é apenas uma visualização em forma de gráfico em duas dimensões dos valores da série para cada pixel, sem muita informação sobre o contexto local. Devido a estas necessidades que ferramentas como o TimeSync foram desenvolvidas [21].

O TimeSync possui uma interface gráfica apropriada para a visualização de toda a série tanto em forma de imagens quanto de gráficos (Figura 12 & 13). O TimeSync também utiliza arquivos no formato do Microsoft Access tanto para a configuração do programa quanto para o registro final da validação. O *software* visa a análise de séries anuais, já que foi desenvolvido para ser utilizado como um facilitador do processo de validação dos resultados do Landtrendr. No entanto, pode sim ser utilizado para a validação de resultados de outros algoritmos, desde que sejam derivados de séries anuais.

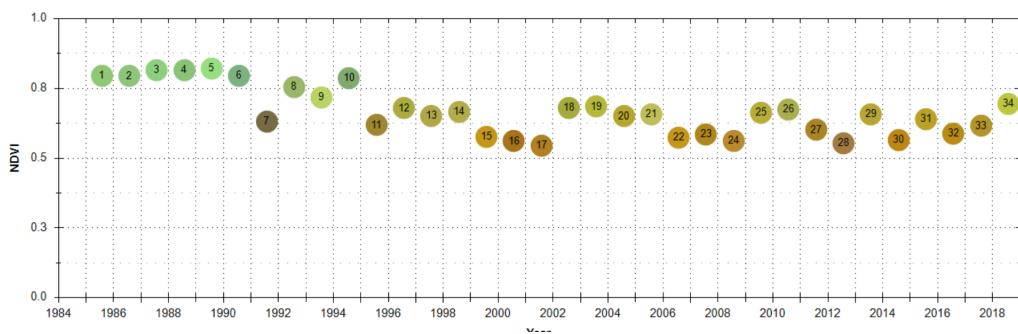


Figura 12: Visualização dos valores de NDVI para cada ano. A cor dos pontos segue a mesma coloração obtida pelo pixel na imagem, o que ajuda na interpretação visual dos eventos. Na imagem, podemos ver um evento de perda.

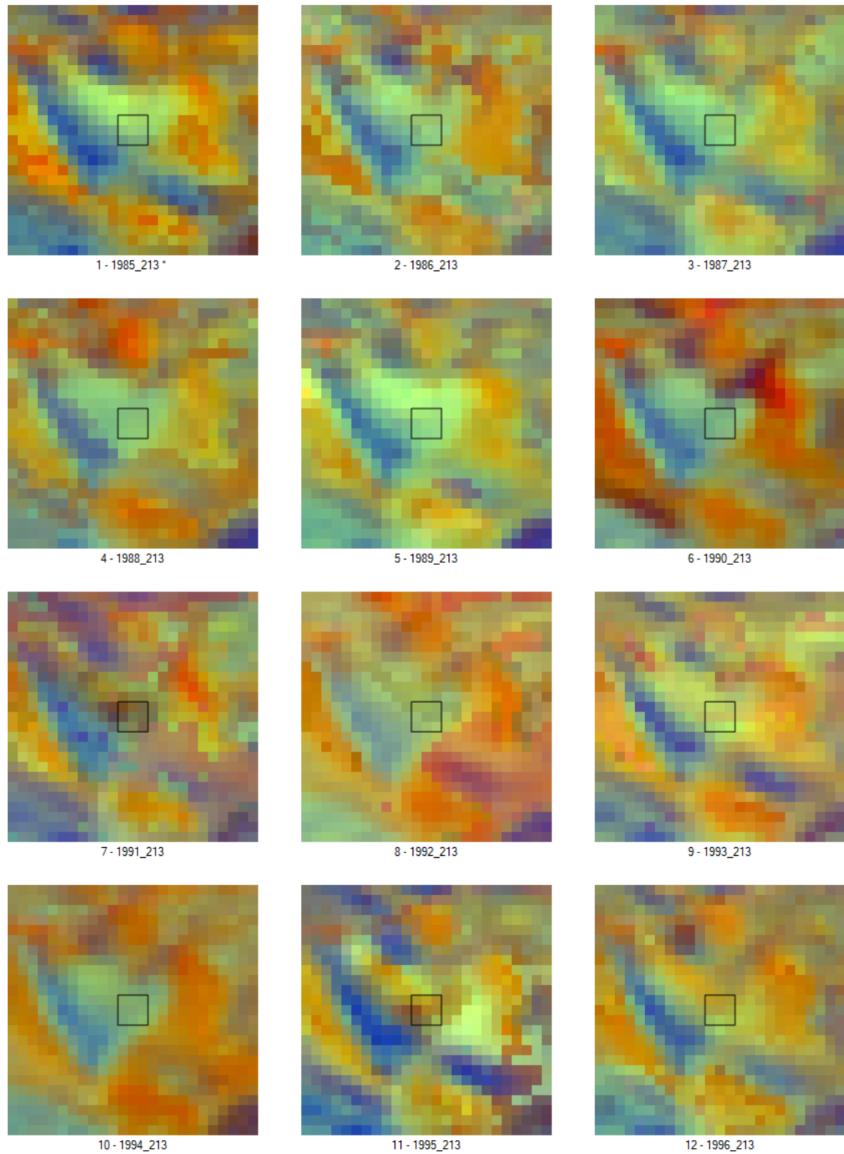


Figura 13: TimeSync Image Viewer. Evento de perda na bacia hidrográfica do rio São João. Cada imagem representa o mesmo pixel/local para cada ano do estudo.

Desde a implementação do Landtrendr no GEE, o TimeSync possui scripts em Python que visam facilitar a exportação de séries temporais do GEE para um ambiente *offline*. Esta etapa é essencial, já que diferente da versão para ENVI/IDL do Landtrendr, no GEE, toda a etapa de preparação dos dados de entrada e de seu processamento são feitos na nuvem de forma quase que automática pelo próprio algoritmo. Como a validação tem de ser feita em ambiente *offline*, é necessário baixar a série inteira ou pedaços da mesma para a realização deste processo.

No caso da validação de uma área extensa como a da Mata Atlântica, apenas pedaços da série foram exportados já que o processo de exportação de toda a área seria muito demorado, custando algumas horas para a exportação de áreas com apenas algumas centenas de km^2 . Devemos considerar também que a exportação de toda a série para uma área extensa em resolução espacial de 30m necessitaria de excessivo espaço para armazenamento, sendo incoerente com a proposta inicial de processamento de grande escala e com baixo custo. Sendo assim, uma área de teste foi escolhida para cada fitofisionomia

estudada.

Para cada área selecionada, pontos aleatórios distribuídos de forma estratificada foram gerados para três classes distintas: Ganhos, Perdas e pseudo-invariância/Outros. A classe de Pseudo-invariância/Outros foi criada para comportar todos os pontos que na verdade não eram de interesse da análise de detecção de mudanças. Sejam por serem áreas que se mantiveram constante ao longo dos anos estudados ou porque foram mascaradas por serem áreas urbanas, áreas naturais não vegetadas ou qualquer outra classe de não interesse. Para cada classe foram gerados 100 pontos, totalizando 300 pontos de validação para cada fitofisionomia, uma soma total de 900 pontos. Além disso, mais 300 pontos (100 por classe) foram validados para a Bacia Hidrográfica do Rio São João com o intuito, assim como no estudo sobre a banda CSNR, verificar possíveis variações no resultado do algoritmo para regiões geograficamente distantes mas fitofisionomicamente similares.

Nas áreas de floresta ombrófila densa, os resultados mostraram uma acurácia de 90% e um kappa de 0.85. Já nas áreas de vegetação ombrófila mista, obtivemos uma acurácia de 88% com um kappa de 0.82. Finalmente, nas áreas de vegetação estacional semideciduado, a acurácia, como esperado, foi um pouco menor ficando em 84% e com kappa 0.76. Apesar da diferença aparente entre regiões ombrófilas e estacionais, todas as regiões obtiveram resultados considerados altos, e portanto, satisfatórios, mostrando que ao utilizar composições anuais essas diferenças causadas pelas dinâmicas estacionais acabem se diluindo. Não foram detectadas diferenças significativas entre os erros de comissão e omissão. As mesmas mantiveram resultados semelhantes em todas as fitofisionomias analisadas. Esta diluição causada pela composição de séries anuais fica ainda mais clara quando os testes para a região adicional da Bacia Hidrográfica do Rio São João foram analisados. Para a bacia, uma região classificada como ombrófila densa, foi obtido uma acurácia de 85% e kappa de 0.77, o que estaria muito mais próximo dos resultados obtidos para a região estacional do que das ombrófilas. Espera-se que os resultados obtidos por fitofisionomia possam contribuir para o entendimento da característica mais homogênea dos estudos que tem como dado de entrada composições derivadas de uma coleção densa de imagens. Além disso, uma validação considerando todas as regiões estudadas foi feita, obtendo um valor de acurácia global de 86.7% e kappa de 0.8.

Estes resultados demonstraram um excelente resultado obtido pelo algoritmo e confirmam seu potencial para aplicação em áreas tropicais extensas.

2.3.2 Plataforma para visualização dos resultados

Uma das dificuldades encontradas na análise de áreas extensas como a Mata Atlântica está na representação dos resultados, principalmente em escalas derivadas de resoluções espaciais médias como no caso das imagens Landsat. A criação de mapas de calor e criação de estatísticas zonais acabam servindo para uma análise mais geral das regiões e até mesmo em nível de município, mas limita uma análise mais pontual, local.

A plataforma do Google Earth Engine (GEE) disponibiliza a possibilidade de criação de uma interface gráfica através da própria API, possibilitando a publicação de resultados obtidos na plataforma ou de dados externos importados para seu ambiente através da criação de um *website*. Esta funcionalidade possibilita a divulgação interativa de forma prática e rápida de grande quantidade de dados. Sem esta infraestrutura, o compartilhamento dos dados resultantes de análises na plataforma teriam de ser feito de forma tradicional, através do *download* dos dados da plataforma e posterior *upload* em serviços de hospedagem na nuvem. Para dados como os resultados obtidos nesta análise esta

opção se mostrou essencial, já que os arquivos resultantes são grandes e demandam poder computacional significativo para uma visualização sem engasgos.

A criação de uma aplicação web utilizando o GEE pode ser feita de forma relativamente simples através da própria interface gráfica. O desenvolvimento da interface gráfica deve ser realizada utilizando a API JavaScript, que possui documentação extensa no próprio *website* oficial. Os dados que serão visualizados devem estar conectados a sua conta do GEE e compartilhados de forma aberta. Após o link dos dados com a interface, é possível fazer a publicação através do botão "App". A plataforma leva alguns minutos para subir a aplicação final e gerar um link compartilhável Figura (14).

Neste caso, o código para a aplicação ainda foi registrado na plataforma Zenodo com o objetivo de gerar um DOI (10.5281/zenodo.6481487). O código fonte para a aplicação pode ser acessado aqui: https://github.com/sacridini/ui_gee_ltr_mata_atlantica. A visualização das principais camadas geradas neste trabalho (perda, perda rápida, perda longa e ganho) podem ser acessadas através deste link: <https://elacerda.users.earthengine.app/view/atlantic-forest-landtrendr>.

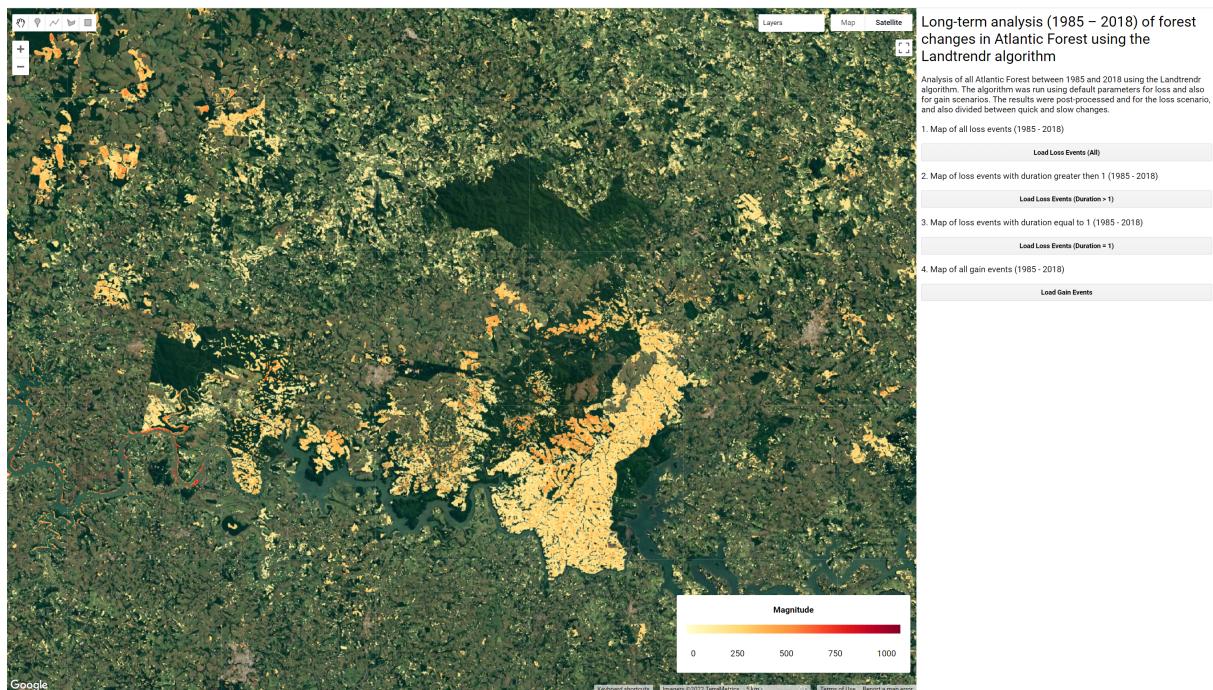


Figura 14: Página principal da aplicação web para visualização dos resultados de mudança na Mata Atlântica

2.3.3 Resultados para os eventos de perda na Mata Atlântica

Somando-se todos os eventos de perda detectados pelo algoritmo após as filtragens das áreas de interesse, houveram ao longo de todos os anos da análise 61.167.796 de pixels com uma perda média de 225 ou diminuição de 0.225 no índice NDVI. Isso equivale a uma área total de pouco mais de 55 mil km^2 de florestas que sofreram perdas significativas no bioma e que não foram recuperadas após a supressão.

O resultado mais abrangente envolvendo todos os eventos de perda do bioma pode ser visualizado na (Figura 17). A maior aglomeração de eventos de perda está localizada principalmente entre os estados do Paraná e Santa Catarina e no estado da Bahia. Nos outros estados o mapa de calor mostra uma distribuição mais homogênea dos eventos ao

longo do território.

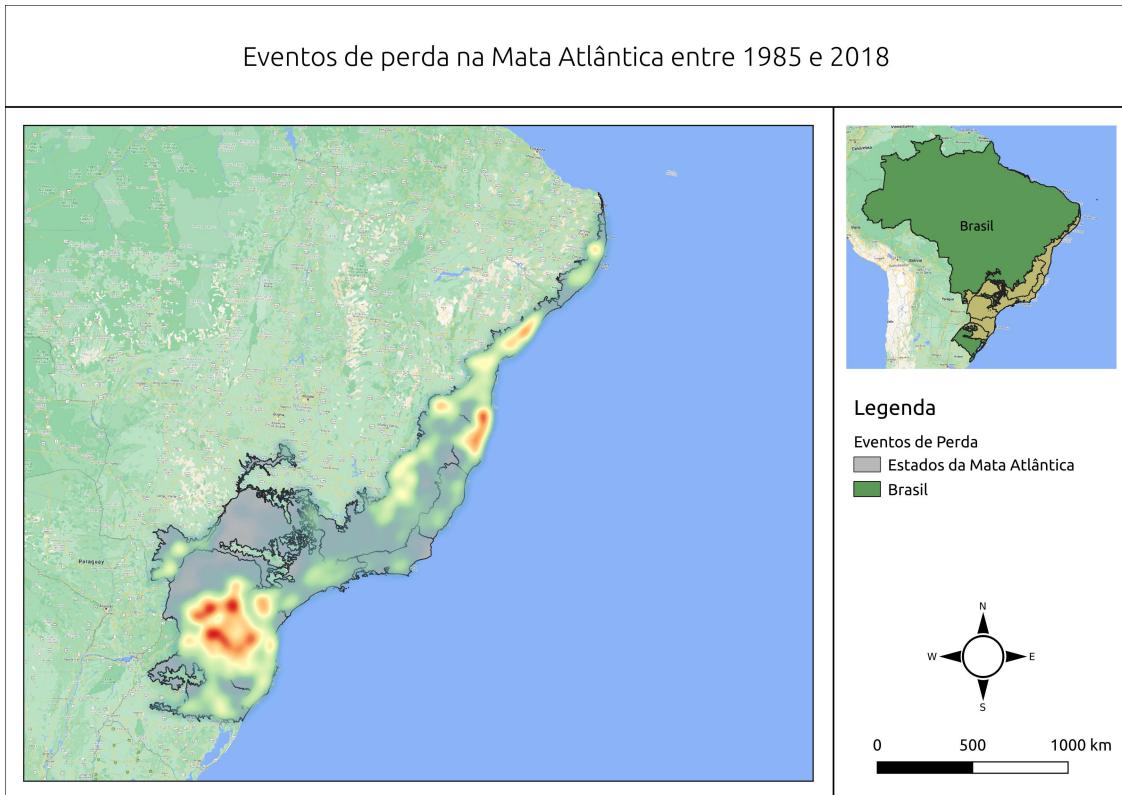


Figura 15: Todos os eventos de perda na Mata Atlântica entre 1985 e 2018.

2.3.4 Os eventos de ganho na Mata Atlântica

Somando-se todos os eventos de ganho detectados pelo algoritmo e após as filtragens necessárias, houveram ao longo de todos os anos da análise 68.869.908 de pixels com um ganho médio de 197 ou aumento de 0.197 no índice NDVI. Isso equivale a uma área total de aproximadamente 62 mil km^2 de florestas que sofreram ganhos significativos. Como discutido na sessão 3.2.4, áreas de florestas pseudo-invariantes não foram consideradas, sendo assim, esta área representa um ganho real de área verde dentro do bioma.

Na Figura 29, podemos observar que o ganho de áreas no bioma de deu de forma bem mais homogênea que as áreas de perda. Apenas algumas áreas de aglomeração podem ser visualizados como no sul do Rio Grande do Sul, Espírito Santo, sul de Pernambuco, São Paulo e Minas Gerais.

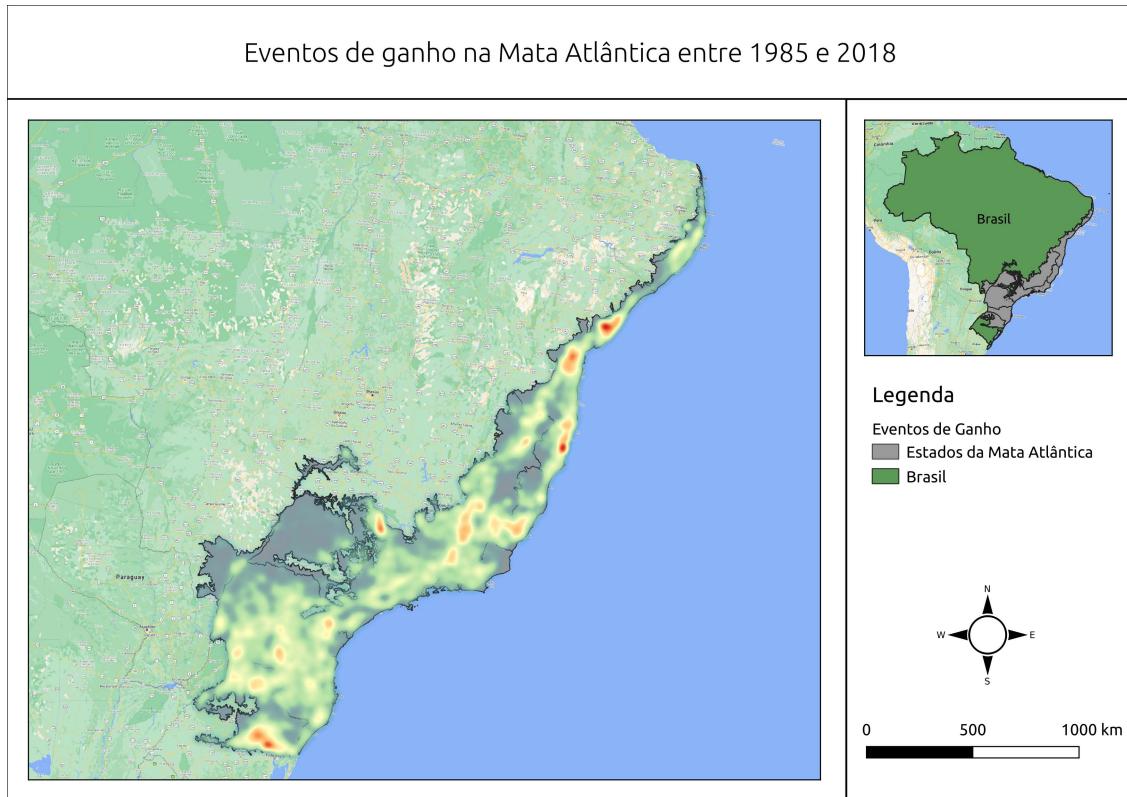


Figura 16: Eventos de ganho entre 1985 e 2018.

2.4 Conclusão

Podemos observar através deste estudo que o algoritmo Landtrendr apresentou resultado bastante satisfatório quando aplicado à áreas extensas de floresta tropical. Diferente de estudos realizados anteriormente, foi possível observar o comportamento do algoritmo quando aplicado a diferentes fitofisionomias. Os resultados apresentados são coerentes com os apresentados por programas de mapeamento sistemáticos com o Mapbiomas, mas contribuiu para uma melhor qualificação das mudanças ocorridas no bioma ao longo dos 33 anos da análise.

Este estudo contribui ainda para o desenvolvimento do conhecimento sobre a aplicação de técnicas de detecção de mudança baseado em trajetórias em um contexto ecológico complexo e fragmentado como o da Mata Atlântica em meso-escala. A incorporação de ferramentas de processamento de dados espaciais em infraestruturas computacionais interconectadas demonstra através de trabalhos como este, mais uma vez, sua potencialidade. Não só na clara capacidade extraordinária de processamento como na qualidade das ferramentas disponíveis para análise dos dados. Observando os resultados obtidos, acreditamos que a implementação do Landtrendr para a plataforma Google Earth Engine poderá contribuir para futuras análises, sejam elas locais ou para áreas extensas, utilizando assim todo o potencial de processamento disponível.

Análise de longo prazo (1985 – 2018) das mudanças florestais na Mata Atlântica utilizando o algoritmo Landtrendr

3 Análise de longo prazo (1985 – 2018) das mudanças florestais na Mata Atlântica utilizando o algoritmo Landtrendr

3.1 Introdução

Estamos na década da restauração (2020 - 2030), e o desafio para alcançar as metas são enormes. A Mata Atlântica, como uma das regiões mais biodiversas do mundo [84], tem papel importante nesse desafio. Movimentos como a criação do Pacto pela Mata Atlântica em 2009 visando a restauração de 15 Mha de áreas degradadas até 2050, servem para mostrar a importância que o bioma tem para a conservação da parte considerável da biodiversidade mundial com suas quase 16 mil espécies de plantas e mais de 2 mil espécies de vertebrados [90].

O bioma está entre as áreas com maior biodiversidade do mundo ao mesmo tempo que também é considerada uma das mais ameaçadas e historicamente degradadas. A restauração dessas áreas está diretamente associada a forma com que os atores associados irão lidar com dificuldades como o custo de implementação da restauração, interesses econômicos locais, falta de investimento, assistência técnica limitada e baixo nível de governança em algumas regiões [96, 22, 17, 97].

Como os compromissos nacionais e internacionais possuem metas para conservação e restauração, o entendimento sobre a dinâmica do uso e cobertura do solo nessas regiões passou a ser ainda mais importante. O desenvolvimento de técnicas que ajudam a entender os processos através da incorporação do tempo nas análises são essenciais para o acompanhamento dos projetos, assim como para o próprio estabelecimento das metas. Entender o quanto se deve restaurar tem ligação direta com o que foi perdido em ações antrópicas recentes. Quantificar as mudanças para estabelecer metas e qualificar as perdas para justificar os compromissos. Entender os processos para compreender os fluxos e o sentido das dinâmicas no espaço. Estas são tendências na área de geotecnologia e a consequência vem sendo o desenvolvimento de ferramentas e soluções geoespaciais que visam possibilitar a análise e até mesmo o monitoramento do espaço no tempo.

A Mata Atlântica, assim como a Amazônia, é um dos biomas mais estudados no território nacional. Devido ao contexto histórico do processo de colonização brasileiro, o bioma foi o primeiro a ser ocupado e hoje possui 70% da população do país, além de possuir apenas cerca de 27% de sua área preservada [15], quase sempre de forma bastante fragmentada. Mapeamentos de alta precisão [15], assim como projetos de mapeamento sistemático [95], vem sendo condizidos no bioma, mas a qualificação dos eventos tradicionalmente só é feita após os resultados serem obtidos. Consequentemente, esta qualificação do resultado acaba sendo feita de forma limitada de acordo com o dado gerado. Se o dado final apresenta apenas os eventos de mudança e a data da detecção, não há muito mais o que extrair do que apenas a quantificação das áreas, a data da mudança e o sentido restrito das tendências de mudança.

A identificação das mudanças através da comparação binária entre datas não consegue compreender a complexidade de processos principalmente em regiões mais dinâmicas como a Mata Atlântica. Para além da identificação da mudança em si, é cada vez mais necessário identificar a magnitude dos eventos, sua duração, sua amplitude e até mesmo a quantificação de diversos eventos de mudança em uma mesma região como viabilizador para análises de resiliência [56]. Visando possibilitar estas análises, ferramentas especiali-

zadas vem sendo desenvolvidos na última década. Exemplos como o CCDC [123], COLD [19], VCT [51, 99] , VerDET [52], EWMACD [13], MIICA [57], ITRA [108], Shapes-NBR [71, 72] e o Landtrendr [60, 61] podem ser citados. Dentre eles, o possivelmente mais popular, principalmente desde sua implementação na plataforma Google Earth Engine (GEE) [62], é o Landtrendr.

No entanto, apesar de sua implementação inicial ter surgido a mais de uma década [60], a análise de áreas de grande extensão com a da Mata Atlântica, eram inviáveis, vide a capacidade computacional necessária tanto para o processamento dos dados de entrada quanto para a execução do próprio algoritmo. O surgimento de uma plataforma como o Google Earth Engine [35] possibilitou a escalabilidade necessária. Algoritmos como o Landtrendr deixaram de lado a comparação direta entre classes e focaram na execução de modelos de regressão possibilitando uma análise temporal, como uma busca para uma melhor qualificação dos resultados, para que cada pixel possa contar uma história um pouco mais completa desse espaço.

Devido a possibilidade de uso de ferramentas como as citadas, e visando uma melhor qualificação dos eventos de mudança em áreas que tiveram ou ainda possuem área de floresta, o presente trabalho teve como objetivo o uso do algoritmo Landtrendr na plataforma GEE para o mapeamento de todos os eventos de perda e de ganho de floresta em toda a região da Mata Atlântica em território nacional. Para além do próprio mapeamento, o trabalho teve como objetivo a quantificação e qualificação das dinâmicas ocorridas na região de 1985 até 2018 buscando entender as dinâmicas espaciais no âmbito do bioma e também de acordo com as divisões políticas. As divisões espaciais da análise visam contribuir não só com o conhecimento sobre os eventos ocorridos nos últimos 33 anos em todo bioma quanto para tomadas de decisão políticas em âmbito estadual e até mesmo municipal.

3.2 Materiais e Métodos

3.2.1 Dados de entrada

Para este estudo foram utilizadas imagens do satélite Landsat da série 5, 7 e 8 com valores de reflectância da superfície de 1985 até 2018. Para cobrir toda a área do bioma da Mata Atlântica foram necessárias 88 cenas (path/row) diferentes, cada cena contendo 23 imagens por ano, por 33 anos, o que resultou em um total de aproximadamente 67 mil imagens. Todas as imagens utilizaram o algoritmo Fmask para retirar sombras e locais com presença de nuvem antes da construção das composições anuais.

O Landtrendr trabalha analisando uma banda ou índice por vez, sendo assim, para este trabalho, o índice NDVI foi escolhido e consequentemente extraído das composições anuais. As 88 cenas, cada uma com 33 índices NDVI, representando cada um dos anos da análise, foram utilizados como dado de entrada para o algoritmo.

3.2.2 Processamento dos dados

Todo o processamento do Landtrendr foi feito na plataforma do Google Earth Engine e exportado para um ambiente *offline* para a etapa de pós-processamento, análise e validação. Toda o pós-processamento e análise foi feito utilizando a linguagem de programação R e a etapa de validação no software TimeSync [21].

O processamento foi dividido com o objetivo de gerar resultados tanto para perda quanto para o ganho de áreas de floresta no bioma. Foram analisadas apenas áreas com

vegetação de floresta. Para as análise de perda foram analisadas áreas que possuíam floresta em 1985 de acordo com o projeto Mapbiomas [95] v4 e que não apresentaram recuperação da vegetação de acordo tanto com o Mapbiomas como quanto pelo próprio resultado da análise de ganho do Landtrendr. Já para a análise de ganho, foram retiradas primeiramente todas as áreas de floresta consideradas pseudo-invariantes, ou seja, áreas que foram classificadas como floresta pelo projeto Mapbiomas em todos os anos de 1985 até 2018 com o objetivo de excluir detecção de mudanças relacionadas a regeneração natural de florestas mais antigas que o tempo de análise do trabalho. Para o ganho, também foram retirados todos os pixels detectados pelo Landtrendr que tinham uma duração menor do que 4 anos, com o objetivo de mostrar áreas que tiveram um tempo mínimo de recuperação para serem consideradas florestas secundárias iniciais de acordo com a bibliografia especializada [16].

3.3 Resultados e Discussões

Os resultados obtidos mostram uma Mata Atlântica com concentrações de perda na parte sul e nordeste do país, e com ganhos locais distribuídos por todo o bioma. A Mata Atlântica que foi desmatada e fragmentada ao longo dos séculos se vê hoje ganhando mais do que perdendo em área total, mas as perdas e os ganhos não podem ser tratados de forma igualitária. A perda interfere mais na manutenção do bioma por degradar majoritariamente áreas antigas e bem estruturadas, enquanto os ganhos, por serem eventos ainda recentes, são frágeis e não possuem a mesma resiliência. Os resultados obtidos corroboram com outros estudos recentes como em [85, 22, 84].

3.3.1 Resultados para os eventos de perda na Mata Atlântica

Somando-se todos os eventos de perda detectados pelo algoritmo após as filtragens das áreas de interesse, houveram ao longo de todos os anos da análise 61.167.796 de pixels com uma perda média de magnitude de 225 ou diminuição de 0.225 no índice NDVI. Isso equivale a uma área total de pouco mais de 55 mil km^2 de florestas que sofreram perdas significativas no bioma e que não foram recuperadas após a supressão.

O resultado mais abrangente envolvendo todos os eventos de perda do bioma pode ser visualizado na (Figura 17). A maior aglomeração de eventos de perda está localizada principalmente entre os estados do Paraná e Santa Catarina e no estado da Bahia. Nos outros estados o mapa de calor mostra uma distribuição mais homogênea dos eventos ao longo do território.

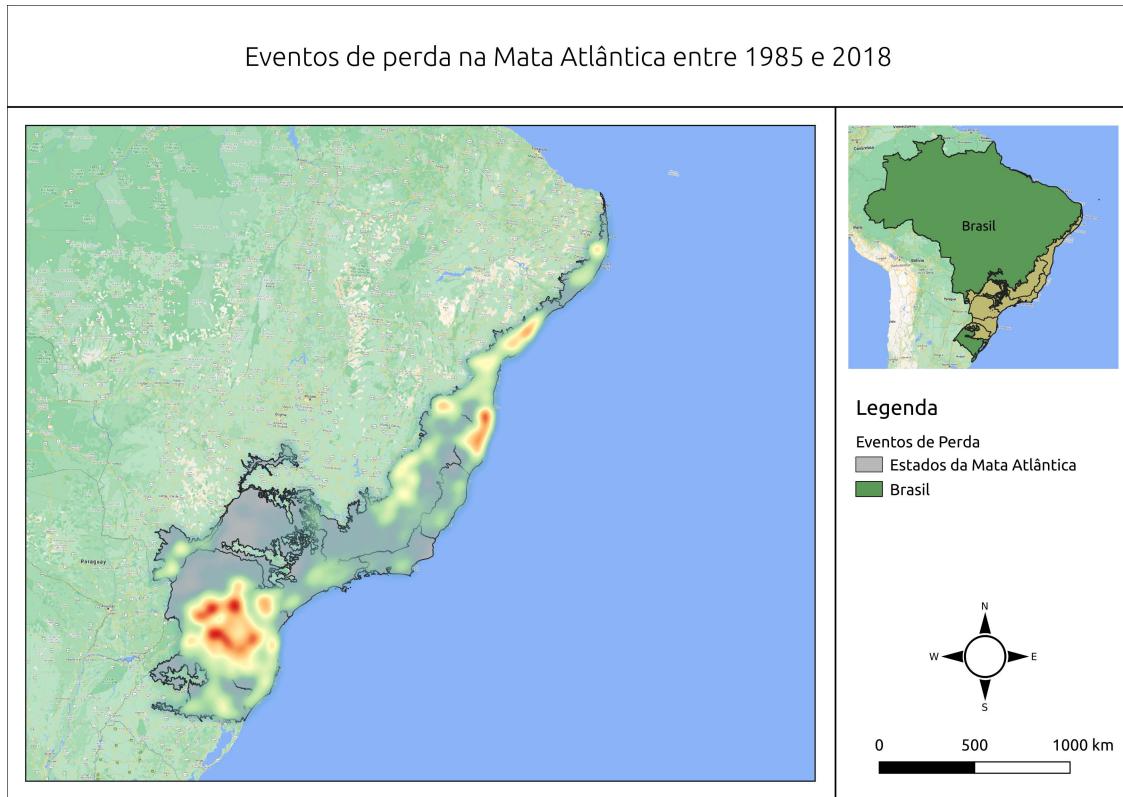


Figura 17: Todos os eventos de perda na Mata Atlântica entre 1985 e 2018.

Quando a divisão das detecções é feita de acordo com eventos de curta duração (um ano) e longos (maiores que um ano), verificamos que o padrão espacial das aglomerações (*clusters*) se mantém semelhante com apenas algumas variações (Figura 18). Os eventos de curta duração tendem a se localizar mais na fronteira entre Paraná e Santa Catarina, enquanto os de longa aconteceram com maior frequência na região central do Paraná, sul/norte da Bahia e norte de Pernambuco. Dos mais de 61 milhões de eventos detectados ou 55 mil km^2 , cerca de 27.5 milhões foram eventos de curta duração, o que significa uma área aproximada de 25 mil km^2 . Os outros 33.7 milhões de eventos tiveram duração maior que um ano, o que totalizou aproximadamente 30.4 mil km^2 .

Já quando a divisão é feita por estados (Figura 19), verificamos que estados como Minas Gerais possuem um número grande de eventos que estão distribuídos de forma homogênea pelo território, assim como Bahia e São Paulo. Vemos que apesar do maior *cluster* de perdas estar localizado entre Paraná e Santa Catarina, a maior quantidade de eventos está no estado do Paraná.

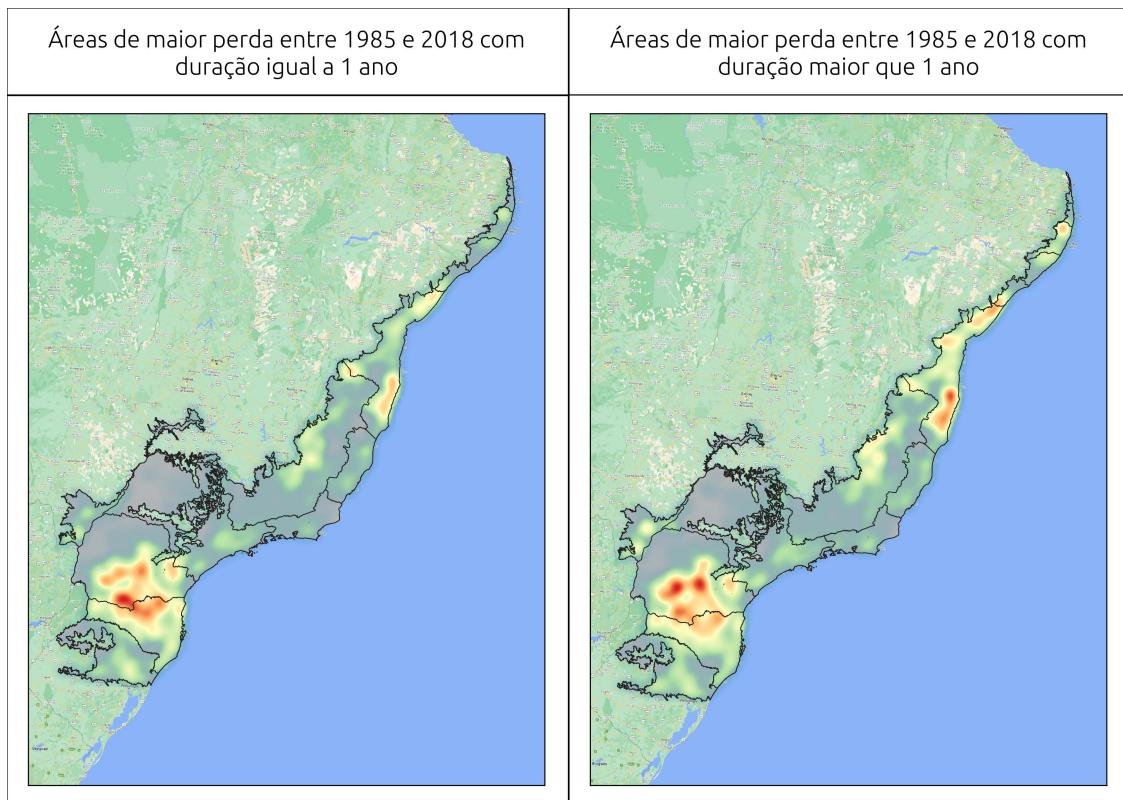


Figura 18: Mapa com os eventos de perda entre 1985 e 2018 tanto com duração igual a 1 quanto somente maiores que 1.

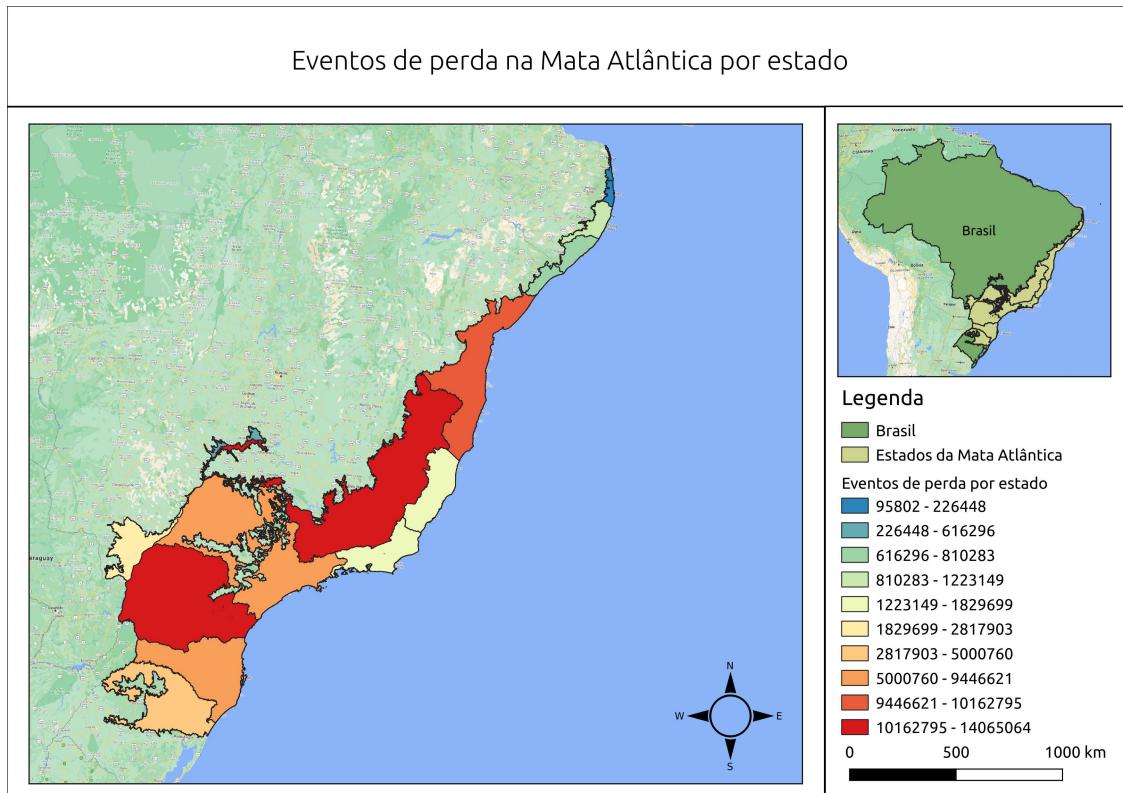


Figura 19: Todos os eventos de perda na Mata Atlântica entre 1985 e 2018 por estado. Os valores representam o número de pixels que tiveram alguma detecção de perda.

Ao considerar o número de eventos de acordo com a área de cada estado, verificamos que estados como Santa Catarina e Bahia se destacam mostrando o maior proporção de perdas ao longo dos 33 anos seguido de Pernambuco, Paraná e Sergipe (Figura 20). Já ao calcular a área perdida de acordo com a proporção de floresta presente em cada município em 1985, podemos perceber que grande parte do litoral nas regiões sul e sudeste mantiveram baixa proporção de perda com aumento significativo ao longo de parte majoritária do litoral nordestino (Figura 21). *Hotspots* com maior proporção podem ser identificados em todos os estados do nordeste, além de Paraná, Santa Catarina e Mato Grosso. Para este cálculo foram utilizados a quantidade total de pixels classificados como floresta pelo projeto Mapbiomas para o ano de 1985, assim como os pixels com os eventos de perda detectados durante todos os anos da análise. Uma proporção de 0,1 equivale a 10% de perda da área total de florestas no município em 1985.

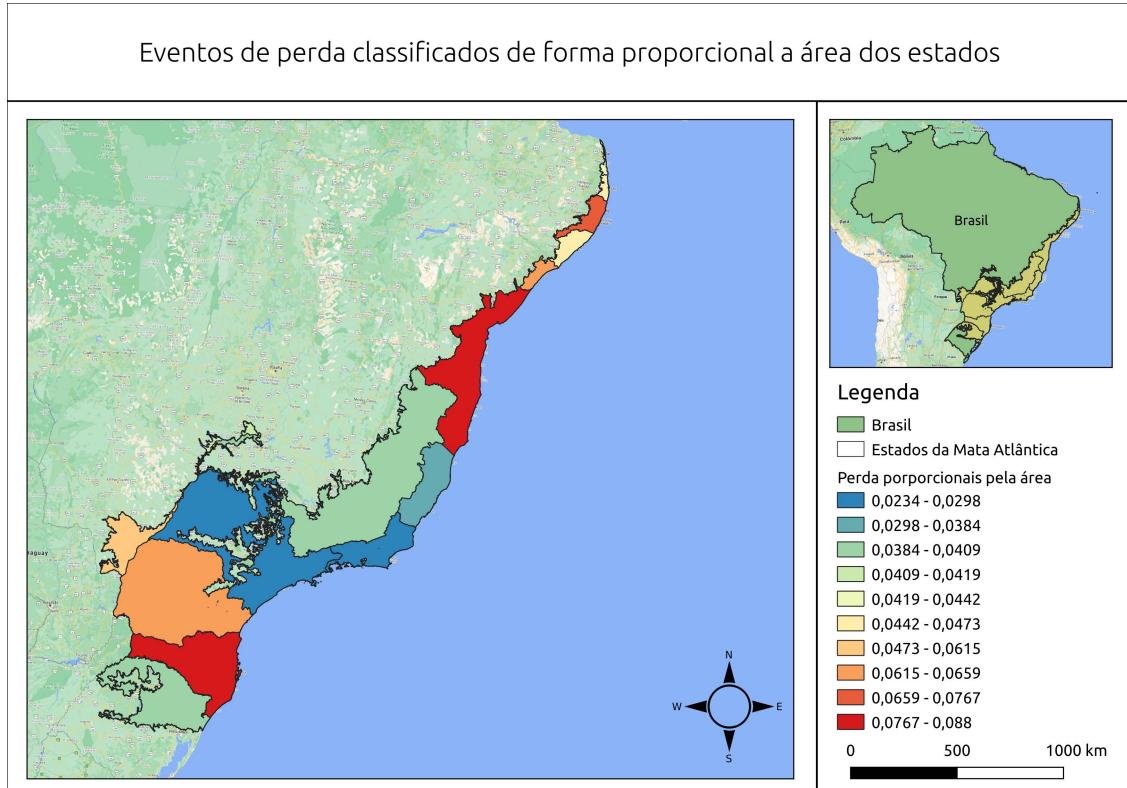


Figura 20: Mapa com os eventos de perda entre 1985 e 2018 classificado de acordo com a proporção de área de cada estado.

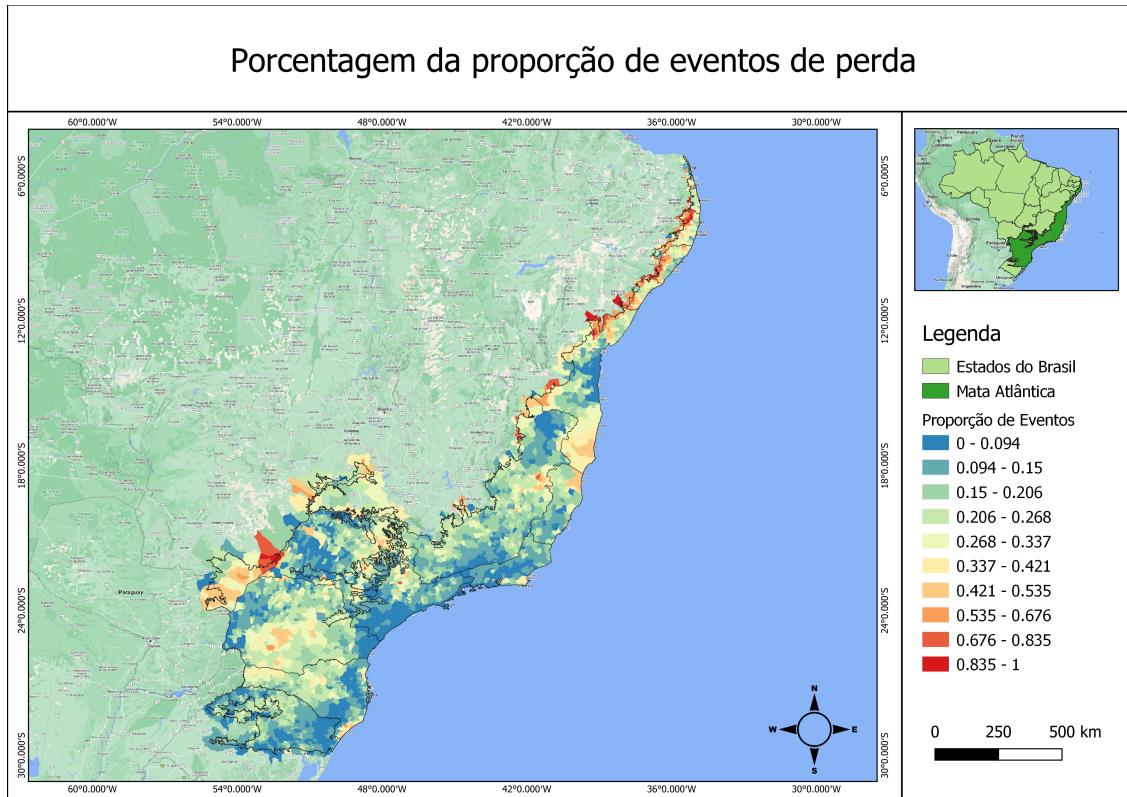


Figura 21: Mapa com a proporção dos eventos de perda entre 1985 e 2018 classificado de acordo com a área total de floresta em 1985.

Já quando analisamos a proporção de área perdida dentro das unidades de conservação (UC) presente no bioma, percebemos que muitos eventos foram detectados durante a década de 1990. A tabela 4 mostra as dez unidades com maior quantidade de perda no bioma, a proporção de área de floresta perdida entre 1985 e 2018 em relação a área total da UC, o ano de criação da unidade e a média do YOD (*Year of Detection*), ou seja, a média do ano de detecção dos eventos de maior perda detectado dentro das UCs. Esta coluna serve como parâmetro para entender se, em média, os eventos de mudança foram detectados antes ou depois da criação da UC. A UC com maior proporção de área perdida foi o Parque Nacional do Alto Cariri no estado da Bahia, que teve a maior parte dos seus eventos de perda detectados antes de sua criação em 2010.

Unidade de Conservação	UF	% área perdida	Ano Criação	Média YOD
PARNA do Alto Cariri	BA	0.14	2010	1994
PARNA do Monte Pascoal	BA	0.13	1961	1996
FLONA de Passo Fundo	RS	0.13	1968	1992
ARIE Serra da Abelha	SC	0.10	1990	1997
RESEX do Mandira	SP	0.09	2002	1992
ESEC de Murici	AL	0.09	2001	1991
FLONA de Canela	RS	0.09	1968	1996
FLONA de São Francisco de Paula	RS	0.08	1968	1994
FLONA de Assungui	PR	0.07	1968	2004
FLONA de Caçador	SC	0.07	1968	1995

Tabela 4: As dez unidades de conservação com maior proporção de área perdida.

Como visto previamente no mapa de *clusters*, os eventos de perda de curta duração tendem a se concentrar principalmente no Paraná e Santa Catarina quando analisados sob divisões políticas (Figura 22). Já os de longa duração, se concentram em estados como o Paraná e Bahia, seguido de Minas Gerais, Santa Catarina e São Paulo (Figura 23).

Quando realizamos a divisão por municípios (Figura 24), o padrão espacial similar ao mapa de calor da Figura 17, mas demonstra como eventos que anteriormente estavam aparentemente distribuídos de forma mais homogênea, se agrupam quando classificados por município. As aglomerações ainda permanecem ocorrendo principalmente em estados como Paraná, Santa Catarina e Bahia, mas podemos observar municípios em outros estados que concentraram um maior número de perda como em Iguatemi no Mato Grosso do Sul ou em Águas Vermelhas em Minas Gerais. A lista completa com todos os 3078 municípios pertencentes ao bioma pode ser acessado neste link https://github.com/sacridini/municipios_perdas_ganhos.

Nome	Eventos	UF
Porto Seguro	444892	BA
Prudentópolis	425340	PR
Ortigueira	373635	PR
Coronel Domingos Soares	367051	PR
Belmonte	333728	BA
Itamaraju	329167	BA
Guarapuava	314087	PR
Santa Cruz Cabrália	296493	BA
Prado	283573	BA
Canavieiras	279240	BA
Rio Bonito do Iguaçu	271232	PR
Pinhão	270471	PR
Encruzilhada	264281	BA
Reserva	263798	PR
Bituruna	262246	PR
Tibagi	253448	PR
Mafra	251392	SC
Santa Cecília	246603	SC
Itaiópolis	246205	SC
Guaratinga	241392	BA

Tabela 5: Os vinte municípios com maior número de eventos de perda

Eventos de perda rápida na Mata Atlântica por estado

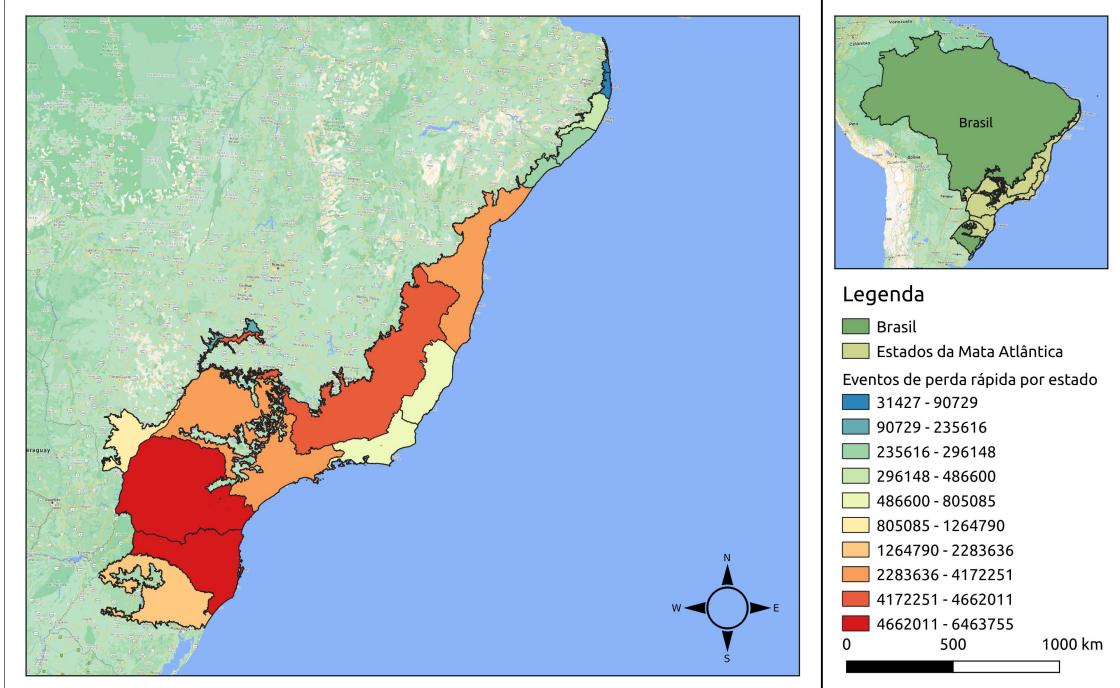


Figura 22: Todos os eventos de perda rápida (duração igual a 1) na Mata Atlântica entre 1985 e 2018 por estado. Os valores representam o número de pixels que tiveram alguma detecção de perda.

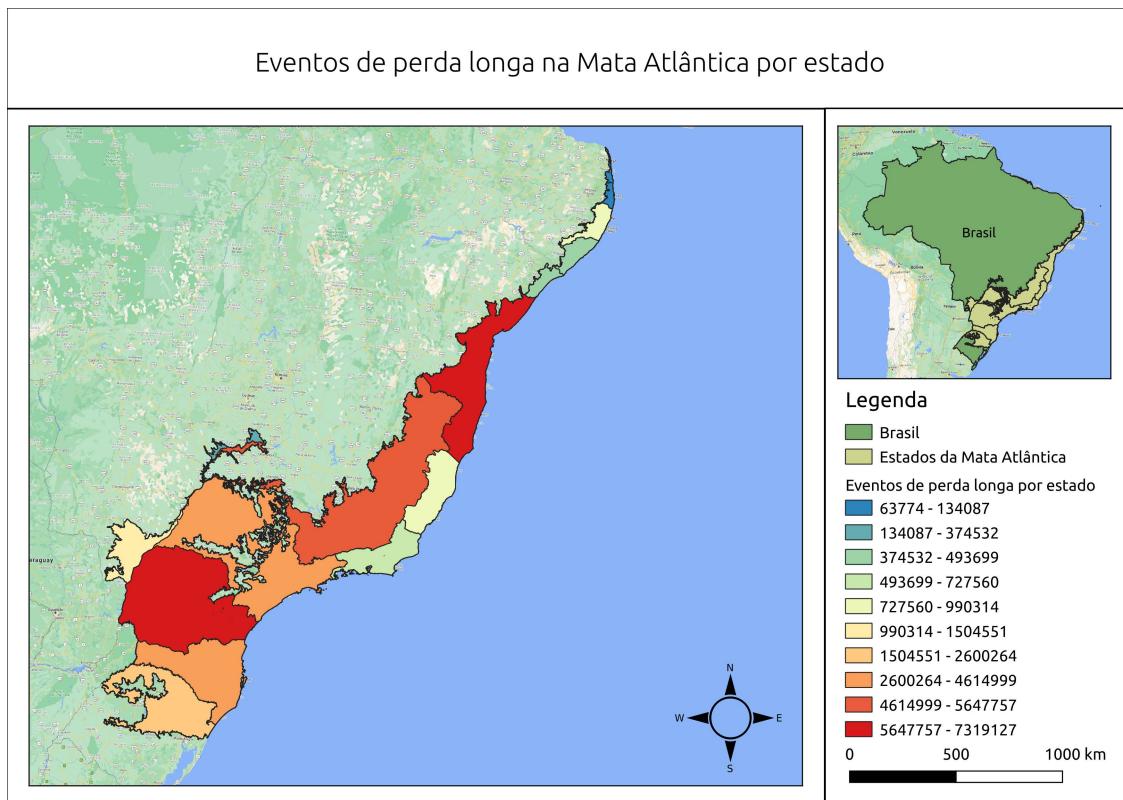


Figura 23: Todos os eventos de perda longa (duração maior que 1) na Mata Atlântica entre 1985 e 2018 por estado.

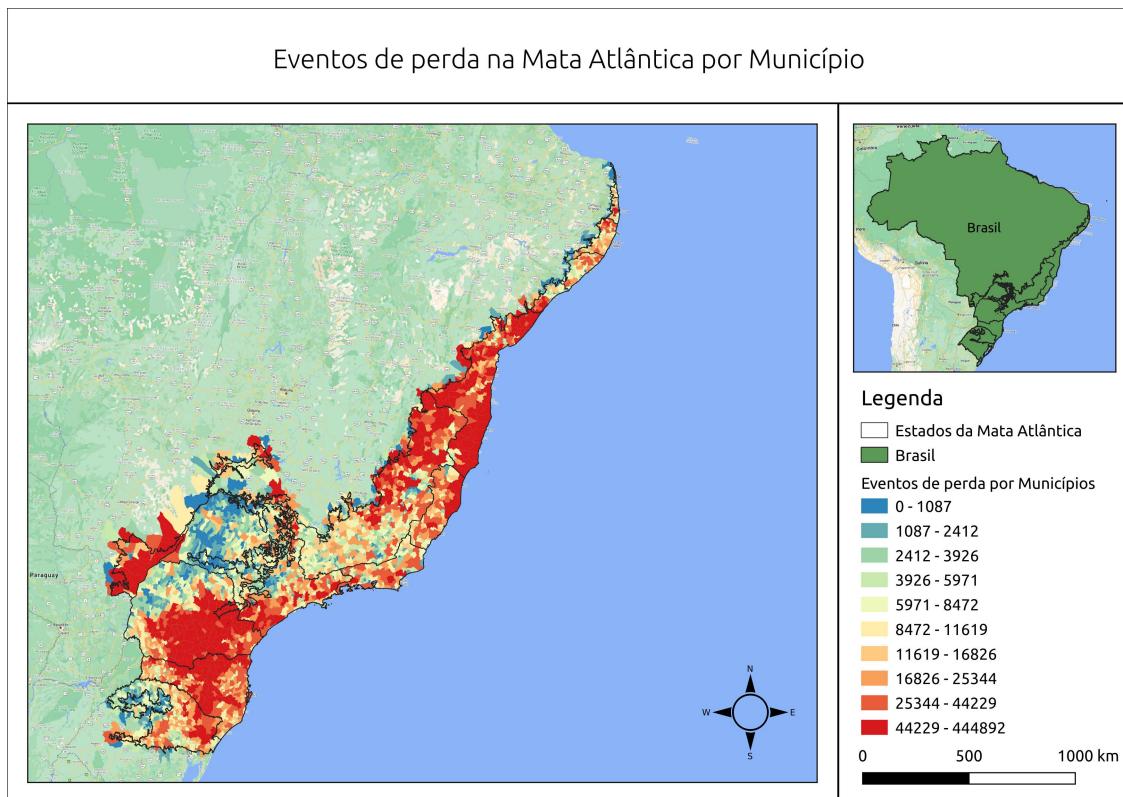


Figura 24: Todos os eventos de perda na Mata Atlântica entre 1985 e 2018 por município. Os valores representam o número de pixels que tiveram alguma detecção de perda.

Seja através dos mapas de calor, ou divisões por municípios ou estados, podemos observar que os eventos de perda na Mata Atlântica brasileira ocorre de forma aglomerada em certas regiões. Apesar de termos registrado eventos de perda em todos os tipos de fitofisionomias, parece ter havido uma predominância de eventos em florestas ombrófilas densas principalmente por conta das perdas detectadas no Paraná, Santa Catarina e Bahia.

Podemos observar ainda que grande parte dos eventos de perda no bioma aconteceu durante a década de 1990 concentrados principalmente no sudeste e centro-oeste. Já na parte região sul, os eventos foram mais recentes, ocorrendo em sua maioria durante a década de 2000. Já a região nordeste foi a que mostrou maior variabilidade neste sentido, possuindo estados com eventos mais antigos e recentes (Figura 25). Ao diminuirmos a escala geográfica da análise para municípios, podemos ver que há, de modo geral, grande presença de eventos durante a década de 1990 em todo o bioma. Mesmo na região sul, boa parte das perdas ocorridas no estado do Paraná forma registradas durante esta década (Figura 26). Nesta escala de análise, podemos observar ainda a presença, mesmo que não proporcionalmente em grande quantidade, de municípios com predominância de perdas bem mais recentes, durante a última década de 2010, principalmente nos estados de Minas Gerais, Paraná, Santa Catarina e São Paulo.

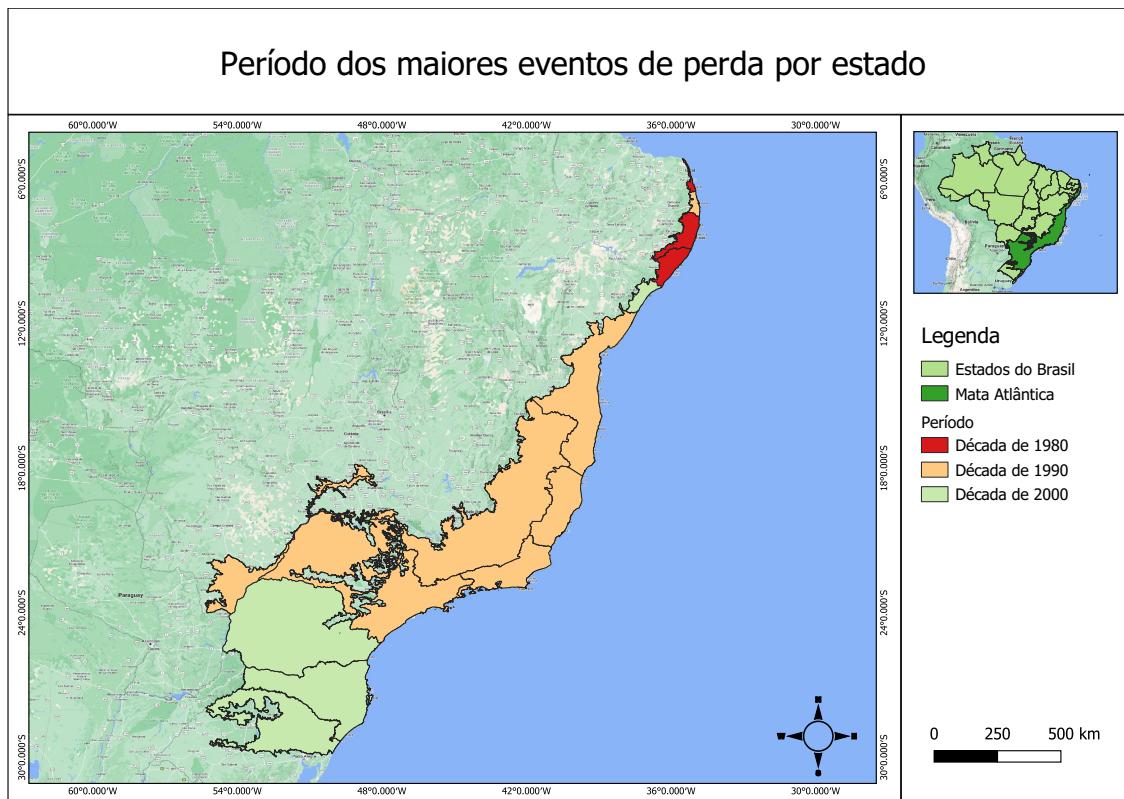


Figura 25: Mapa com os eventos de perda entre 1985 e 2018 classificado de acordo com a proporção de área de cada estado.

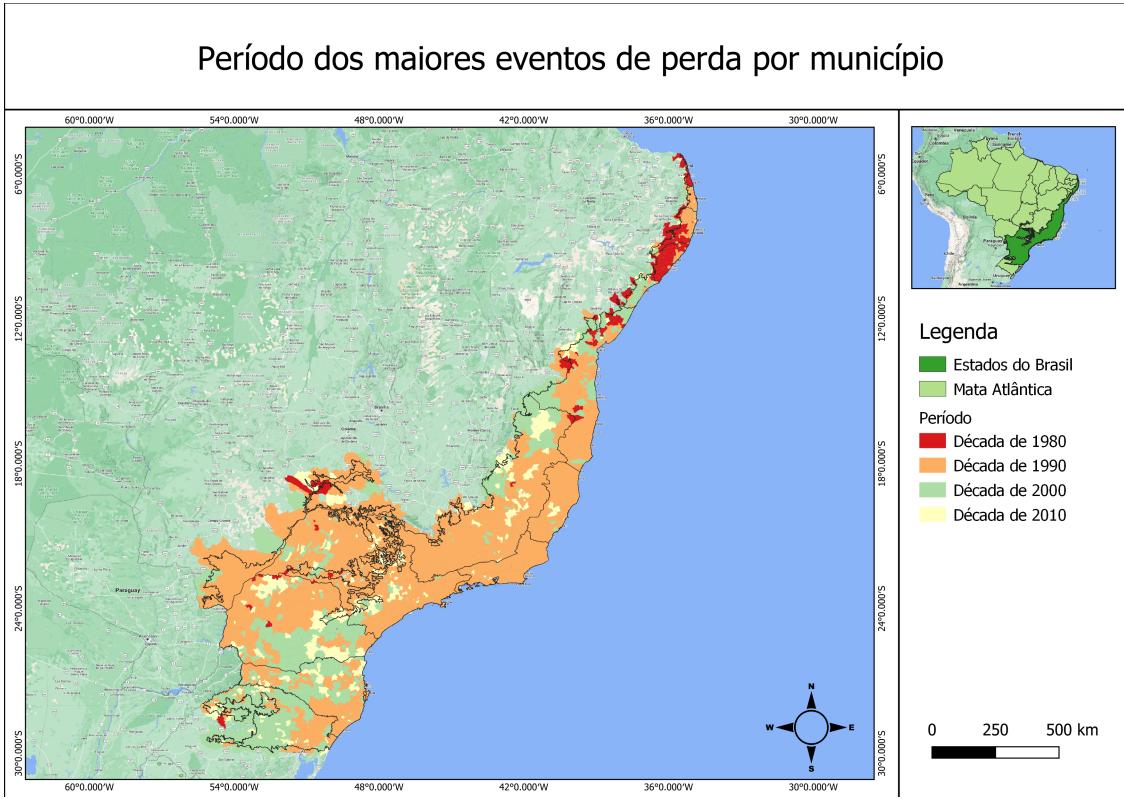


Figura 26: Mapa com os eventos de perda entre 1985 e 2018 classificado de acordo com a proporção de área de cada estado.

O grau de elevação de onde os eventos foram detectados também foram avaliados com o intuito de entender se as mudanças ocorreram em áreas mais altas ou baixas. O modelo digital de elevação utilizado foi o Shuttle Radar Topography Mission (SRTM) com 30m de resolução espacial [28]. E para a criação da análise foi necessário primeiramente calcular a média da elevação de cada estado, assim como a média dos eventos de mudança e posteriormente subtrair ambos os resultados para a criação de um mapa de elevação relativa:

$$E_{rel} = \frac{1}{n} \sum_{i=1}^n ce_i - \frac{1}{n} \sum_{i=1}^n dem_i \quad (1)$$

Sendo (E_{rel}) a elevação relativa por estado, (n) o número de pixel, (ce) a camada com os eventos de mudança e (dem) a camada original de elevação. Assim, números positivos significam áreas onde a média dos eventos de perda foram detectados acima da elevação média para o estado. Podemos observar na Figura 27 que todos os estados do sudeste tiveram eventos de perda em áreas mais altas, assim como no estado do Paraná, o que o distoou do resto dos estados do sul que obtiveram média abaixo da elevação, assim como no nordeste.

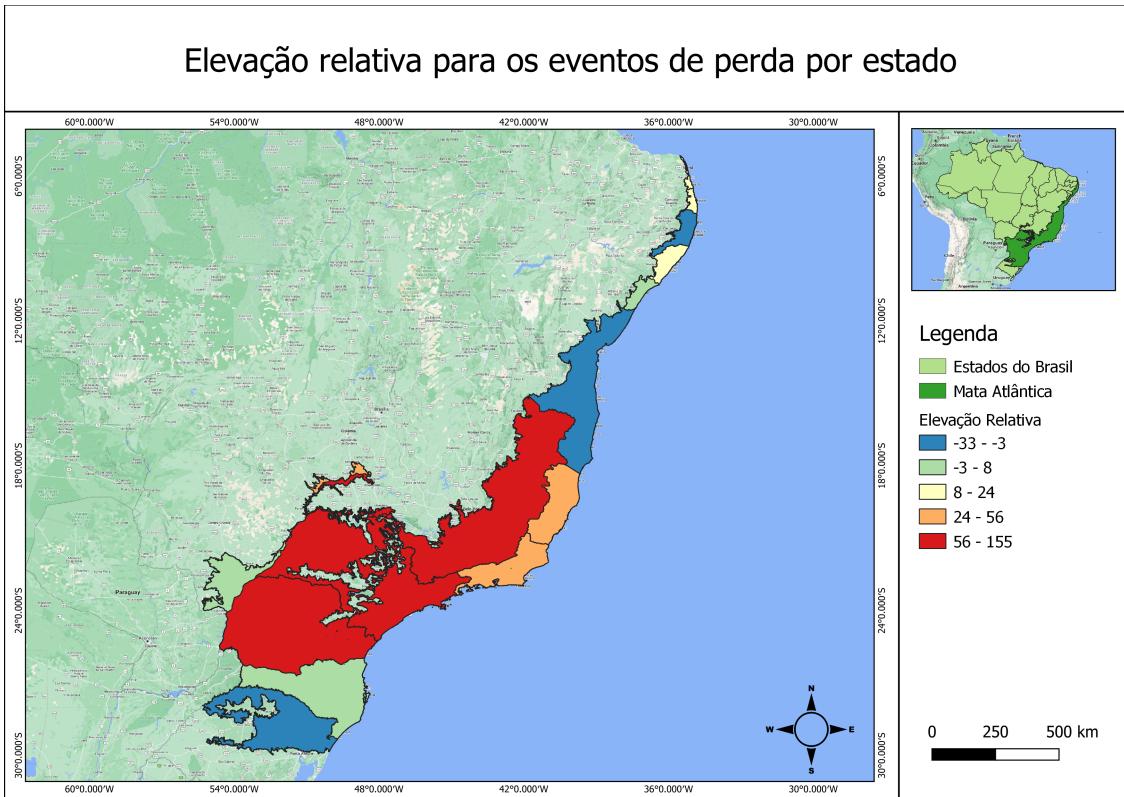


Figura 27: Mapa com a elevação relativa dos eventos de perda por estado.

Além da elevação, foi analisado também o grau de declividade dos eventos de perda com o objetivo de entender se os eventos ocorriam majoritariamente em áreas planas ou com algum grau de declividade. Desta vez a escala de análise se deu no nível de município devido à variabilidade dos dados. Novamente, o dado de entrada para a geração da camada de declividade SRTM 30m [28]. Os pixels foram agrupados em classes utilizando uma modificação do sistema de classificação de declividade da EMBRAPA 1979 [1] (Figura 28).

Declividade (%)	Relevo
0 - 3	Pouco ou nenhum
4 - 9	Suave
10 - 15	Moderado
16 - 30	Íngreme
31+	Extremamente Íngreme

É possível observar uma predominância de eventos de declividade íngreme em todo o bioma, com exceção de parte da costa onde a declividade não passou dos 3% e de regiões no sul/sudeste e norte da Bahia com a presença de inclinações suaves. De forma geral, foi possível observar que a maior parte dos eventos de perda aconteceram em relevos mais inclinados, o que pode demonstrar uma possível procura por novas áreas fora das planícies já desmatadas.

Grau de inclinação majoritário dos eventos de perda por município

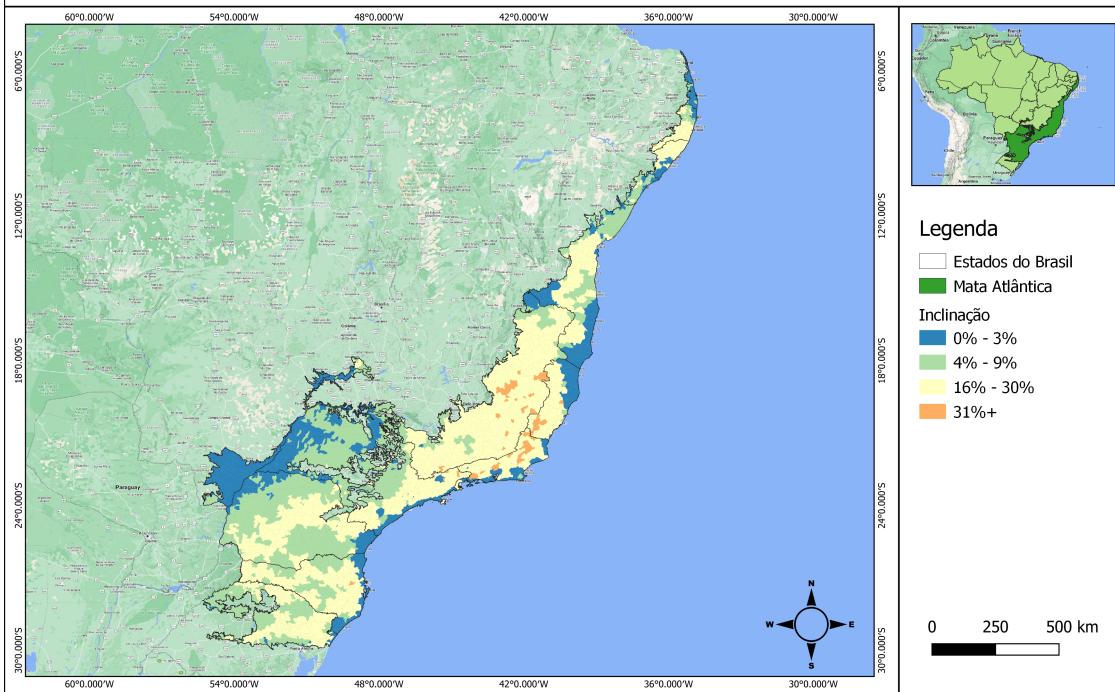


Figura 28: Mapa com os graus de declividade mais comuns de acordo com as áreas de evento de perda para cada município do bioma.

3.3.2 Os eventos de ganho na Mata Atlântica

Somando-se todos os eventos de ganho detectados pelo algoritmo e após as filtragens necessárias, houveram ao longo de todos os anos da análise 68.869.908 de pixels com um ganho médio de 197 ou aumento de 0.197 no índice NDVI. Isso equivale a uma área total de aproximadamente 62 mil km^2 de florestas que sofreram ganhos significativos. Como discutido na sessão 3.2.4, áreas de florestas pseudo-invariantes não foram consideradas, sendo assim, esta área representa um ganho real de área verde dentro do bioma.

Na Figura 29, podemos ver que o ganho de áreas no bioma de deu de forma bem mais homogênea que as áreas de perda. Apenas alguns pontos de aglomeração podem ser visualizados como no sul do Rio Grande do Sul, Espírito Santo, sul de Pernambuco, São Paulo e Minas Gerais.

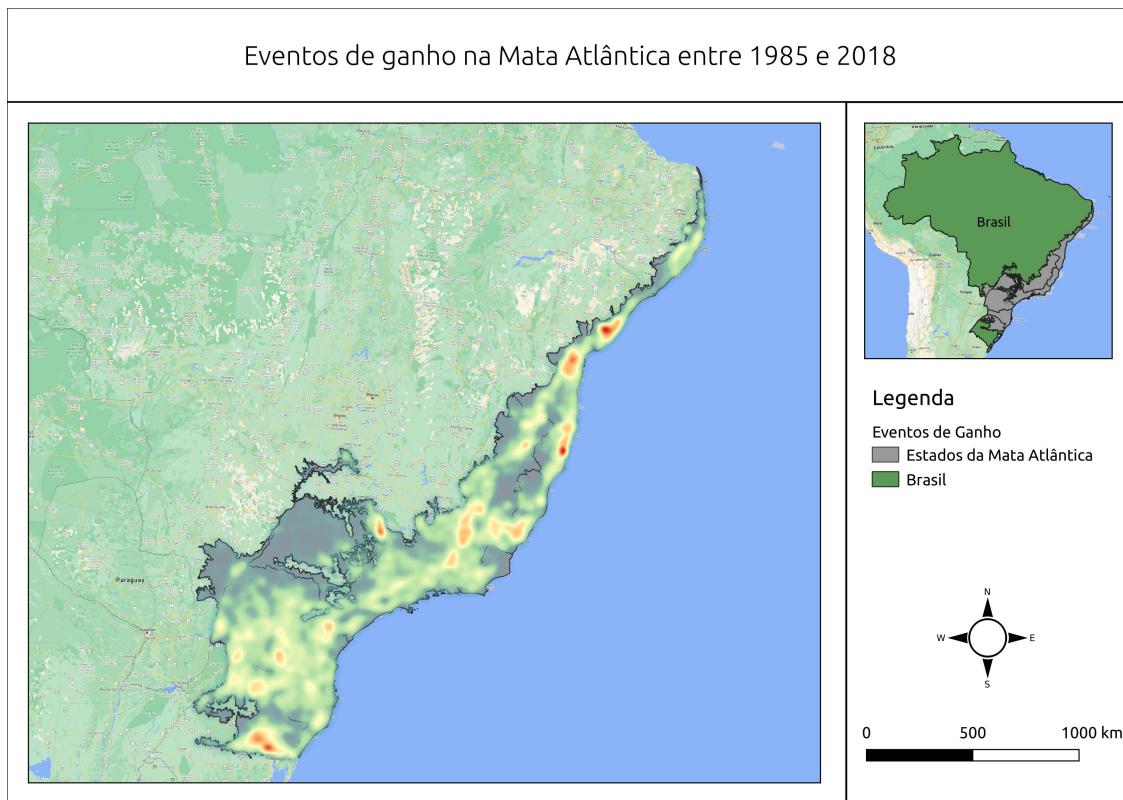


Figura 29: Mapa com os eventos de ganho entre 1985 e 2018.

Quando analisamos por estado, verificamos que Paraná e Minas Gerais dominam na quantidade total de eventos, seguido de São Paulo, Santa Catarina e Bahia (Figura 30). Ao dividir o número de eventos pela área de cada estado vemos que o concentração ocorre principalmente em Santa Catarina e Bahia, seguida de Sergipe, Rio Grande do Sul e Espírito Santo (Figura 31). Assim como nos eventos de perda, ao calcular a proporção dos eventos de ganho por município de acordo com a quantidade original de floresta presente em 1985, o litoral sul e sudeste apresentam baixa proporção de ganho com aumento significativo em regiões do Paraná, São Paulo, Minas Gerais e Bahia (Figura 32). O município de Cosmorama em São Paulo foi o recordista no aumento proporcional de área de floresta, saindo de 1,2 km² em 1985 para 10,4 km² em 2018, um aumento de aproximadamente 8,6 vezes.

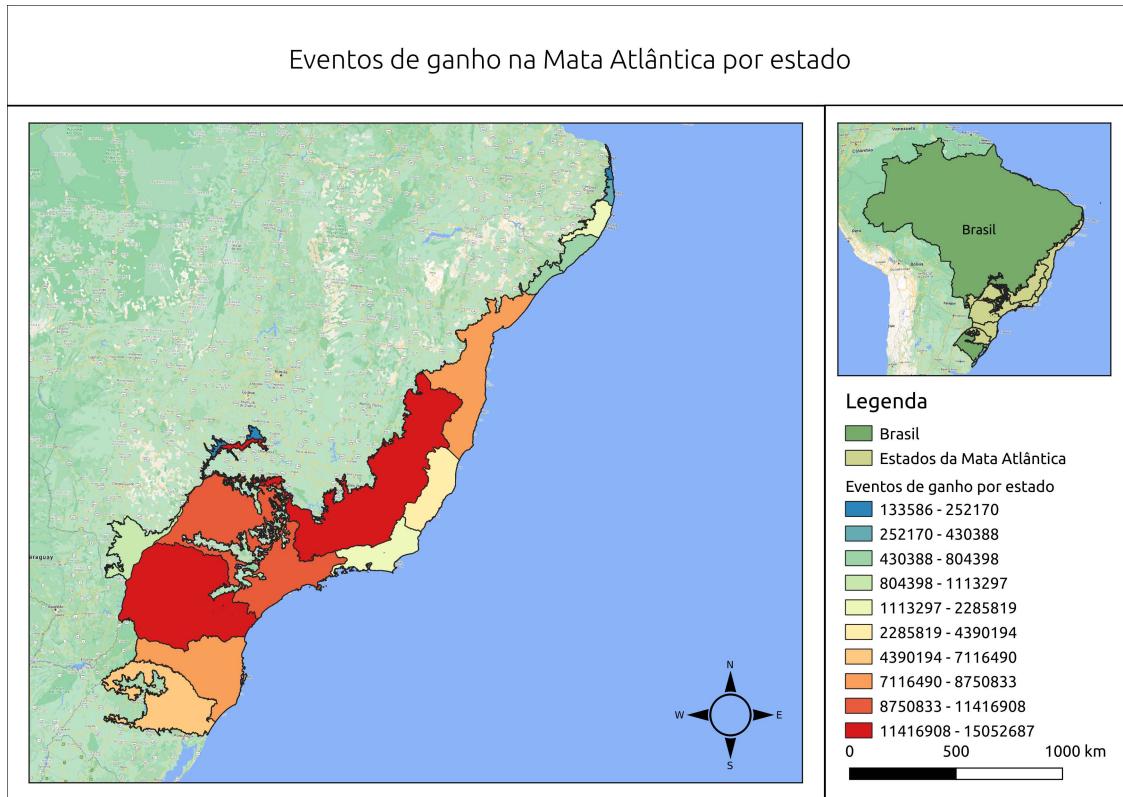


Figura 30: Mapa com os eventos de ganho entre 1985 e 2018 por estado. Os valores representam o número de pixels que tiveram alguma detecção de ganho.

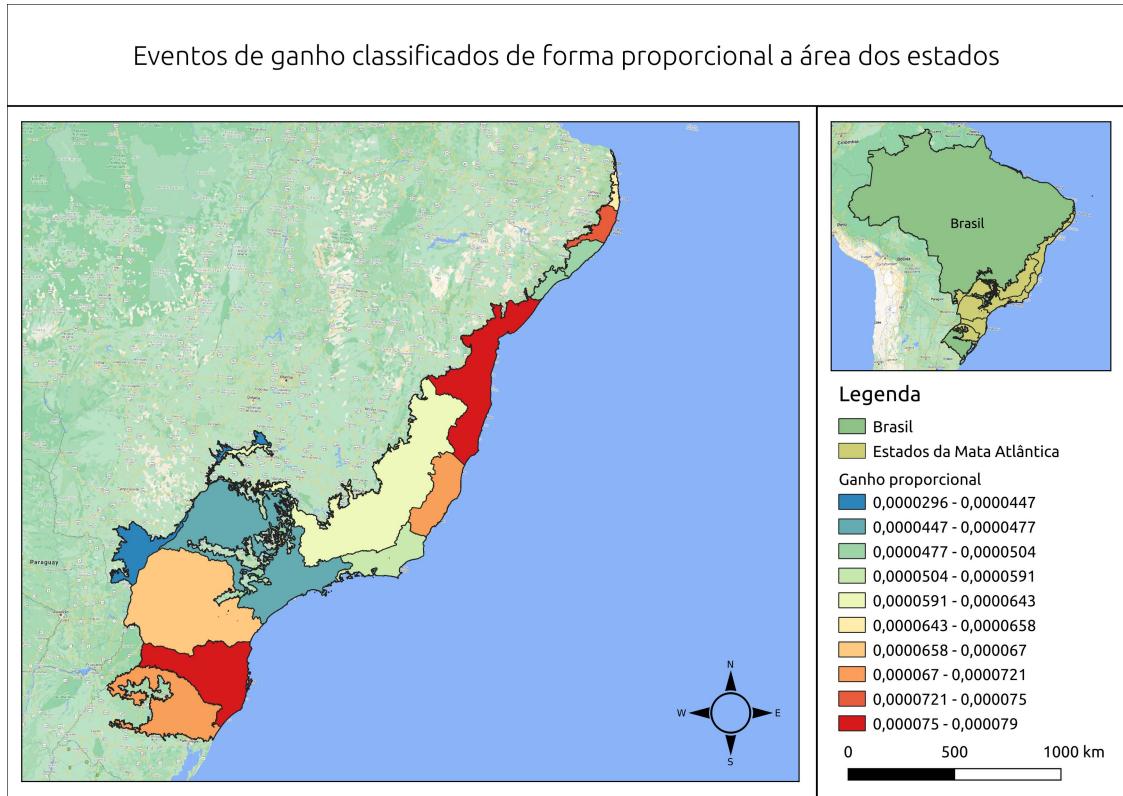


Figura 31: Mapa com os eventos de ganho entre 1985 e 2018 classificado de acordo com a proporção de área de cada estado.

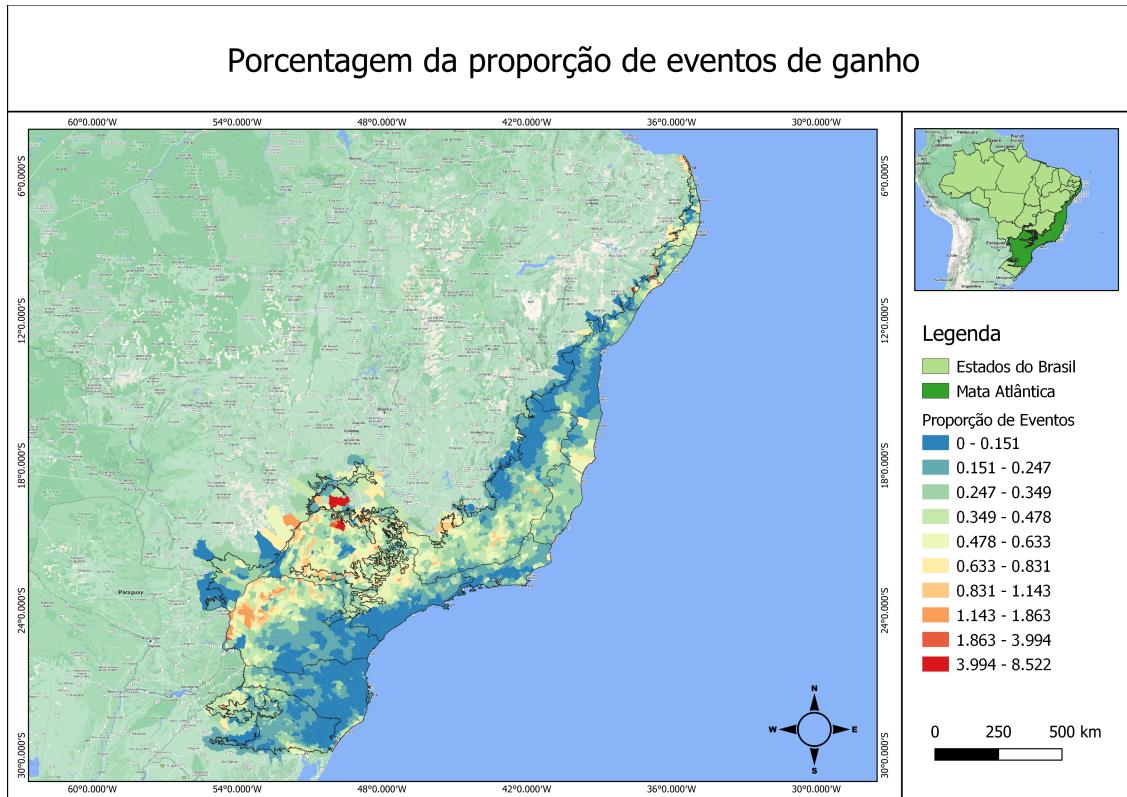


Figura 32: Mapa com a proporção dos eventos de ganho entre 1985 e 2018 classificado de acordo com a área total de floresta em 1985.

Ao analisar a proporção de área ganha dentro das unidades de conservação (UC) presente no bioma, percebemos que, como esperado, a proporção de área ganha dentro das unidades é muito mais significativa que as de perda. Diferente dos cenário de perda, aqui encontramos a média dos anos de início do ganho próximos do início da década de 1990, enquanto na perda a média tende mais para a segunda metade da década ou até mesmo os anos 2000 (Tabela 6).

Unidade de Conservação	UF	% de ganho de área	Ano Criação	Média YOD
PARNA do Descobrimento	BA	0.64	1999	1991
REBIO do Córrego Grande	ES	0.53	1989	1989
ESEC de Aracuri-Esmeralda	RS	0.44	1981	1993
FLONA de Nísia Floresta	RN	0.43	2001	1990
FLONA do Rio Preto	ES	0.34	1990	1989
FLONA de Lorena	SP	0.23	2001	1991
PARNA de Monte Pascoal	BA	0.22	1961	1991
FLONA de Ipanema de Paula	SP	0.21	1992	1989
PARNA do Pau Brasil	BA	0.18	1999	1991
REBIO de Sooretama	ES	0.17	1982	1989

Tabela 6: As dez unidades de conservação com maior proporção de ganho de área.

Já quando realizamos a análise de ganho por município, assim como no cenário de perdas, conseguimos perceber uma maior aglomeração em municípios em estados que tiveram baixa taxa de eventos como o Rio de Janeiro (Figura 33). A lista de municípios

com a maior quantidade de eventos se mostrou um pouco mais heterogênea que a do cenário de perdas (Tabela 7).

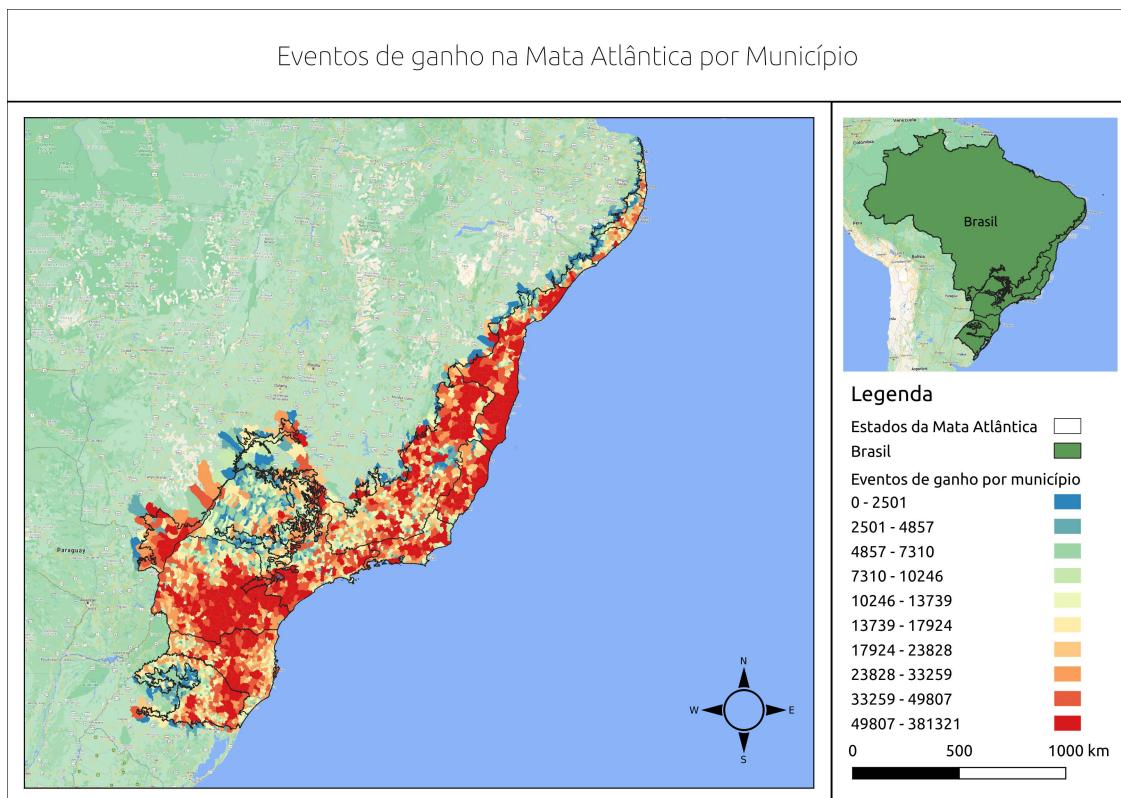


Figura 33: Mapa com os eventos de ganho entre 1985 e 2018 por município. Os valores representam o número de pixels que tiveram alguma detecção de ganho.

Nome	Eventos	UF
Porto Seguro	381321	BA
Prado	337864	BA
Jequitinhonha	309792	MG
Santa Cruz Cabrália	243153	BA
Linhares	241735	ES
Almenara	235791	MG
Prudentópolis	231492	PR
Belmonte	228173	BA
Guarapuava	225197	PR
Ortigueira	218987	PR
Entre Rios	203945	BA
Cruz Machado	196431	PR
Domingos Martins	182013	ES
Juiz de Fora	181554	MG
Esplanada	181265	BA
Mariana	177423	MG
Teófilo Otoni	176573	MG
Tibagi	175646	PR
São Sebastião do Paraíso	175471	MG
Caravelas	174156	BA

Tabela 7: Os vinte municípios com maior número de eventos de perda

Ao analisar o ano de detecção dos ganhos agregando através das décadas, percebemos que grande parte dos estados tiveram seus ganhos iniciados na década de 1990 com exceção de Sergipe, que apresentou recuperações na década de 1980 (Figura 34). Ao subdividirmos a análise por municípios, percebemos a presença de recuperações mais recentes espalhadas principalmente em São Paulo, Paraná, Mato Grosso e Minas Gerais. Eventos mais antigos iniciados na década de 1980 também são maioria em alguns municípios em Santa Catarina, São Paulo e Bahia, mas ainda sim, em menor quantidade (Figura 35).



Figura 34: Mapa com os períodos dos maiores eventos de ganho dividido por década por estado.

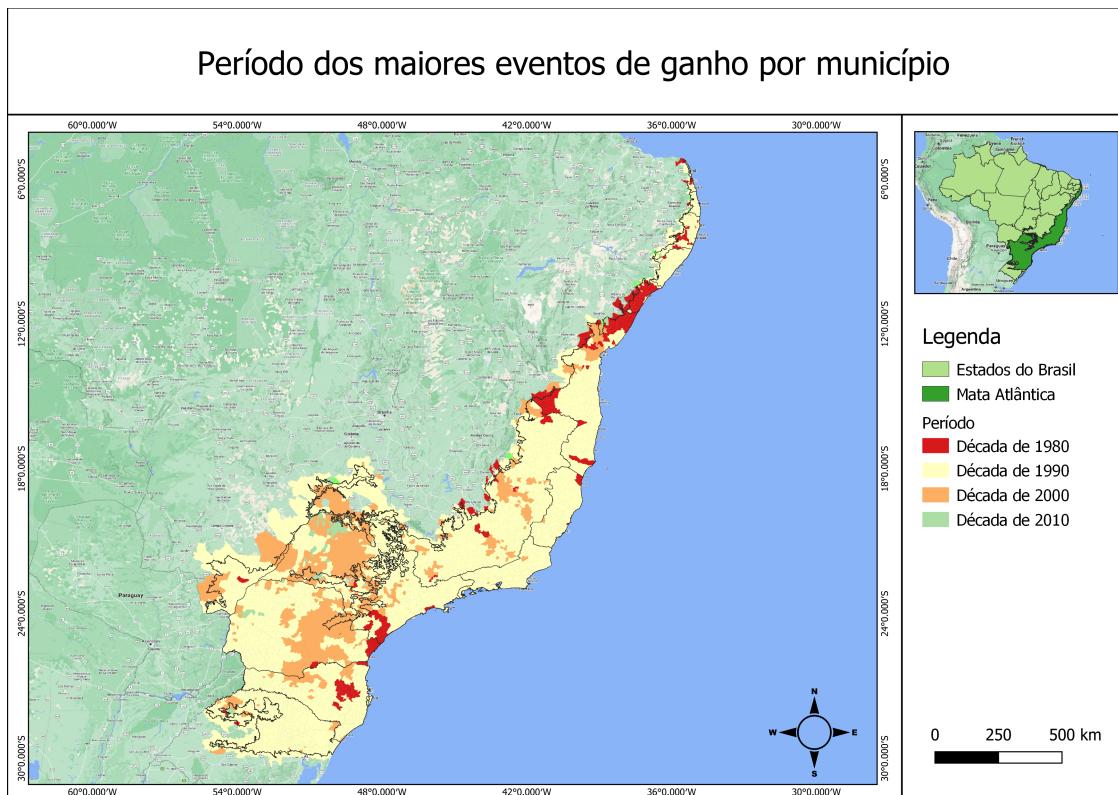


Figura 35: Mapa com os períodos dos maiores eventos de ganho dividido por década por município.

Assim como para os eventos de perda, uma análise de elevação foi realizada para identificar estados que tiveram mudanças maiores ou menores que a média da elevação estadual. São Paulo, Rio de Janeiro e Espírito Santo tiveram as maiores médias, mostrando que os eventos de ganho nessas regiões ocorreram em partes mais altas (Figura 36). É interessante observar que a região sudeste como um todo obteve uma média alta tanto nos eventos de ganho quanto nos de perda, o que demonstra uma dinâmica maior das partes mais altas. Já no Sul houve uma queda geral da média em relação ao cenário de perda. Já as regiões nordeste e centro-oeste se mantiveram estáveis em todos os estados.

Já o grau de declividade para os cenários de ganho permaneceu similar ao cenário de perdas, mostrando uma coerência geral. No entanto, é perceptível em certas regiões uma maior quantidade de municípios com grau de declividade maior nos eventos de ganho (Figura 37).



Figura 36: Mapa com a elevação relativa dos eventos de ganho por estado.

Grau de inclinação majoritário dos eventos de ganho por município

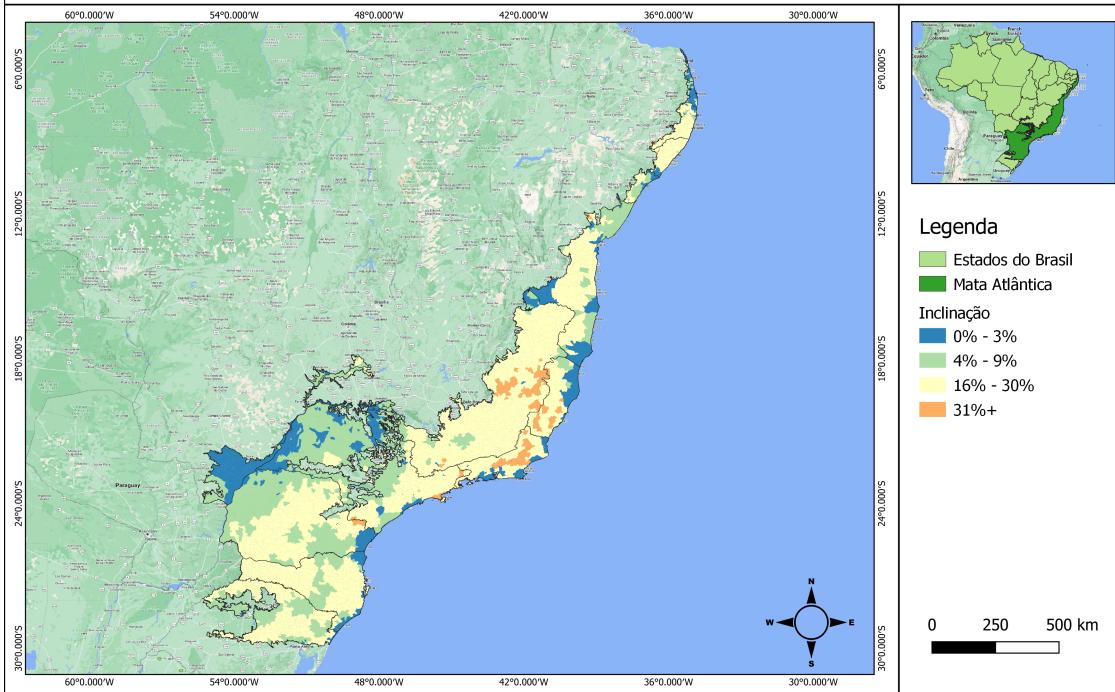


Figura 37: Mapa com os graus de declividade mais comuns de acordo com as áreas de evento de ganho para cada município.

3.4 Conclusão

O estudo da paisagem através da análise de séries temporais de imagens orbitais se mostrou essencial para o melhor entendimento dos processos ocorridos em uma região tão importante como a Mata Atlântica. Mesmo sendo um dos biomas mais estudados do país, a compreensão dos processos de mudança do uso e cobertura do solo através de uma representação visual e a possibilidade da quantificação dos processos só passaram a ser viáveis recentemente. O trabalho apresentou resultados que podem contribuir com projetos de análise e monitoramento do bioma, assim como estudos futuros sobre as mudanças ocorridas nos últimos mais de 30 anos.

O algoritmo Landtrendr e sua implementação na plataforma Google Earth Engine se mostrou robusto e suficiente para analisar áreas extensas como a do bioma e seus 15 estados com altíssimo rendimento de velocidade de processamento. Ademais, o algoritmo apresentou alto rendimento ao apresentar resultados com acurácia global de 87% e índice kappa de 0.8. O uso da ferramenta através de *templates* possui ainda capacidade de ampliar sua utilização para públicos ainda maiores e certamente de sua aplicação em ambientes tropicais com qualidade similar aos estudos em áreas temperadas, onde originalmente foi desenvolvido, testado e aplicado.

Apesar da facilidade de uso do Landtrendr em plataformas como o GEE, não se pode dizer que a aplicação do algoritmo é trivial, já que o mesmo possui um custo de processamento elevado mesmo na plataforma do Google. Esta característica acaba gerando a necessidade de códigos um pouco mais complexos, uma capacidade de armazenamento maior e um tempo total de processamento relativamente alto. No entanto, quando comparado a técnicas mais tradicionais, a utilização da técnica ainda apresenta benefícios signifi-

tivos. Todo o trabalho de pré-processamento e criação de composições processadas como dado de entrada é feito com apenas uma única função, e a escolha dos parâmetros pode ser feita de forma rápida tanto dentro da plataforma como em aplicativos web criados especialmente para a realização de testes.

Quanto aos resultados obtidos, os resultados mostraram um bioma com mais ganhos do que perdas de áreas florestadas. Grande parte dos eventos de ganho podem ser considerados antigos, iniciados ainda na década de 1990, mas como foi possível observar, existe boa parte do território com áreas de floresta secundária mais recentes, com menos de 20 anos de existência. No geral, foram detectados na última década mais eventos de ganho (11,667 km²) do que de perda (8,796 km²). Estados como o do Paraná e de Santa Catarina tiveram ao mesmo tempo uma boa quantidade de eventos de ganho quanto também de perda com idade similar, o que demonstra alta dinâmica na mudança do uso e cobertura na região.

Grande parte dos eventos foram detectados em áreas com declividade considerada íngreme em todo o bioma. Isso pode ser um indicativo de disputas por terras em regiões menos estabelecidas. Já grande parte da região sul, centro-oeste e nordeste, declividades mais baixas foram majoritárias, o que pode significar mudanças em remanescentes já altamente fragmentados existentes nas planícies com presença de áreas cultivadas. Outro resultado significativo foi a dominância de eventos de mudança em áreas mais elevadas que a média principalmente no sudeste, o que pode ser indicativo de uma maior mudança em áreas chave para importantes para a manutenção de bacias hidrográficas e outros serviços ecossistêmicos.

Este trabalho teve como objetivo utilizar o algoritmo Landtrendr para contribuir para um maior entendimento sobre o bioma da Mata Atlântica e consequentemente para programas e projetos de conservação e restauração de uma região que é um *hotspot* de biodiversidade. O espaço temporal escolhido também possui sua importância devido a sua relevância social e política, vide que representa um momento chave de reestabelecimento da democracia brasileira. O bioma foi o primeiro a ser colonizado e povoado, possui até hoje a maior quantidade da população nacional e um das paisagens mais fragmentadas dentre todos os biomas. No entanto, como os resultados indicam, é um bioma que pode representar a esperança necessária para a conservação e restauração que o país precisa como busca para um desenvolvimento, de fato, sustentável.

Conclusões

4 Conclusões

A incorporação de novas tecnologias para a detecção de mudanças na cobertura vegetal como as aplicadas neste trabalho se mostrou satisfatória para sua aplicação em florestas tropicais. Mesmo ao utilizar o Landtrendr com um mesmo conjunto de parâmetros originalmente aplicados em florestas temperadas em fitofisionomias tropicais da Mata Atlântica, o algoritmo apresentou um resultado significativo. O uso do Google Earth Engine se mostrou essencial tanto para o processamento, quanto armazenamento e também visualização e apresentação dos resultados. Sem a possibilidade de processamento na plataforma, a aplicação de algoritmos de detecção de mudança em larga escala seria limitada a poucos centros de pesquisa e a projetos com verba elevada.

No entanto, algumas limitações também foram percebidas durante o processo de teste da solução. Apesar do ganho significativo na capacidade e tempo de processamento, o Landtrendr só consegue ser executado em imagens com área similar a uma cena Landsat por vez, o que torna necessário a estruturação de uma plano de execução e agregação posterior dos resultados de forma que os mesmos não sejam sobrepostos. Além disso, ainda existem poucos casos de aplicação da ferramenta, uma documentação em constante desenvolvimento e limitações em relação a aplicação do algoritmo utilizando índices ou bandas que ainda não foram implementados na ferramenta. A incorporação de novos índices ainda é feita pela equipe desenvolvedora à partir de pedidos formais por email ou pela sessão *issues* do GitHub.

Há também, pouca informação e pesquisa sobre os parâmetros adotados pela ferramenta, assim como sobre os melhores índices/bandas. A incorporação da banda extra inicialmente chamada DSNR, atualmente CSNR, possibilitou entender quais bandas podem obter o melhor resultado de acordo com a área de estudo, mas como visto neste trabalho, quando aplicada a áreas extensas, os resultados não se mostraram robustos o suficiente. Houve uma variação muito alta nos erros associados para que os mesmos pudessem ser aplicados e uma banda ou índice pudesse ser escolhido para a aplicação da ferramenta.

Contudo, mesmo utilizando os parâmetros padrão da ferramenta, assim como o uso do NDVI como índice base para sua aplicação, os resultados obtidos pela ferramenta foram surpreendentes. Os resultados mostraram uma acurácia de 90% e kappa de 0.85 em áreas de floresta ombrófila densa, 88% e kappa de 0.82 em florestas ombrófilas mistas, e acurácia de 84% com kappa de 0.76 em áreas de vegetação estacional semidecidual. Com uma acurácia global de 86.7% e kappa de 0.8 pode se dizer que o algoritmo apresentou um resultado excelente para uma região tão extensa e diversa como o bioma. O TimeSync, ferramenta desenvolvida e disponibilizada abertamente pelos mesmos criadores do algoritmo se mostrou uma ferramenta essencial para a etapa de validação, sendo também um ótimo recursos para a etapa de validação de outros projetos, mesmo nos que utilizem outros algoritmos de detecção. O TimeSync possui a limitação de trabalhar apenas com séries temporais anuais, o que para algoritmos similares como o CCDC que trabalha com séries inteiras sem divisão temporal fixa, é um problema. No entanto, é certamente uma ferramenta que pode inspirar o desenvolvimento de opções similares que possuam a possibilidade de trabalho com outros formatos de análise. O campo ainda é novo e muitos algoritmos foram desenvolvidos na última década. A incorporação dos mesmos em plataformas como o Google Earth Engine mostra o crescimento da popularidade, e resultados como o obtido no caso da Mata Atlântica mostram a maturidade, potencialidade e viabilidade das mesmas.

Os resultados obtidos pelo Landtrendr para a Mata Atlântica, mostra um bioma que nos 33 anos (1985 - 2018) teve mais ganhos (11,667 km²) do que perdas (8,796 km²). Tanto os eventos de ganho quanto de perda, em sua maioria, aconteceram durante a década de 1990, o que refletiu diretamente nos resultados obtidos para as unidades de conservação do bioma. Uma alta dinâmica no uso e cobertura da terra devido a idade similar tanto dos eventos de ganho quanto perda foi detectada principalmente em estados com o do Paraná, Santa Catarina e Bahia.

Os dados ainda mostraram eventos de ganho e perda, principalmente no sudeste, em partes mais altas e/ou com alto grau de declividade, o que demonstra nessas regiões com histórico de antropização mais forte, uma provável maior disputa por terras em regiões menos antropizadas. Já no sul, com exceção do Paraná, a maior parte das detecções aconteceram em áreas mais baixas, seguindo a mesma lógica presente no nordeste. Mudanças nesses locais aconteceram principalmente em remanescentes já fragmentados presentes nas áreas mais planas. Outro resultado significativo apresentado pelo algoritmo foi a alta quantidade de perdas com declividade considerada íngreme em todo o bioma, provável influência causada por movimentos de massa nessas regiões.

Uma característica importante dos resultados obtidos por algoritmos de detecção de mudança baseado na análise de séries temporais, e principalmente no caso do Landtrendr, é a quantidade realmente significativa de resultados derivados que podem ser gerados. A execução da ferramenta resulta em ao menos seis camadas, que por si só já podem servir de apoio a análise, monitoramento e tomada de decisão estratégica em áreas cruciais para o desenvolvimento sustentável. A possibilidade de mudança de índice e dos parâmetros de execução possibilita a aplicação da ferramenta em projetos com diferentes objetivos e até mesmo da aplicação em áreas não tradicionais, como áreas urbanas.

O foco deste trabalho foi o teste do algoritmo Landtrendr em áreas tropicais com o objetivo do desenvolvimento de uma metodologia para aplicação da mesma em áreas maiores, visando uma maior diversidade de aplicações, inclusive em grandes projetos de monitoramento. Estamos na década da restauração, e o uso de soluções como a estudada durante este trabalho se mostrou robusta o suficiente para sua consideração em trabalhos futuros que tenham como ao menos um dos seus objetivos a incorporação do tempo e o maior entendimento dos processos da dinâmica da paisagem. Este entendimento se mostra cada vez mais essencial para que os projetos de conservação e restauração sejam analisados ou monitorados com alto nível de complexidade e maior qualidade.

No início deste trabalho existiam pouquíssimas iniciativas de utilização do Landtrendr, assim como de outras ferramentas similares no território nacional. O Landtrendr possuía apenas sua versão clássica para ENVI/IDL e somente em 2018 que passou a contar com sua implementação para a plataforma do Google. Com isso, novas possibilidades surgiram, e o esforço foi para que este documento pudesse contribuir tanto para uma discussão mais ampla sobre a ferramenta, como para o uso de soluções similares e para as possibilidades de análises baseadas em séries temporais em um contexto territorial extenso como o nosso. Os resultados, como discutido anteriormente, foram satisfatórios e muitas possibilidades de análise não caberiam em um documento como este. No entanto, acredita-se que o mesmo pode contribuir tanto no sentido técnico voltado para a comunidade de geotecnologias e sensoriamento remoto, assim como para um maior entendimento das dinâmicas espaciais ocorridas no bioma em um período chave da democracia nacional.

Referências Bibliográficas

5 Bibliografia

- [1] E. B. D. P. AGROPECUÁRIA. Súmula da 10. Reunião Técnica de Levantamento de Solos. *Serviço Nacional de Levantamento e Conservação de Solos (Rio de Janeiro, RJ)*, 13:83, 1979.
- [2] D. Almeida, S. Stark, R. Chazdon, B. Nelson, R. Cesar, P. Meli, E. Gorgens, M. Duarte, R. Valbuena, V. Moreno, A. Mendes, N. Amazonas, N. Gonçalves, C. Silva, J. Schietti, and P. Brancalion. The effectiveness of lidar remote sensing for monitoring forest cover attributes and landscape restoration. *Forest Ecology and Management*, 438:34 – 43, 2019.
- [3] D. Arribas-Bel and J. Reades. Geography and computers: Past, present, and future. *Geography Compass*, 12(10):e12403, 2018. e12403 GECO-1139.R1.
- [4] A. Banskota, N. Kayastha, M. J. Falkowski, M. A. Wulder, R. E. Froese, and J. C. White. Forest monitoring using landsat time series data: A review. *Canadian Journal of Remote Sensing*, 40(5):362–384, 2014.
- [5] H. Bendini, I. Sanches, T. Körting, L. Fonseca, A. Luiz, and A. Formaggio. Using landsat 8 image time series for crop mapping in a region of cerrado, brazil. *ISPRS - International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, XLI-B8:845–850, 06 2016.
- [6] D. Berndt and J. Clifford. Using dynamic time warping to find patterns in time series. volume 10/16, pages 359–370, 01 1994.
- [7] B. Bischl, M. Lang, L. Kotthoff, J. Schiffner, J. Richter, E. Studerus, G. Casalicchio, and Z. M. Jones. mlr: Machine learning in r. *Journal of Machine Learning Research*, 17(170):1–5, 2016.
- [8] M. T. Bonney, Y. He, and S. W. Myint. Contextualizing the 2019–2020 kangaroo island bushfires: Quantifying landscape-level influences on past severity and recovery with landsat and google earth engine. *Remote Sensing*, 12(23), 2020.
- [9] A. B. Bos, V. D. Sy, A. E. Duchelle, M. Herold, C. Martius, and N.-E. Tsendlbazar. Global data and tools for local forest cover loss and redd+ performance assessment: Accuracy, uncertainty, complementarity and impact. *International Journal of Applied Earth Observation and Geoinformation*, 80:295 – 311, 2019.
- [10] M. Brandt, C. J. Tucker, A. Kariryaa, K. Rasmussen, C. Abel, J. Small, J. Chave, L. V. Rasmussen, P. Hiernaux, A. A. Diouf, L. Kergoat, O. Mertz, C. Igel, F. Gielseke, J. Schöning, S. Li, K. Melocik, J. Meyer, S. Sinno, E. Romero, E. Glennie, A. Montagu, M. Dendoncker, and R. Fensholt. An unexpectedly large count of trees in the West African Sahara and Sahel. *Nature*, 587(7832):78–82, Nov. 2020.
- [11] L. Breiman. Random forests. *Machine Learning*, 45(1):5–32, Oct 2001.
- [12] E. B. Brooks, V. A. Thomas, R. H. Wynne, and J. W. Coulston. Fitting the multitemporal curve: A fourier series approach to the missing data problem in remote sensing analysis. *IEEE Transactions on Geoscience and Remote Sensing*, 50(9):3340–3353, Sep. 2012.

- [13] E. B. Brooks, R. H. Wynne, V. A. Thomas, C. E. Blinn, and J. W. Coulston. On-the-fly massively multitemporal change detection using statistical quality control charts and landsat data. *IEEE Transactions on Geoscience and Remote Sensing*, 52(6):3316–3332, June 2014.
- [14] E. L. Bullock, C. E. Woodcock, and C. E. Holden. Improved change monitoring using an ensemble of time series algorithms. *Remote Sensing of Environment*, page 111165, 2019.
- [15] R. S. V. Carla. B. M. Cruz. *Estado atual da Cobertura Vegetal e do Uso da Terra no Bioma Mata Atlântica*. Instituto Bioatlântica, 2008.
- [16] R. L. Chazdon. *Second Growth*. University of Chicago Press, 2014.
- [17] R. L. Chazdon, P. H. S. Brancalion, D. Lamb, L. Laestadius, M. Calmon, and C. Kumar. A policy-driven knowledge agenda for global forest and landscape restoration. *Conservation Letters*, 10(1):125–132, 2017.
- [18] W. Chen, W. Chen, and J. Li. Comparison of surface reflectance derived by relative radiometric normalization versus atmospheric correction for generating large-scale landsat mosaics. *Remote Sensing Letters*, 1(2):103–109, 2010.
- [19] W. B. Cohen, S. P. Healey, Z. Yang, Z. Zhu, and N. Gorelick. *Remote Sens.* 12, 2020.
- [20] W. B. Cohen, Z. Yang, S. P. Healey, R. E. Kennedy, and N. Gorelick. A landtrendr multispectral ensemble for forest disturbance detection. *Remote Sensing of Environment*, 205:131–140, 2018.
- [21] W. B. Cohen, Z. Yang, and R. Kennedy. Detecting trends in forest disturbance and recovery using yearly landsat time series: 2. timesync — tools for calibration and validation. *Remote Sensing of Environment*, 114(12):2911 – 2924, 2010.
- [22] R. Crouzeilles, E. Santiami, M. Rosa, L. Pugliese, P. H. Brancalion, R. R. Rodrigues, J. P. Metzger, M. Calmon, C. A. de M. Scaramuzza, M. H. Matsumoto, A. Padovezi, R. de M. Benini, R. B. Chaves, T. Metzker, R. B. Fernandes, F. R. Scarano, J. Schmitt, G. Lui, P. Christ, R. M. Vieira, M. M. Senta, G. A. Malaguti, B. B. Strassburg, and S. Pinto. There is hope for achieving ambitious atlantic forest restoration commitments. *Perspectives in Ecology and Conservation*, 2019.
- [23] T. W. Crowther, H. B. Glick, K. R. Covey, C. Bettigole, D. S. Maynard, S. M. Thomas, J. R. Smith, G. Hintler, M. C. Duguid, G. Amatulli, M.-N. Tuanmu, W. Jetz, C. Salas, C. Stam, D. Piotto, R. Tavani, S. Green, G. Bruce, S. J. Williams, S. K. Wiser, M. O. Huber, G. M. Hengeveld, G.-J. Nabuurs, E. Tikhonova, P. Borchardt, C.-F. Li, L. W. Powrie, M. Fischer, A. Hemp, J. Homeier, P. Cho, A. C. Vibrans, P. M. Umunay, S. L. Piao, C. W. Rowe, M. S. Ashton, P. R. Crane, and M. A. Bradford. Mapping tree density at a global scale. *Nature*, 525(7568):201–205, Sept. 2015.
- [24] A. Dara, M. Baumann, T. Kuemmerle, D. Pflugmacher, A. Rabe, P. Griffiths, N. Hözel, J. Kamp, M. Freitag, and P. Hostert. Mapping the timing of cropland abandonment and recultivation in northern kazakhstan using annual landsat time series. *Remote Sensing of Environment*, 213:49–60, 2018.

- [25] T. De Marzo, D. Pflugmacher, M. Baumann, E. F. Lambin, I. Gasparri, and T. Kuemmerle. Characterizing forest disturbances across the argentine dry chaco based on landsat time series. *International Journal of Applied Earth Observation and Geoinformation*, 98:102310, 2021.
- [26] L. Dutrieux and B. DeVries. bfastSpatial: Set of utilities and wrappers to perform change detection on satellite image time-series, 2014.
- [27] L. P. Dutrieux, C. C. Jakovac, S. H. Latifah, and L. Kooistra. Reconstructing land use history from landsat time-series: Case study of a swidden agriculture system in brazil. *International Journal of Applied Earth Observation and Geoinformation*, 47:112 – 124, 2016.
- [28] T. G. Farr, P. A. Rosen, E. Caro, R. Crippen, R. Duren, S. Hensley, M. Kobrick, M. Paller, E. Rodriguez, L. Roth, D. Seal, S. Shaffer, J. Shimada, J. Umland, M. Werner, M. Oskin, D. Burbank, and D. Alsdorf. The shuttle radar topography mission. *Reviews of Geophysics*, 45(2), 2007.
- [29] E. H. FRAGAL, T. S. F. SILVA, and E. M. L. d. M. NOVO. Reconstructing historical forest cover change in the Lower Amazon floodplains using the LandTrendr algorithm. *Acta Amazonica*, 46(1):13–24, 2016.
- [30] N. Galiatsatos, D. N. Donoghue, P. Watt, P. Bholanath, J. Pickering, M. C. Hansen, and A. R. Mahmood. An assessment of global forest change datasets for national forest monitoring and reporting. *Remote Sensing*, 12(11), 2020.
- [31] GDAL/OGR contributors. *GDAL/OGR Geospatial Data Abstraction software Library*. Open Source Geospatial Foundation, 2020.
- [32] P. Gelabert, M. Rodrigues, J. de la Riva, A. Ameztegui, M. Sebastià, and C. Vega-Garcia. Landtrendr smoothed spectral profiles enhance woody encroachment monitoring. *Remote Sensing of Environment*, 262:112521, 2021.
- [33] F. Giannetti, R. Pegna, S. Francini, R. E. McRoberts, D. Travaglini, M. Marchetti, G. Scarascia Mugnozza, and G. Chirici. A new method for automated clearcut disturbance detection in mediterranean coppice forests using landsat time series. *Remote Sensing*, 12(22), 2020.
- [34] F. Gieseke, S. Rosca, T. Henriksen, J. Verbesselt, and C. E. Oancea. Massively-Parallel Change Detection for Satellite Time Series Data with Missing Values. In *2020 IEEE 36th International Conference on Data Engineering (ICDE)*, pages 385–396. IEEE, apr 2020.
- [35] N. Gorelick, M. Hancher, M. Dixon, S. Ilyushchenko, D. Thau, and R. Moore. Google earth engine: Planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202:18 – 27, 2017. Big Remotely Sensed Data: tools, applications and experiences.
- [36] J. Grace, E. Mitchard, and E. Gloor. Perturbations in the carbon budget of the tropics. *Global Change Biology*, 20(10):3238–3255, 2014.
- [37] J. A. Greenberg and M. Mattiuzzi. *gdalUtils: Wrappers for the Geospatial Data Abstraction Library (GDAL) Utilities*, 2020. R package version 2.0.3.2.

- [38] K. J. Gregory. *The Nature of Physical Geography*. Edward Arnold Publishers, Bedford Square 41, London, 1985.
- [39] P. Griffiths and P. Hostert. *Forest Cover Dynamics During Massive Ownership Changes – Annual Disturbance Mapping Using Annual Landsat Time-Series*, pages 307–322. 01 2015.
- [40] K. Gutjahr, R. Perko, H. Raggam, and M. Schardt. The epipolarity constraint in stereo-radargrammetric dem generation. *IEEE Transactions on Geoscience and Remote Sensing*, 52(8):5014–5022, Aug 2014.
- [41] M. C. Hansen, P. V. Potapov, R. Moore, M. Hancher, S. A. Turubanova, A. Tyukavina, D. Thau, S. V. Stehman, S. J. Goetz, T. R. Loveland, A. Kommareddy, A. Egorov, L. Chini, C. O. Justice, and J. R. G. Townshend. High-resolution global maps of 21st-century forest cover change. *Science*, 342(6160):850–853, 2013.
- [42] N. L. Harris, S. Brown, S. C. Hagen, S. S. Saatchi, S. Petrova, W. Salas, M. C. Hansen, P. V. Potapov, and A. Lotsch. Baseline map of carbon emissions from deforestation in tropical regions. *Science*, 336(6088):1573–1576, 2012.
- [43] S. P. Healey, W. B. Cohen, Z. Yang, C. K. Brewer, E. B. Brooks, N. Gorelick, A. J. Hernandez, C. Huang, M. J. Hughes, R. E. Kennedy, T. R. Loveland, G. G. Moisen, T. A. Schroeder, S. V. Stehman, J. E. Vogelmann, C. E. Woodcock, L. Yang, and Z. Zhu. Mapping forest change using stacked generalization: An ensemble approach. *Remote Sensing of Environment*, 204:717 – 728, 2018.
- [44] M. Hemati, M. Hasanlou, M. Mahdianpari, and F. Mohammadimanesh. A Systematic Review of Landsat Data for Change Detection Applications: 50 Years of Monitoring the Earth. *Remote Sensing*, 13(15):2869, jul 2021.
- [45] R. J. Hijmans. *raster: Geographic Data Analysis and Modeling*, 2020. R package version 3.4-5.
- [46] R. J. Hijmans. *terra: Spatial Data Analysis*, 2021. R package version 1.0-10.
- [47] M. Hirschmugl, H. Gallaun, M. Dees, P. Datta, J. Deutscher, N. Koutsias, and M. Schardt. Methods for mapping forest disturbance and degradation from optical earth observation data: a review. *Current Forestry Reports*, 3(1):32–45, Mar 2017.
- [48] M. Hirschmugl, M. Steinegger, H. Gallaun, and M. Schardt. Mapping forest degradation due to selective logging by means of time series analysis: Case studies in central africa. *Remote Sensing*, 6, 12 2013.
- [49] S. Hislop, S. Jones, M. Soto-Berelov, A. Skidmore, A. Haywood, and T. H. Nguyen. A fusion approach to forest disturbance mapping using time series ensemble techniques. *Remote Sensing of Environment*, 221:188–197, 2019.
- [50] R. A. Houghton, J. I. House, J. Pongratz, G. R. van der Werf, R. S. DeFries, M. C. Hansen, C. Le Quéré, and N. Ramankutty. Carbon emissions from land use and land-cover change. *Biogeosciences*, 9(12):5125–5142, 2012.

- [51] C. Huang, N. Thomas, S. N. Goward, J. G. Masek, Z. Zhu, J. R. G. Townshend, and J. E. Vogelmann. Automated masking of cloud and cloud shadow for forest change analysis using landsat images. *International Journal of Remote Sensing*, 31(20):5449–5464, 2010.
- [52] M. J. Hughes, S. D. Kaylor, and D. J. Hayes. Patch-based forest change detection from landsat time series. *Forests*, 8(5), 2017.
- [53] IBGE. *Mapa de Biomas do Brasil – primeira aproximação.*, 2004.
- [54] IBGE. *Monitoramento da cobertura e uso da terra do Brasil : 2016 - 2018.* IBGE, Brasil, 2020.
- [55] C. C. Jakovac, L. P. Dutrieux, L. Siti, M. Peña-Claros, and F. Bongers. Spatial and temporal dynamics of shifting cultivation in the middle-amazonas river: Expansion and intensification. *PLOS ONE*, 12(7):1–15, 07 2017.
- [56] C. C. Jakovac, M. Peña-Claros, T. W. Kuyper, and F. Bongers. Loss of secondary-forest resilience by land-use intensification in the amazon. *Journal of Ecology*, 103(1):67–77, 2015.
- [57] S. Jin, L. Yang, P. Danielson, C. Homer, J. Fry, and G. Xian. A comprehensive change detection method for updating the national land cover database to circa 2011. *Remote Sensing of Environment*, 132:159 – 175, 2013.
- [58] P. Jönsson and L. Eklundh. Timesat - a program for analyzing time-series of satellite sensor data. *Computers & Geosciences*, 30:833–845, 2004.
- [59] R. E. Kennedy, W. B. Cohen, and T. A. Schroeder. Trajectory-based change detection for automated characterization of forest disturbance dynamics. *Remote Sensing of Environment*, 110(3):370 – 386, 2007.
- [60] R. E. Kennedy, Z. Yang, and W. B. Cohen. Detecting trends in forest disturbance and recovery using yearly landsat time series: 1. landtrendr — temporal segmentation algorithms. *Remote Sensing of Environment*, 114(12):2897 – 2910, 2010.
- [61] R. E. Kennedy, Z. Yang, W. B. Cohen, E. Pfaff, J. Braaten, and P. Nelson. Spatial and temporal patterns of forest disturbance and regrowth within the area of the northwest forest plan. *Remote Sensing of Environment*, 122:117 – 133, 2012. Landsat Legacy Special Issue.
- [62] R. E. Kennedy, Z. Yang, N. Gorelick, J. Braaten, L. Cavalcante, W. B. Cohen, and S. Healey. Implementation of the landtrendr algorithm on google earth engine. *Remote Sensing*, 10(5), 2018.
- [63] N. Kolecka. Greening trends and their relationship with agricultural land abandonment across poland. *Remote Sensing of Environment*, 257:112340, 2021.
- [64] A. Koltunov, S. L. Ustin, G. P. Asner, and I. Fung. Selective logging changes forest phenology in the brazilian amazon: Evidence from modis image time series analysis. *Remote Sensing of Environment*, 113(11):2431 – 2440, 2009.

- [65] A. W. Komba, T. Watanabe, M. Kaneko, and M. B. Chand. Monitoring of vegetation disturbance around protected areas in central tanzania using landsat time-series data. *Remote Sensing*, 13(9), 2021.
- [66] E. Lacerda and R. Vicens. Detection of invariant vegetation areas in time series using random forest algorithm. *Geographia*, 23(50), 2021.
- [67] S. H. Latifah. *Quantifying Land Use Intensity of Slash and Burn Agriculture Using Remote Sensing Time-Series*. PhD thesis, Wageningen University, 2016.
- [68] S. Liu, X. Wei, D. Li, and D. Lu. Examining forest disturbance and recovery in the subtropical forest region of zhejiang province using landsat time-series data. *Remote Sensing*, 9(5), 2017.
- [69] V. Maus, G. Câmara, M. Appel, and E. Pebesma. dtwsat: Time-weighted dynamic time warping for satellite image time series analysis in r. *Journal of Statistical Software, Articles*, 88(5):1–31, 2019.
- [70] V. Maus, G. Câmara, R. Cartaxo, A. Sanchez, F. M. Ramos, and G. R. de Queiroz. A time-weighted dynamic time warping method for land-use and land-cover mapping. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 9(8):3729–3739, Aug 2016.
- [71] M. C. Meyer. Semi-parametric additive constrained regression. *Journal of Nonparametric Statistics*, 25(3):715–730, 2013.
- [72] G. G. Moisen, M. C. Meyer, T. A. Schroeder, X. Liao, K. G. Schleeweis, E. A. Freeman, and C. Toney. Shape selection in landsat time series: a tool for monitoring forest dynamics. *Global Change Biology*, 22(10):3518–3528, 2016.
- [73] T. Mugiraneza, A. Nascetti, and Y. Ban. Continuous monitoring of urban land cover change trajectories with landsat time series and landtrendr-google earth engine cloud computing. *Remote Sensing*, 12(18), 2020.
- [74] P. J. Murillo-Sandoval, E. Gjerdseth, C. Correa-Ayram, D. Wrathall, J. Van Den Hoek, L. M. Dávalos, and R. Kennedy. No peace for the forest: Rapid, widespread land changes in the andes-amazon region following the colombian civil war. *Global Environmental Change*, 69:102283, 2021.
- [75] V. Myroniuk, A. Bilous, Y. Khan, A. Terentiev, P. Kravets, S. Kovalevskyi, and L. See. Tracking rates of forest disturbance and associated carbon loss in areas of illegal amber mining in ukraine using landsat time series. *Remote Sensing*, 12(14), 2020.
- [76] H. Ni, P. Gong, and X. Li. Extraction of old towns in hangzhou (2000–2018) from landsat time series image stacks. *Remote Sensing*, 13(13), 2021.
- [77] A. Okabe, B. Boots, and K. Sugihara. *Spatial Tessellations: Concepts and Applications of Voronoi Diagrams*. John Wiley Sons, Inc., USA, 1992.
- [78] D. Pfugmacher, W. B. Cohen, and R. E. Kennedy. Using landsat-derived disturbance history (1972–2010) to predict current forest structure. *Remote Sensing of Environment*, 122:146 – 165, 2012. Landsat Legacy Special Issue.

- [79] P. Potapov, M. C. Hansen, I. Kommareddy, A. Kommareddy, S. Turubanova, A. Pickens, B. Adusei, A. Tyukavina, and Q. Ying. Landsat analysis ready data for global land cover and land cover change mapping. *Remote Sensing*, 12(3), 2020.
- [80] P. Potapov, X. Li, A. Hernandez-Serna, A. Tyukavina, M. C. Hansen, A. Kommareddy, A. Pickens, S. Turubanova, H. Tang, C. E. Silva, J. Armston, R. Dubayah, J. B. Blair, and M. Hofton. Mapping global forest canopy height through integration of gedi and landsat data. *Remote Sensing of Environment*, 253:112165, 2021.
- [81] QGIS Development Team. *QGIS Geographic Information System*. Open Source Geospatial Foundation, 2009.
- [82] R Core Team. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2021.
- [83] C. W. Rathnayake, S. Jones, and M. Soto-Berelov. Mapping land cover change over a 25-year period (1993–2018) in sri lanka using landsat time-series. *Land*, 9(1), 2020.
- [84] C. Rezende, F. Scarano, E. Assad, C. Joly, J. Metzger, B. Strassburg, M. Tabarelli, G. Fonseca, and R. Mittermeier. From hotspot to hopespot: An opportunity for the brazilian atlantic forest. *Perspectives in Ecology and Conservation*, 16(4):208–214, 2018.
- [85] M. R. Rosa, P. H. S. Brancalion, R. Crouzeilles, L. R. Tambosi, P. R. Piffer, F. E. B. Lenti, M. M. Hirota, E. Santiami, and J. P. Metzger. Hidden destruction of older forests threatens Brazil’s Atlantic Forest and challenges restoration programs. *Science Advances*, 7:eabc4547, 2021.
- [86] V. Sagan, Q. Qin, and L. Zhu. 6s model based atmospheric correction of visible and near-infrared data and sensitivity analysis. 40:611–618, 07 2004.
- [87] H. Sakoe and S. Chiba. A dynamic programming approach to continuous speech recognition. In *Proceedings of the Seventh International Congress on Acoustics, Budapest*, volume 3, pages 65–69, Budapest, 1971. Akadémiai Kiadó.
- [88] A. Savitzky and M. J. E. Golay. Smoothing and differentiation of data by simplified least squares procedures. *Analytical Chemistry*, 36(8):1627–1639, 1964.
- [89] R. Saxena, L. T. Watson, R. H. Wynne, E. B. Brooks, V. A. Thomas, Y. Zhiqiang, and R. E. Kennedy. Towards a polyalgorithm for land use change detection. *ISPRS Journal of Photogrammetry and Remote Sensing*, 144(July):217–234, 2018.
- [90] F. R. Scarano. *Mata Atlântica: Uma História do Futuro*. Edições de Janeiro, Rio de Janeiro, Brazil, 2014.
- [91] T. A. Schroeder, K. G. Schleeweis, G. G. Moisen, C. Toney, W. B. Cohen, E. A. Freeman, Z. Yang, and C. Huang. Testing a landsat-based approach for mapping disturbance causality in u.s. forests. *Remote Sensing of Environment*, 195:230 – 243, 2017.
- [92] C. Senf and R. Seidl. Mapping the forest disturbance regimes of Europe. *Nature Sustainability*, 4(1):63–70, Jan. 2021.

- [93] K. Shimizu, T. Ota, N. Mizoue, and S. Yoshida. A comprehensive evaluation of disturbance agent classification approaches: Strengths of ensemble classification, multiple indices, spatio-temporal variables, and direct prediction. *ISPRS Journal of Photogrammetry and Remote Sensing*, 158:99–112, 2019.
- [94] C. H. L. Silva Junior, A. C. M. Pessôa, N. S. Carvalho, J. B. C. Reis, L. O. Anderson, and L. E. O. C. Aragão. The Brazilian Amazon deforestation rate in 2020 is the greatest of the decade. *Nature Ecology & Evolution*, 5(2):144–145, Feb. 2021.
- [95] C. M. Souza, J. Z. Shimbo, M. R. Rosa, L. L. Parente, A. A. Alencar, B. F. Rudorff, H. Hasenack, M. Matsumoto, L. G. Ferreira, P. W. Souza-Filho, S. W. de Oliveira, W. F. Rocha, A. V. Fonseca, C. B. Marques, C. G. Diniz, D. Costa, D. Monteiro, E. R. Rosa, E. Vélez-Martin, E. J. Weber, F. E. Lenti, F. F. Paternost, F. G. Pareyn, J. V. Siqueira, J. L. Viera, L. C. Neto, M. M. Saraiva, M. H. Sales, M. P. Salgado, R. Vasconcelos, S. Galano, V. V. Mesquita, and T. Azevedo. Reconstructing three decades of land use and land cover changes in brazilian biomes with landsat archive and earth engine. *Remote Sensing*, 12(17), 2020.
- [96] B. B. N. Strassburg, H. L. Beyer, R. Crouzeilles, A. Iribarrem, F. Barros, M. F. de Siqueira, A. Sánchez-Tapia, A. Balmford, J. B. B. Sansevero, P. H. S. Brancalion, E. N. Broadbent, R. L. Chazdon, A. O. Filho, T. A. Gardner, A. Gordon, A. Latawiec, R. Loyola, J. P. Metzger, M. Mills, H. P. Possingham, R. R. Rodrigues, C. A. d. M. Scaramuzza, F. R. Scarano, L. Tambosi, and M. Uriarte. Strategic approaches to restoring ecosystems can triple conservation gains and halve costs. *Nature Ecology & Evolution*, 3(1):62–70, Jan. 2019.
- [97] B. B. N. Strassburg, A. Iribarrem, H. L. Beyer, C. L. Cordeiro, R. Crouzeilles, C. C. Jakovac, A. Braga Junqueira, E. Lacerda, A. E. Latawiec, A. Balmford, T. M. Brooks, S. H. M. Butchart, R. L. Chazdon, K.-H. Erb, P. Brancalion, G. Buchanan, D. Cooper, S. Díaz, P. F. Donald, V. Kapos, D. Leclère, L. Miles, M. Obersteiner, C. Plutzar, C. A. de M. Scaramuzza, F. R. Scarano, and P. Visconti. Global priority areas for ecosystem restoration. *Nature*, 586(7831):724–729, oct 2020.
- [98] B. Tao, Y. Yang, J. Yang, R. Smith, J. Fox, A. C. Ruane, J. Liu, and W. Ren. Recent shrinkage and fragmentation of bluegrass landscape in kentucky. *Remote Sensing*, 12(11), 2020.
- [99] N. E. Thomas, C. Huang, S. N. Goward, S. Powell, K. Rishmawi, K. Schleeweis, and A. Hinds. Validation of north american forest disturbance dynamics derived from landsat time series stacks. *Remote Sensing of Environment*, 115(1):19 – 32, 2011.
- [100] C. Vancutsem, F. Achard, J.-F. Pekel, G. Vieilledent, S. Carboni, D. Simonetti, J. Gallego, L. E. O. C. Aragão, and R. Nasi. Long-term (1990–2019) monitoring of forest cover changes in the humid tropics. *Science Advances*, 7(10), 2021.
- [101] V. Velichko and N. Zagoruyko. Automatic recognition of 200 words. *International Journal of Man-Machine Studies*, 2(3):223 – 234, 1970.
- [102] J. Verbesselt, R. Hyndman, G. Newnham, and D. Culvenor. Detecting trend and seasonal changes in satellite image time series. *Remote Sensing of Environment*, 114(1):106 – 115, 2010.

- [103] J. Verbesselt, R. Hyndman, A. Zeileis, and D. Culvenor. Phenological change detection while accounting for abrupt and gradual trends in satellite image time series. *Remote Sensing of Environment*, 114(12):2970 – 2980, 2010.
- [104] J. Verbesselt, A. Zeileis, and M. Herold. Near real-time disturbance detection using satellite image time series. *Remote Sensing of Environment*, 123:98 – 108, 2012.
- [105] A. Viana-Soto, I. Aguado, J. Salas, and M. García. Identifying post-fire recovery trajectories and driving factors using landsat time series in fire-prone mediterranean pine forests. *Remote Sensing*, 12(9), 2020.
- [106] J. V. Z. R. W. R. S. Vicens. Desempenho de descritores de vegetação na classificação de trajetórias evolutivas de floresta pelo algoritmo landtrendr. *Anais do XIX Simpósio Brasileiro de Sensoriamento Remoto*, 2019.
- [107] J. C. Vogeler, R. A. Slesak, P. A. Fekety, and M. J. Falkowski. Characterizing over four decades of forest disturbance in minnesota, usa. *Forests*, 11(3), 2020.
- [108] J. E. Vogelmann, G. Xian, C. Homer, and B. Tolk. Monitoring gradual ecosystem change using landsat time series analyses: Case studies in selected forest and rangeland ecosystems. *Remote Sensing of Environment*, 122:92 – 105, 2012. Landsat Legacy Special Issue.
- [109] Y. Wang, G. Ziv, M. Adami, E. Mitchard, S. A. Batterman, W. Buermann, B. S. Marimon, B. H. M. Junior, S. M. Reis, D. Rodrigues, and D. Galbraith. Mapping tropical disturbed forests using multi-decadal 30m optical satellite imagery. *Remote Sensing of Environment*, 221:474 – 488, 2019.
- [110] R. Weckmüller and R. S. Vicens. Detecção de Mudanças Florestais em Séries Temporais Utilizando os Algoritmos Landtrendr: Estudo de Caso no Estado do Rio de Janeiro. *Geography Department University of Sao Paulo*, 37(July):44–57, 2019.
- [111] Z. Wenbo and L. Shuangcheng. The dynamic response of forest vegetation to hydrothermal conditions in the funiu mountains of western henan province. *Journal of Geographical Sciences*, 5:565–578, 2017.
- [112] J. C. White, M. A. Wulder, T. Hermosilla, and N. C. Coops. Satellite time series can guide forest restoration. *Nature*, 569, 2019.
- [113] M. A. Wulder, T. R. Loveland, D. P. Roy, C. J. Crawford, J. G. Masek, C. E. Woodcock, R. G. Allen, M. C. Anderson, A. S. Belward, W. B. Cohen, J. Dwyer, A. Erb, F. Gao, P. Griffiths, D. Helder, T. Hermosilla, J. D. Hipple, P. Hostert, M. J. Hughes, J. Huntington, D. M. Johnson, R. Kennedy, A. Kilic, Z. Li, L. Lymburner, J. McCorkel, N. Pahlevan, T. A. Scambos, C. Schaaaf, J. R. Schott, Y. Sheng, J. Storey, E. Vermote, J. Vogelmann, J. C. White, R. H. Wynne, and Z. Zhu. Current status of landsat program, science, and applications. *Remote Sensing of Environment*, 225:127–147, 2019.
- [114] M. A. Wulder, J. G. Masek, W. B. Cohen, T. R. Loveland, and C. E. Woodcock. Opening the archive: How free data has enabled the science and monitoring promise of landsat. *Remote Sensing of Environment*, 122:2–10, 2012. Landsat Legacy Special Issue.

- [115] W. Xiao, X. Deng, T. He, and W. Chen. Mapping annual land disturbance and reclamation in a surface coal mining region using google earth engine and the landtrendr algorithm: A case study of the shengli coalfield in inner mongolia, china. *Remote Sensing*, 12(10), 2020.
- [116] Y. Yang, P. D. Erskine, A. M. Lechner, D. Mulligan, S. Zhang, and Z. Wang. Detecting the dynamics of vegetation disturbance and recovery in surface mining area via landsat imagery and landtrendr algorithm. *Journal of Cleaner Production*, 178:353–362, 2018.
- [117] L. Ye, M. Liu, X. Liu, and L. Zhu. Developing a new disturbance index for tracking gradual change of forest ecosystems in the hilly red soil region of southern china using dense landsat time series. *Ecological Informatics*, 61:101221, 2021.
- [118] H. Yin, A. V. Prishchepov, T. Kuemmerle, B. Bleyhl, J. Buchner, and V. C. Radeloff. Mapping agricultural land abandonment from spatial and temporal segmentation of landsat time series. *Remote Sensing of Environment*, 210:12–24, 2018.
- [119] J. V. Zebende, R. Weckmüller, and R. S. Vicens. Análise da Trajetória Evolutiva da Cobertura Florestal do Município de Teresópolis/RJ utilizando o Algoritmo LandTrendr. *Anuário do Instituto de Geociências - UFRJ*, 43(2):316–324, 2020.
- [120] L. Zhu, X. Liu, L. Wu, Y. Tang, and Y. Meng. Long-term monitoring of cropland change near dongting lake, china, using the landtrendr algorithm with landsat imagery. *Remote Sensing*, 11(10), 2019.
- [121] Z. Zhu, S. Wang, and C. E. Woodcock. Improvement and expansion of the fmask algorithm: cloud, cloud shadow, and snow detection for landsats 4–7, 8, and sentinel 2 images. *Remote Sensing of Environment*, 159:269 – 277, 2015.
- [122] Z. Zhu and C. E. Woodcock. Object-based cloud and cloud shadow detection in landsat imagery. *Remote Sensing of Environment*, 118:83 – 94, 2012.
- [123] Z. Zhu and C. E. Woodcock. Continuous change detection and classification of land cover using all available landsat data. *Remote Sensing of Environment*, 144:152 – 171, 2014.
- [124] Z. Zhu, C. E. Woodcock, C. Holden, and Z. Yang. Generating synthetic landsat images based on all available landsat data: Predicting landsat surface reflectance at any given time. *Remote Sensing of Environment*, 162:67 – 83, 2015.
- [125] Z. Zhu, M. A. Wulder, D. P. Roy, C. E. Woodcock, M. C. Hansen, V. C. Radeloff, S. P. Healey, C. Schaaf, P. Hostert, P. Strobl, J.-F. Pekel, L. Lymburner, N. Pahlevan, and T. A. Scambos. Benefits of the free and open landsat data policy. *Remote Sensing of Environment*, 224:382–385, 2019.

Apêndices

A Apêndice - Gráficos com total de área perdida ano a ano por estado

Os gráficos a seguir mostram os anos que mais houveram perda de área para cada estado presente no bioma. O valor da área está em metros quadrados. Todos os gráficos apresentados se referem apenas a eventos com duração igual a um ano, ou seja, não incluem dados referentes a eventos longos de degradação. Essa escolha se deu devido a grande apresentação de eventos de longa duração no primeiro ano da análise, o que torna difícil e pouco interessante a análise dos gráficos.

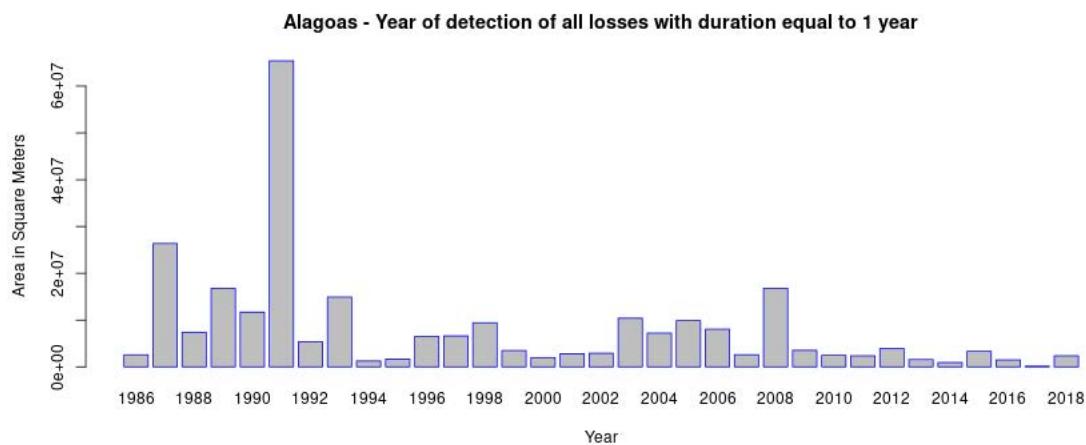


Figura 38: Perda de área por ano em Alagoas

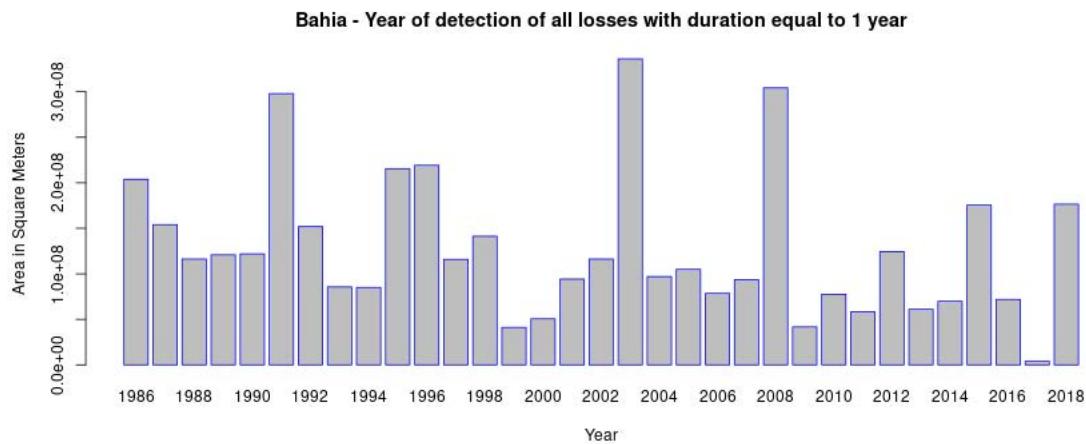


Figura 39: Perda de área por ano na Bahia

Espirito Santo - Year of detection of all losses with duration equal to 1 year

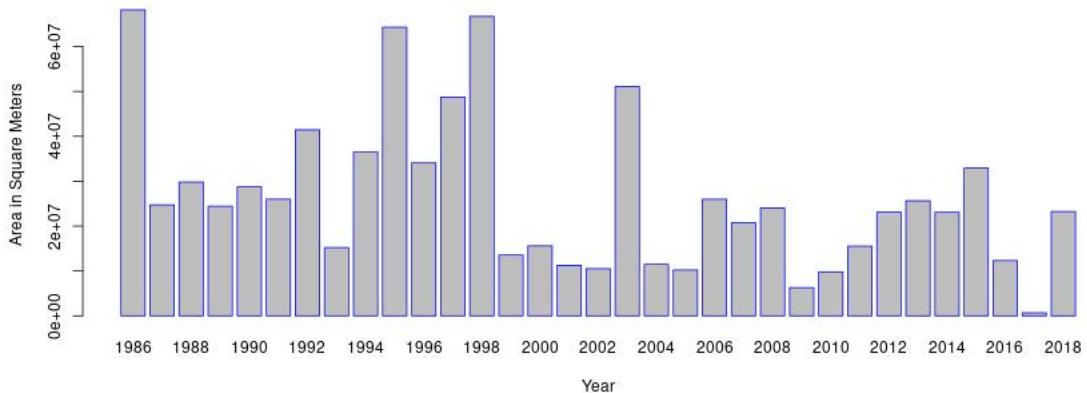


Figura 40: Perda de área por ano no Espírito Santo

Goiás - Year of detection of all losses with duration equal to 1 year

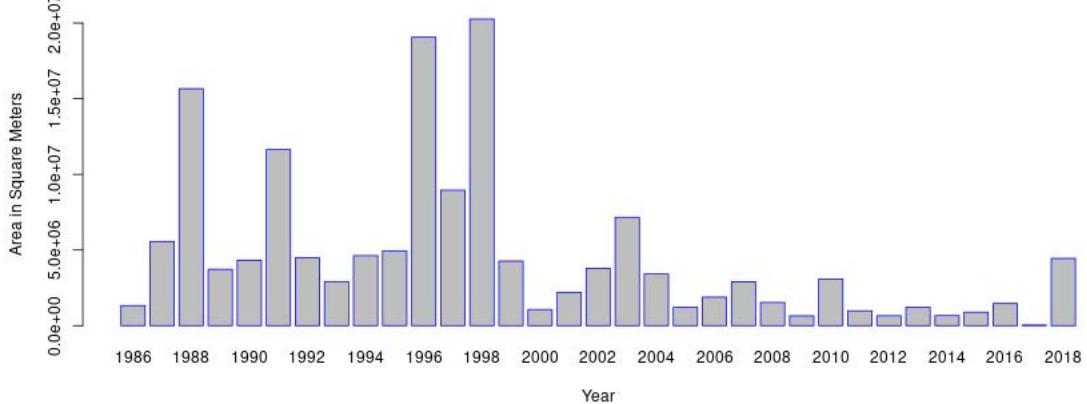


Figura 41: Perda de área por ano em Goiás

Mato Grosso do Sul - Year of detection of all losses with duration equal to 1 year

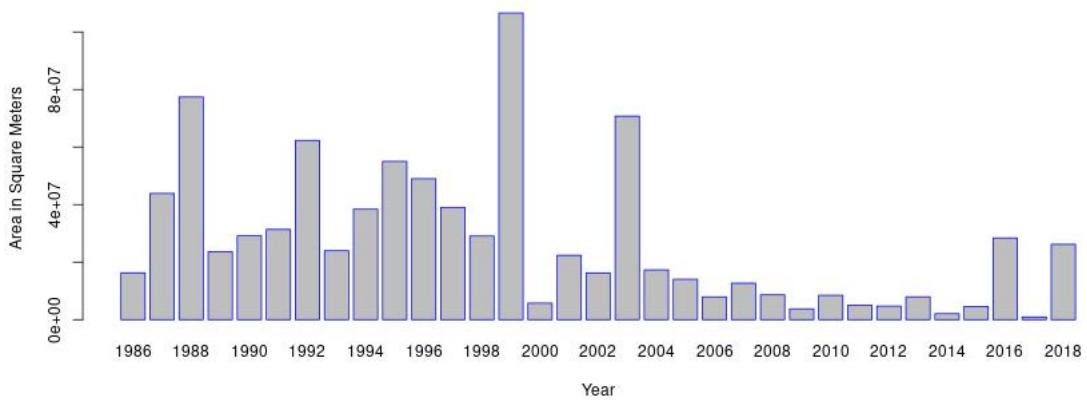


Figura 42: Perda de área por ano no Mato Grosso do Sul

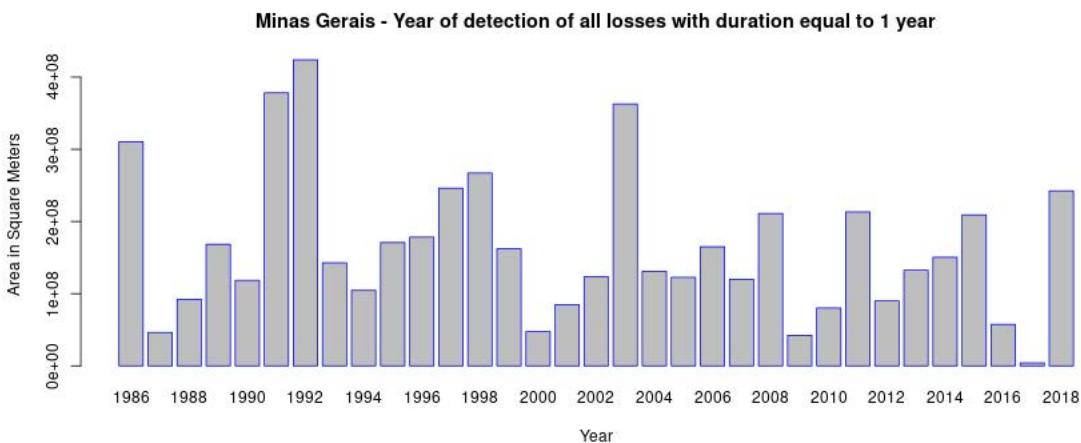


Figura 43: Perda de área por ano em Minas Gerais

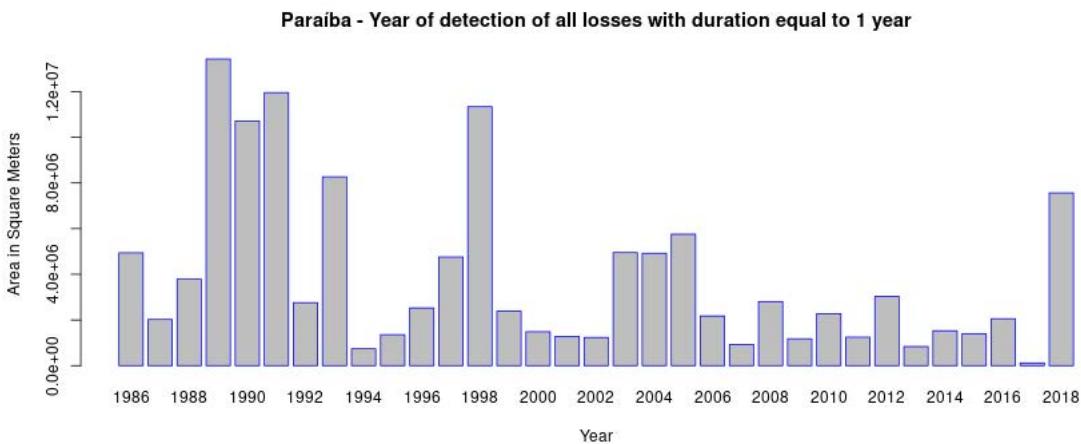


Figura 44: Perda de área por ano na Paraíba

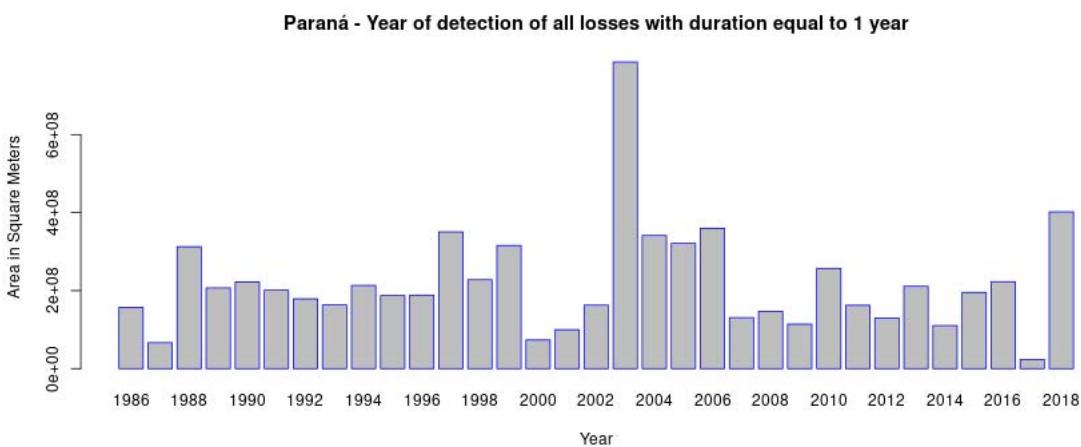


Figura 45: Perda de área por ano no Paraná

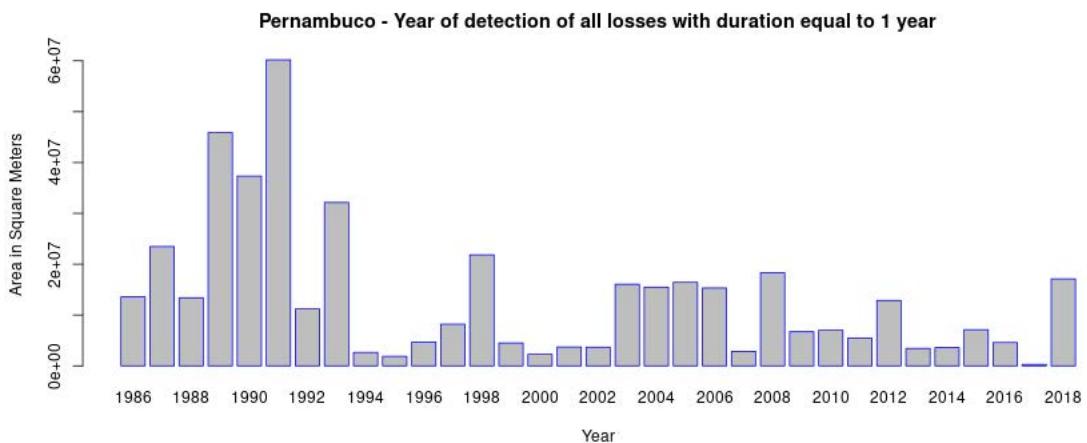


Figura 46: Perda de área por ano em Pernambuco

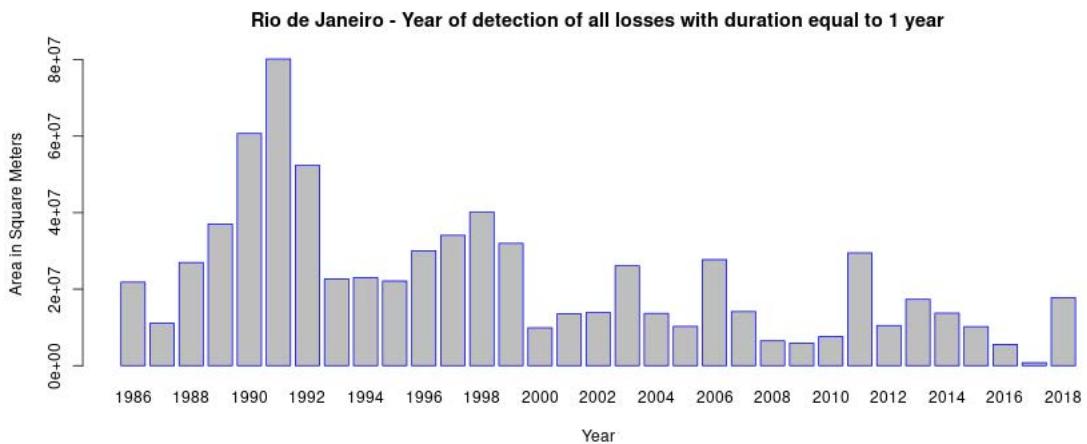


Figura 47: Perda de área por ano no Rio de Janeiro

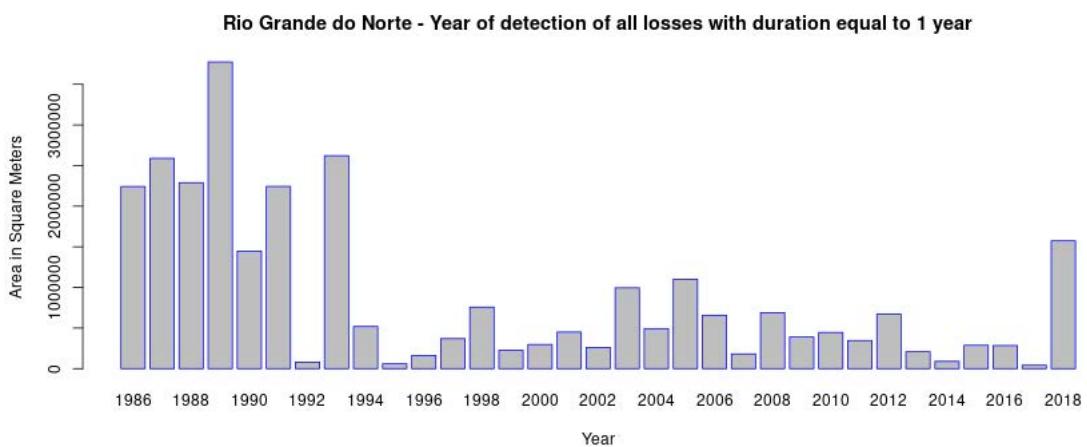


Figura 48: Perda de área por ano no Rio Grande do Norte

Rio Grande do Sul - Year of detection of all losses with duration equal to 1 year

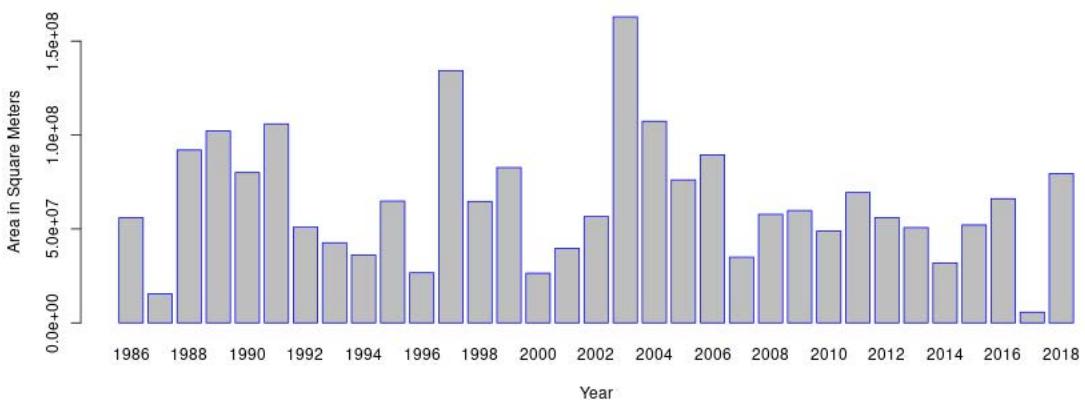


Figura 49: Perda de área por ano no Rio Grande do Sul

Santa Catarina - Year of detection of all losses with duration equal to 1 year

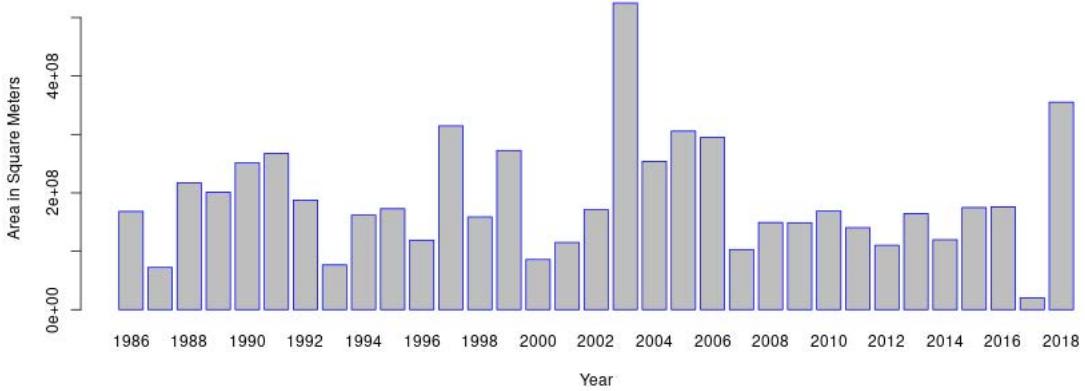


Figura 50: Perda de área por ano em Santa Catarina

São Paulo - Year of detection of all losses with duration equal to 1 year

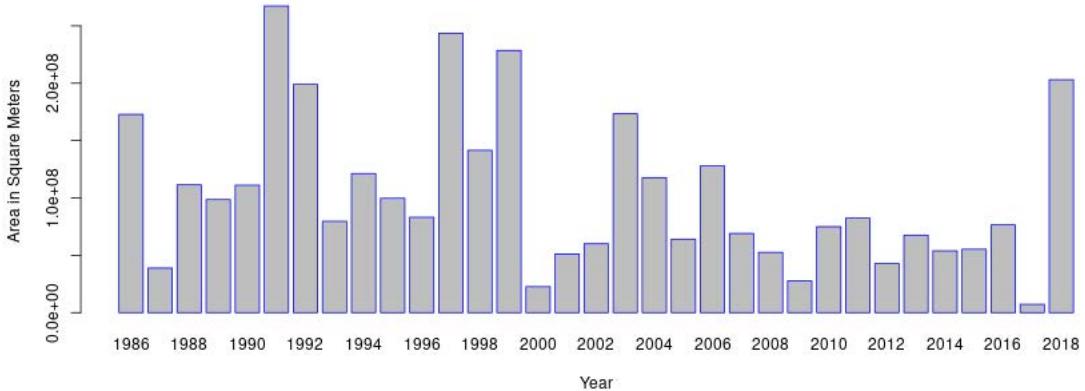


Figura 51: Perda de área por ano em São Paulo

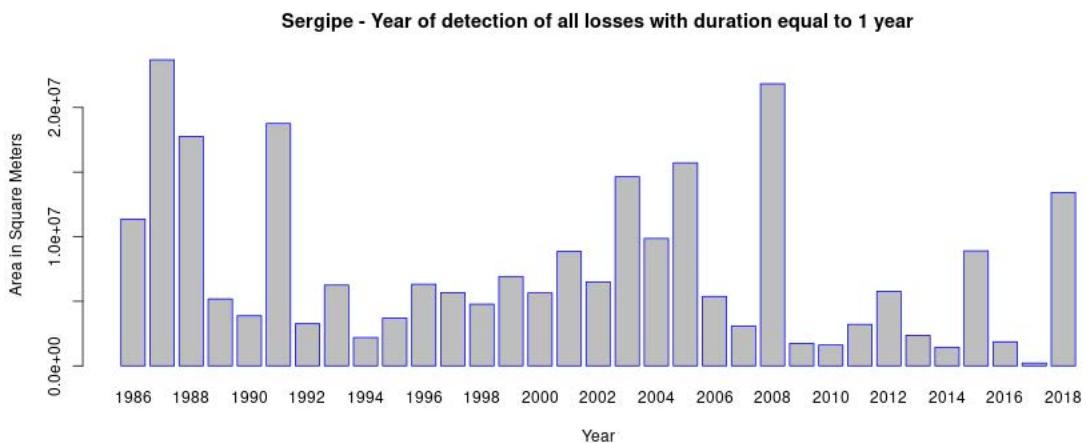


Figura 52: Perda de área por ano em Sergipe

B Apêndice - Gráficos com total de área ganha ano a ano por estado

Os gráficos a seguir mostram os anos que mais houveram ganho de área para cada estado presente no bioma. O valor da área está em metros quadrados. Os gráficos representam apenas eventos que iniciaram a partir de 1987 e não 1986, já que a maior parte dos eventos acabou ficando concentrada no primeiro ano, o que significa que a maior parte dos eventos de ganho detectados são eventos de longa duração.

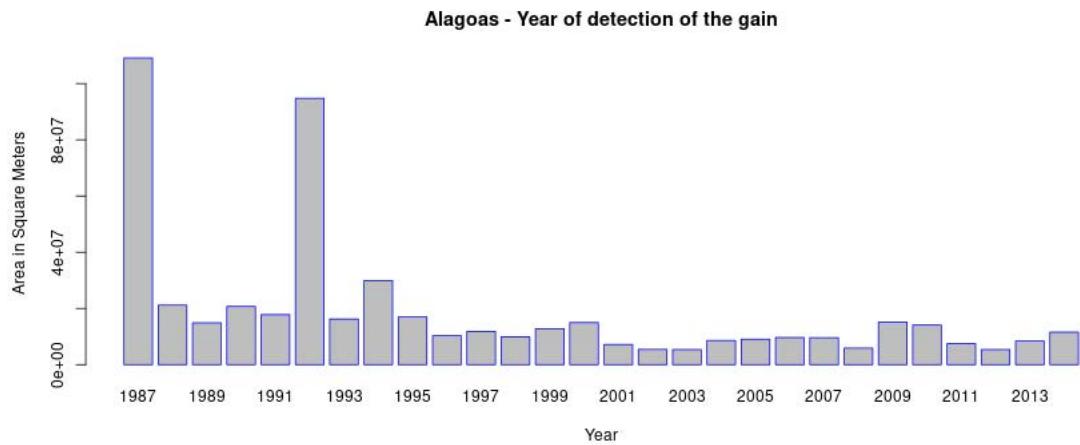


Figura 53: Ganho de área por ano em Alagoas

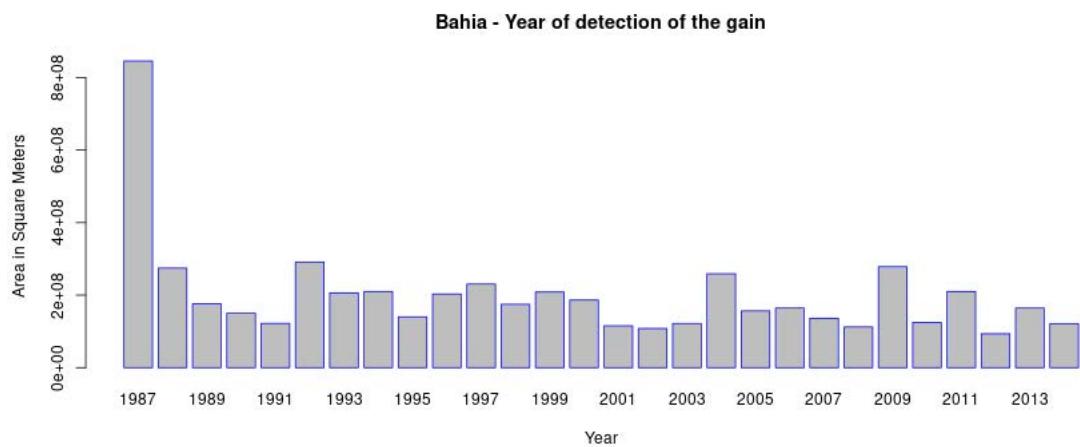


Figura 54: Ganho de área por ano na Bahia

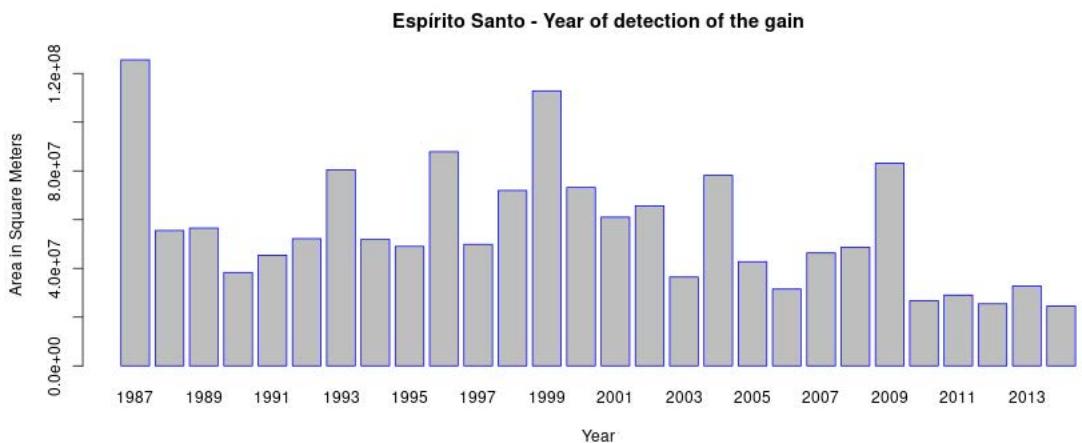


Figura 55: Ganhos de área por ano no Espírito Santo

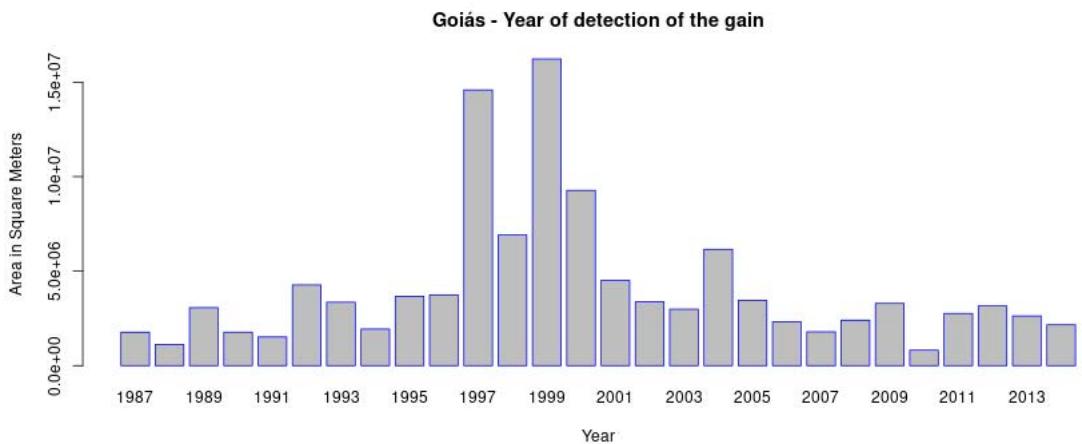


Figura 56: Ganhos de área por ano em Goiás

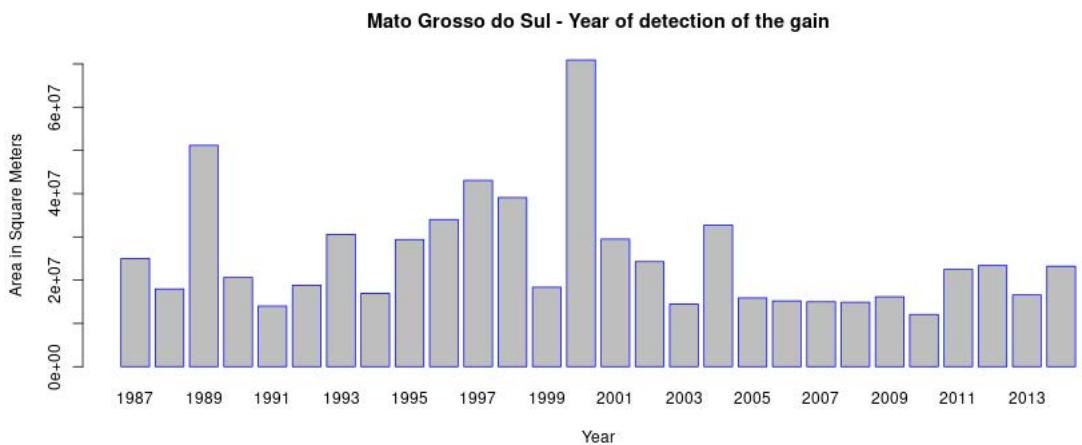


Figura 57: Ganhos de área por ano no Mato Grosso do Sul

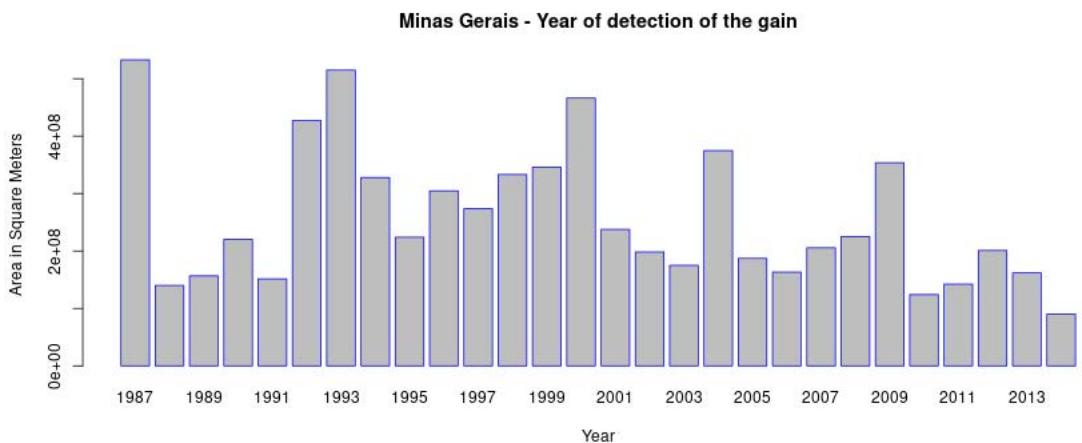


Figura 58: Ganho de área por ano em Minas Gerais

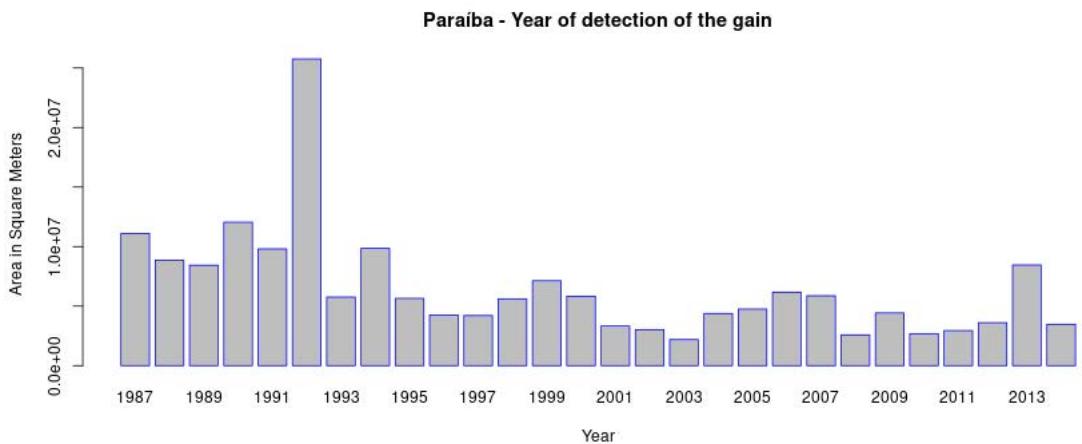


Figura 59: Ganho de área por ano na Paraíba

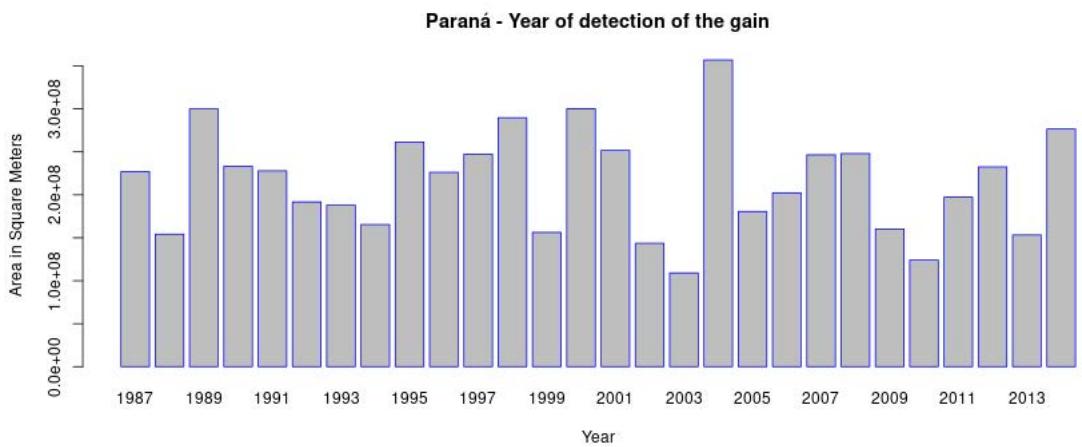


Figura 60: Ganho de área por ano no Paraná

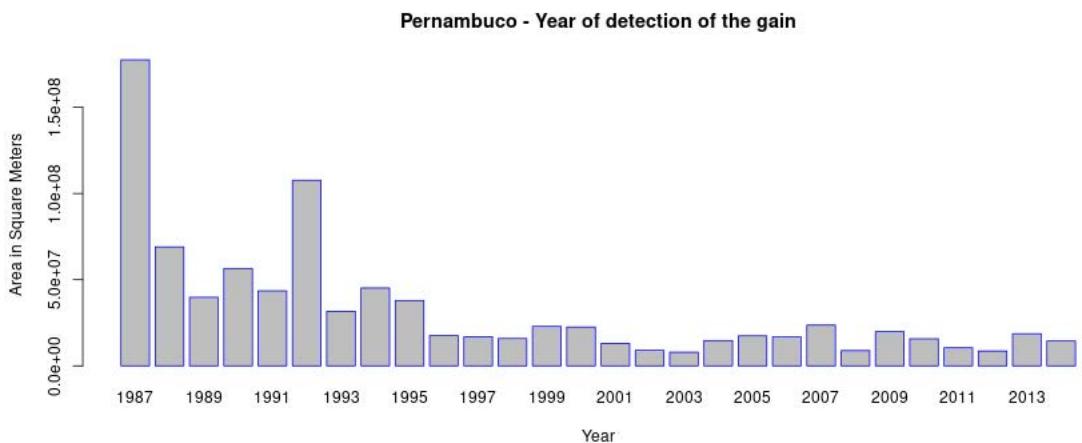


Figura 61: Ganhos de área por ano em Pernambuco

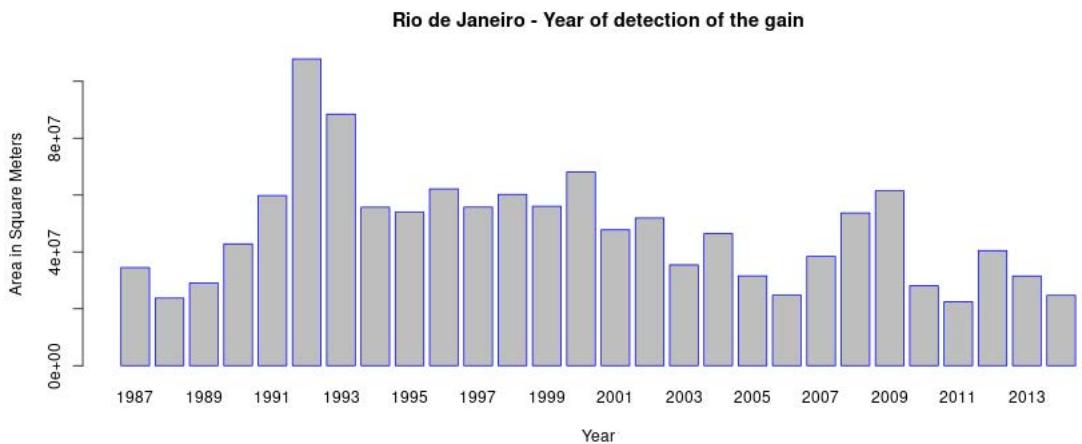


Figura 62: Ganhos de área por ano no Rio de Janeiro

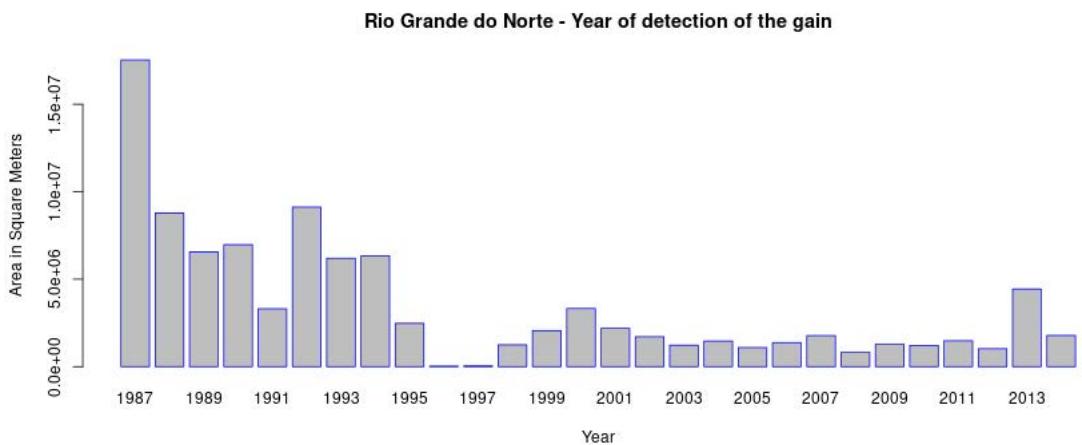


Figura 63: Ganhos de área por ano no Rio Grande do Norte

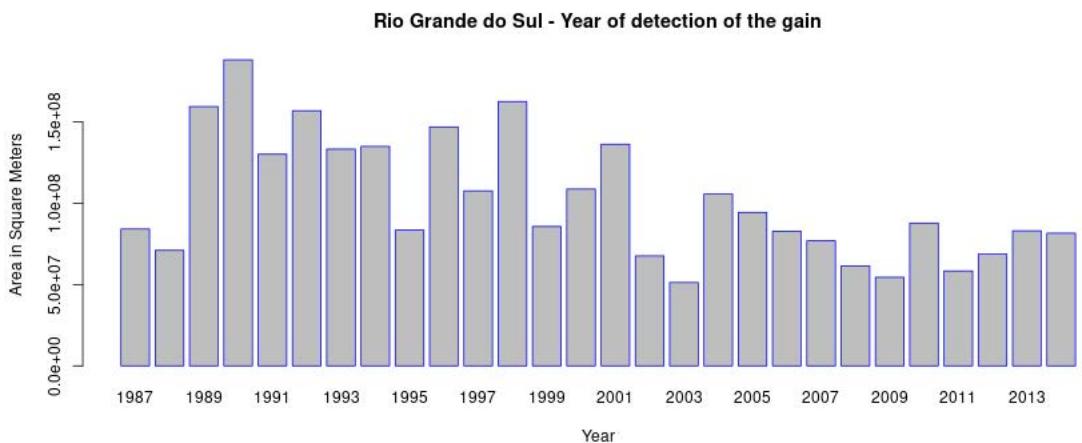


Figura 64: Ganho de área por ano no Rio Grande do Sul

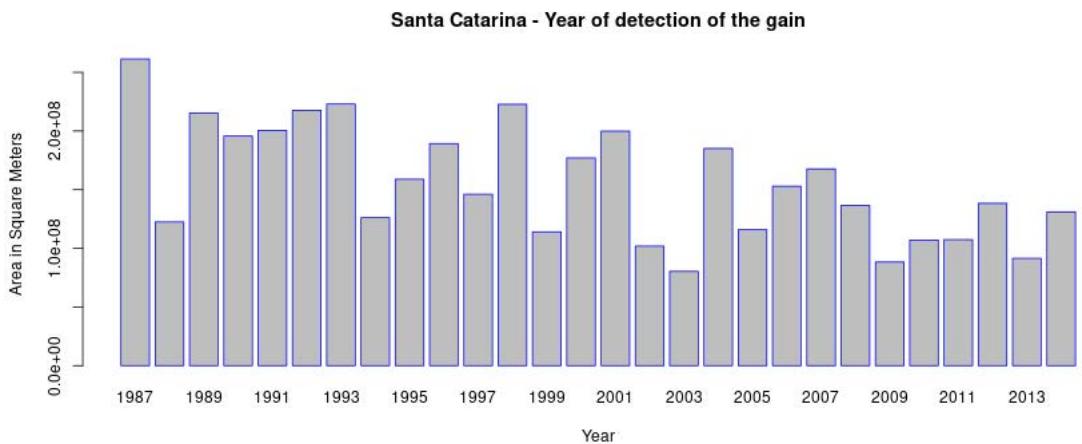


Figura 65: Ganho de área por ano em Santa Catarina

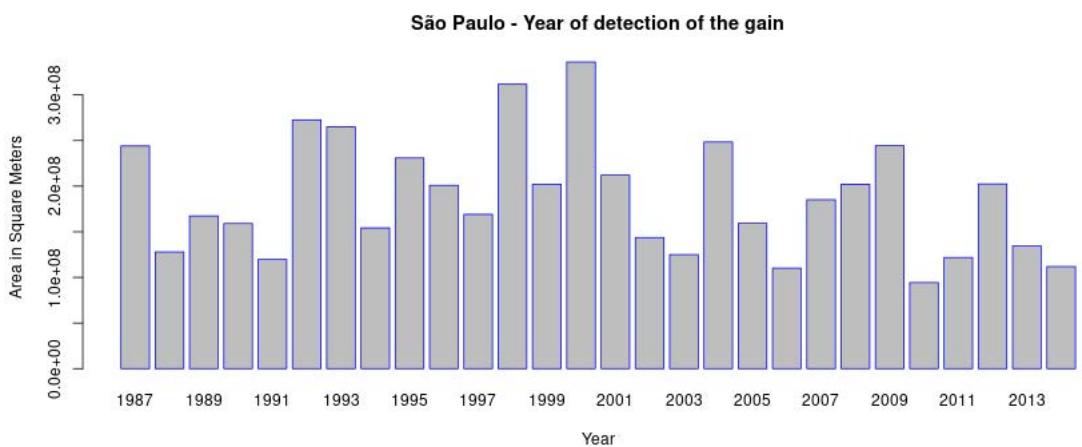


Figura 66: Ganho de área por ano em São Paulo

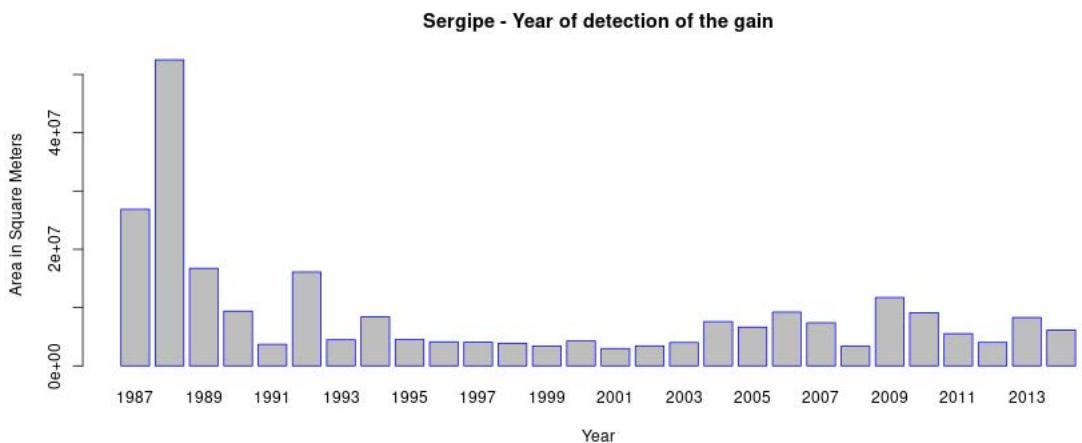


Figura 67: Ganhos de área por ano em Sergipe